

Analyse von Verkehrsunfalldaten in Montgomery County, Maryland

Nele Hauck, Oliver Lucius

2026-01-12

Report von Nele Hauck und Oliver Lucius

1. Definition/Formulierung der Fragestellung

Was interessiert uns an dem Datensatz?

Der Datensatz dokumentiert Verkehrsunfälle in Montgomery County, Maryland, über einen Zeitraum von etwa 10 Jahren (2015–2025). Besonders interessant ist die Möglichkeit, menschliche Verhaltensfaktoren wie Alkohol- und Drogeneinfluss, Ablenkung am Steuer sowie die Interaktion mit vulnerablen Verkehrsteilnehmern zu untersuchen.

Verkehrsunfälle sind keine rein zufälligen Ereignisse, sondern entstehen durch das Zusammenspiel von menschlichem Verhalten, Umweltbedingungen und infrastrukturellen Faktoren. Unser Ziel ist es, Muster und Zusammenhänge zu identifizieren, die zur Unfallprävention beitragen könnten.

Fragestellungen

Im Rahmen dieser Analyse werden sieben zusammenhängende Fragestellungen untersucht, die verschiedene Aspekte des Unfallgeschehens beleuchten.

Deskriptive Fragestellungen

Fragestellung A: Zeitliche Muster von Verkehrsunfällen

Zu welchen Tageszeiten und Wochentagen ereignen sich die meisten Verkehrsunfälle, und unterscheidet sich die Unfallschwere je nach Zeitpunkt?

Eine grundlegende Analyse der zeitlichen Verteilung von Unfällen kann Aufschluss darüber geben, wann besondere Vorsicht geboten ist. Aus `Crash.Date.Time` werden Stunde, Wochentag und Monat extrahiert und mit `Injury.Severity` in Beziehung gesetzt.

Hypothese: Wir erwarten, dass Unfälle während der Rush Hour (7–9 Uhr und 16–18 Uhr) gehäuft auftreten, da dann das Verkehrsaufkommen am höchsten ist. Gleichzeitig vermuten wir, dass nächtliche Unfälle (22–5 Uhr) trotz geringerer Häufigkeit schwerere Verletzungen verursachen, bedingt durch höhere Geschwindigkeiten, schlechtere Sicht und möglicherweise Alkoholeinfluss.

Fragestellung B: Einfluss von Wetter und Straßenbedingungen

Führen ungünstige Wetterbedingungen und Straßenverhältnisse zu schwereren Unfällen?

Diese Fragestellung untersucht den oft vermuteten Zusammenhang zwischen Wetterbedingungen und Unfallschwere. Verwendet werden `Weather`, `Surface.Condition`, `Injury.Severity` und `Vehicle.Damage.Extent`.

Hypothese: Entgegen der intuitiven Annahme erwarten wir, dass Unfälle bei schlechtem Wetter (Regen, Schnee, Eis) nicht zwingend schwerer sind als bei guten Bedingungen. Unsere Vermutung: Fahrer passen ihr Verhalten an und fahren bei widrigen Bedingungen vorsichtiger und langsamer, was die Unfallschwere reduziert.

Analysierende Fragestellungen

Fragestellung C: Substanzeinfluss und Schuldfrage

Sind Fahrer mit nachgewiesenem oder vermutetem Alkohol-/Drogeneinfluss häufiger schuld am Unfall, und führen Unfälle unter Substanzeinfluss zu schwereren Verletzungen?

Diese Fragestellung untersucht den Zusammenhang zwischen Substanzkonsum und der Unfallverantwortung. Verwendet werden die Variablen `Driver.Alcohol`, `Driver.Drugs`, `Driver.At.Fault` und `Injury.Severity`.

Hypothese: Wir erwarten, dass Fahrer mit Alkohol- oder Drogeneinfluss signifikant häufiger als schuldig eingestuft werden als nüchterne Fahrer. Zudem vermuten wir, dass Unfälle unter Substanzeinfluss schwerere Verletzungen nach sich ziehen, da die Reaktionsfähigkeit und das Urteilsvermögen beeinträchtigt sind.

Fragestellung D: Ablenkung am Steuer

Welche Ablenkungsarten sind am häufigsten und wie hängen sie mit dem Kollisionstyp zusammen?

Ablenkung ist eine der Hauptursachen für Verkehrsunfälle. Diese Analyse untersucht, welche Ablenkungsformen (Handynutzung, manuelle Tätigkeiten, visuelle Ablenkung) besonders häufig auftreten und ob bestimmte Ablenkungsarten zu spezifischen Unfalltypen führen. Verwendet werden `Driver.Distracted.By`, `Collision.Type` und `Driver.At.Fault`.

Hypothese: Wir erwarten, dass Handynutzung die häufigste dokumentierte Ablenkungsform ist und überproportional zu Auffahrunfällen führt. Bei der Handynutzung wird der Blick von der Straße abgewendet, wodurch das vorausfahrende Fahrzeug zu spät wahrgenommen wird.

Fragestellung E: Fußgänger- und Radfahrerunfälle

Unter welchen Bedingungen ereignen sich Unfälle mit nicht-motorisierten Verkehrsteilnehmern, und wie schwer sind diese im Vergleich zu reinen Fahrzeugunfällen?

Fußgänger und Radfahrer sind im Straßenverkehr besonders gefährdet. Diese Fragestellung analysiert, unter welchen Lichtverhältnissen und zu welchen Tageszeiten solche Unfälle auftreten und wie schwer die resultierenden Verletzungen sind. Verwendet werden `Related.Non.Motorist`, `Light`, `Injury.Severity` und `Crash.Date.Time`.

Hypothese: Wir erwarten, dass Unfälle mit Fußgängern und Radfahrern häufiger bei schlechten Lichtverhältnissen auftreten und deutlich schwerere Verletzungen verursachen als Unfälle zwischen Fahrzeugen. Der fehlende Schutz durch eine Karosserie macht diese Verkehrsteilnehmer besonders verwundbar.

Ergänzende Fragestellungen

Fragestellung F: Räumliche Unfallhotspots

Wo konzentrieren sich Verkehrsunfälle geografisch, und unterscheiden sich die Hotspots je nach Unfallschwere?

Neben den zeitlichen und verhaltensbezogenen Faktoren ist auch die räumliche Verteilung von Unfällen relevant für die Verkehrssicherheit. Diese Fragestellung untersucht, ob sich Unfälle an bestimmten geografischen Punkten häufen und ob schwere Unfälle andere räumliche Muster aufweisen als leichte. Verwendet werden `Latitude`, `Longitude` und `Injury.Severity`.

Hypothese: Wir erwarten, dass sich Unfälle entlang von Hauptverkehrsachsen und an Knotenpunkten konzentrieren. Zudem vermuten wir, dass schwere Unfälle ein anderes räumliches Muster zeigen könnten. Beispielsweise könnten sie häufiger auf Schnellstraßen mit höheren Geschwindigkeiten auftreten.

Fragestellung G: Fahrzeugtypen und Fahrer-Herkunft

Unterscheiden sich Unfallschwere und Schuldquote je nach Fahrzeugtyp? Woher stammen die unfallbeteiligten Fahrer?

Der Fahrzeugtyp kann sowohl das Unfallrisiko als auch die Verletzungsschwere beeinflussen. Zudem ist interessant, ob lokale Fahrer andere Unfallmuster zeigen als auswärtige. Diese Fragestellung analysiert die Verteilung nach Fahrzeugtyp, Fahrzeugalter und geografischer Herkunft der Fahrer. Verwendet werden `Vehicle.Body.Type`, `Vehicle.Year`, `brands_final`, `Drivers.License.State`, `Driver.At.Fault` und `Injury.Severity`.

Hypothese: Wir erwarten, dass Motorradfahrer die höchste Rate schwerer Verletzungen aufweisen, da sie wie Fußgänger und Radfahrer keinen Karosserieschutz haben. Bei der Fahrer-Herkunft vermuten wir, dass auswärtige Fahrer (nicht aus Maryland) eine leicht höhere Schuldquote aufweisen könnten, da ihnen die Ortskenntnis fehlt.

2. Laden der Daten

Laden der Daten & erster Überblick

Zunächst wurden alle benötigten Pakete installiert und geladen, um die Daten einlesen und untersuchen zu können:

```
#install.packages("skimr")
#install.packages("dplyr")
#install.packages("janitor")
#install.packages("formattable")
library(skimr)
library(dplyr)
library(janitor)
library(formattable)
library(stringr)
library(lubridate)
library(stringdist)
library(knitr)
library(kableExtra)
```

Anschließend wurde der Datensatz geladen:

```
data <- read.csv("data/Crash_Reporting_Drivers_Data.csv")
```

Um einen ersten Überblick über den Datensatz zu erhalten, wurde die folgende Funktion angewendet:

```
skim(data)
```


Table 1: Data summary

Name	data
Number of rows	204688
Number of columns	39
Column type frequency:	
character	35
numeric	4
Group variables	None

Variable type: character

skim_variable	n_missing	complete	ratemin	max	empty	n_unique	whitespace
Report.Number	0	1	10	11	0	115360	0
Local.Case.Number	0	1	4	11	0	115249	0
Agency.Name	0	1	6	25	0	10	0
ACRS.Report.Type	0	1	11	21	0	3	0
Crash.Date.Time	0	1	22	22	0	112545	0
Route.Type	0	1	0	22	20503	20	0
Road.Name	0	1	0	43	23510	4673	0
Cross.Street.Name	8	1	0	85	36744	7464	0
Off.Road.Description	0	1	0	198	185690	13545	0
Municipality	0	1	0	19	48508	22	0
Related.Non.Motorist	0	1	0	86	198036	29	0
Collision.Type	0	1	3	29	0	29	0
Weather	0	1	3	33	0	23	0
Surface.Condition	0	1	0	24	19149	23	0
Light	0	1	3	24	0	17	0
Traffic.Control	0	1	0	72	3015	34	0
Driver.Substance.Abuse	0	1	3	51	0	21	0
Non.Motorist.Substance.Abuse	0	1	0	157	198036	28	0
Person.ID	0	1	36	36	0	204688	0
Driver.At.Fault	0	1	2	7	0	3	0
Injury.Severity	0	1	0	24	2164	11	0
Circumstance	0	1	0	416	24467	751	0
Driver.Distracted.By	0	1	0	49	2336	25	0
Drivers.License.State	0	1	0	6	13659	82	0
Vehicle.ID	0	1	36	36	0	204688	0
Vehicle.Damage.Extent	0	1	3	20	0	13	0

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
Vehicle.First.Impact.Location	0	1	0	20	156	34	0
Vehicle.Body.Type	0	1	0	57	2910	61	0
Vehicle.Movement	0	1	0	23	1095	38	0
Vehicle.Going.Dir	0	1	0	14	8396	11	0
Driverless.Vehicle	0	1	2	7	0	2	0
Parked.Vehicle	0	1	0	3	1526	3	0
Vehicle.Make	11	1	0	20	902	1961	0
Vehicle.Model	25	1	0	40	905	7149	0
Location	0	1	13	27	0	114502	0

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
Speed.Limit	0	1	32.20	11.32	0.00	25.00	35.00	40.00	75.00	
Vehicle.Year	0	1	1965.39	341.82	0.00	2006.00	2012.00	2016.00	9999.00	
Latitude	0	1	39.08	0.07	37.72	39.02	39.07	39.14	39.99	
Longitude	0	1	-	0.10	-	-	-	-	-	
			77.11		79.49	77.19	77.11	77.04	75.53	

Der Datensatz umfasst 39 Variablen und 204.688 Beobachtungen. Von den 39 Variablen sind 35 vom Typ “character”, während die übrigen 4 numerische Werte enthalten. Bereits auf den ersten Blick fällt auf, dass in mehreren Spalten fehlende Werte vorhanden sind. Zudem weisen einige Variablen eine sehr große Anzahl unterschiedlicher Werte auf, was auf eine hohe Individualität innerhalb der Daten hindeutet.

Einen ersten Blick auf die Inhalte des Datensatzes ermöglicht die folgende Funktion:

```
data %>%
  head(5) %>%
  kable() %>%
  kable_styling(bootstrap_options = c("striped", "hover"), full_width = F) %>%
  scroll_box(width = "100%")
```

Report.Number	Local.Case.Number	Agency.Name	ACRS.Report.Type	Crash.Date.Time
MCP3126006X	250037402	MONTGOMERY	Injury Crash	08/21/2025 05:21:00 P
MCP2349001B	250037516	MONTGOMERY	Property Damage Crash	08/22/2025 10:44:00 A
MCP296500BC	250033157	MONTGOMERY	Property Damage Crash	07/25/2025 11:55:00 A
MCP2159003K	250037509	MONTGOMERY	Property Damage Crash	08/22/2025 10:36:00 A

Beim Betrachten der ersten Zeilen wird deutlich, dass mehrere Spalten fehlende Werte aufweisen, die sich durch leere Felder bemerkbar machen.

Zur weiteren Übersicht über die Spalten wurde die folgende Funktion verwendet:

```
summary(data) %>%
  kable() %>%
  kable_styling(bootstrap_options = c("striped", "condensed"), font_size = 12) %>%
  row_spec(1:nrow(summary(data)), extra_css = "white-space: nowrap;") %>%
  scroll_box(width = "100%")
```

Report.Number	Local.Case.Number	Agency.Name	ACRS.Report.Type	Crash.Date.Time
Length:204688	Length:204688	Length:204688	Length:204688	Length:204688
Class :character	Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character	Mode :character
NA	NA	NA	NA	NA
NA	NA	NA	NA	NA
NA	NA	NA	NA	NA

Hierbei fällt insbesondere die Variable “Vehicle.Year” auf, da deren Minimum bei 0 und Maximum bei 9999 liegt. Diese Werte sind offensichtlich unrealistisch für ein Fahrzeugmodelljahr und müssen daher im nächsten Schritt bereinigt werden.

Zur detaillierten Analyse der Datenstruktur wurde anschließend folgende Funktion eingesetzt:

```
str(data)
```

```
'data.frame': 204688 obs. of 39 variables:
 $ Report.Number      : chr  "MCP3126006X" "MCP2349001B" "MCP296500BC" "MCP2159003B" ...
 $ Local.Case.Number  : chr  "250037402" "250037516" "250033157" "250037509" ...
 $ Agency.Name        : chr  "MONTGOMERY" "MONTGOMERY" "MONTGOMERY" "MONTGOMERY" ...
 $ ACRS.Report.Type   : chr  "Injury Crash" "Property Damage Crash" "Property Damage Crash" ...
 $ Crash.Date.Time    : chr  "08/21/2025 05:21:00 PM" "08/22/2025 10:44:00 AM" "07/23/2025 10:44:00 AM" ...
 $ Route.Type         : chr  "Maryland (State) Route" "Interstate (State)" "Bicycle Route" ...
 $ Road.Name          : chr  "" "EISENHOWER MEMORIAL HWY" "" "" ...
 $ Cross.Street.Name  : chr  "" "" "NEW HAMPSHIRE AVE (SB/L) NORBECK RD (WB/L) SPEARHEAD RD (WB/L) ...
 $ Off.Road.Description : chr  "" "" "" "" ...
```

```

$ Municipality           : chr  "" "" "" "" ...
$ Related.Non.Motorist   : chr  "" "" "" "" ...
$ Collision.Type         : chr  "Front to Rear" "Single Vehicle" "Sideswipe, Same Dir
$ Weather                : chr  "Clear" "Clear" "Clear" "Clear" ...
$ Surface.Condition      : chr  "Dry" "Dry" "Dry" "Dry" ...
$ Light                 : chr  "Daylight" "Daylight" "Daylight" "Daylight" ...
$ Traffic.Control        : chr  "No Controls" "No Controls" "Traffic Control Signal"
$ Driver.Substance.Abuse : chr  "Not Suspect of Alcohol Use, Not Suspect of Drug Use"
$ Non.Motorist.Substance.Abuse : chr  "" "" "" "" ...
$ Person.ID             : chr  "BB3CB0F3-5A89-45FB-9516-48DDDB92B0A9" "9B84E695-215A
$ Driver.At.Fault       : chr  "Yes" "No" "No" "Yes" ...
$ Injury.Severity       : chr  "No Apparent Injury" "" "No Apparent Injury" "No Appa
$ Circumstance          : chr  "Followed Too Closely" "" "" "Followed Too Closely" .
$ Driver.Distracted.By  : chr  "Other Action (looking away from task, etc.)" "" "Not
$ Drivers.License.State : chr  "MD" "" "CO" "MD" ...
$ Vehicle.ID            : chr  "768C98FA-C137-47BC-BE44-EE3BA4B95F66" "BC322ECD-006B
$ Vehicle.Damage.Extent : chr  "Superficial" "Vehicle Not at Scene" "Superficial" "D
$ Vehicle.First.Impact.Location: chr  "Twelve O Clock" "Vehicle Not at Scene" "Seven O Clock
$ Vehicle.Body.Type     : chr  "Passenger Car" "" "Passenger Car" "Van - Passenger (
$ Vehicle.Movement      : chr  "Moving Constant Speed" "Moving Constant Speed" "Movin
$ Vehicle.Going.Dir     : chr  "Northbound" "Northbound" "Westbound" "Southbound" ..
$ Speed.Limit           : int  40 55 40 30 0 25 0 25 10 35 ...
$ Driverless.Vehicle    : chr  "No" "No" "No" "No" ...
$ Parked.Vehicle        : chr  "No" "No" "No" "No" ...
$ Vehicle.Year          : int  2013 0 2023 2003 2023 2016 2025 2021 2022 2018 ...
$ Vehicle.Make          : chr  "KIA" "" "LEXUS" "TOYOTA" ...
$ Vehicle.Model         : chr  "SOUL" "" "RX" "SIENNA" ...
$ Latitude              : num  39.2 39.2 39.1 39.2 39 ...
$ Longitude             : num  -77.3 -77.3 -77 -77.1 -77.1 ...
$ Location              : chr  "(39.219796, -77.25741635)" "(39.18018079, -77.250657)

```

Die Ausgabe zeigt, welche Datentypen den einzelnen Spalten zugeordnet sind und wie gut diese zu den tatsächlichen Werten passen. Beispielsweise ist die Spalte “Local.Case.Number” aktuell als “character” gespeichert, obwohl sie numerische Werte enthält. Eine Umwandlung in einen numerischen Datentyp wäre hier sinnvoll. Auch die Variable “Crash.Date.Time” ist derzeit vom Typ “character”, obwohl sie Datum- und Uhrzeitinformaten enthält. Eine Konvertierung in ein passendes Datum-/Zeitformat sowie eine mögliche Trennung von Datum und Uhrzeit wäre hier angebracht. Darüber hinaus ist die Variable “Driver.At.Fault” ebenfalls als “character” gespeichert, enthält jedoch die Werte “Yes” und “No”. Eine Umwandlung in einen logischen Datentyp wäre hier möglicherweise sinnvoll. Gleiches gilt für die Spalten “Driverless.Vehicle” und “Parked.Vehicle”, die ähnliche Strukturen aufweisen. Die Variable “Location” enthält zwar Koordinaten im Textformat, muss jedoch nicht zwingend angepasst

werden, da zwei weitere Variablen bereits den Breitengrad und den Längengrad numerisch getrennt darstellen. Mehrere Variablen des Datensatzes könnten potenziell kategorische Merkmale darstellen, da sie nur eine begrenzte Anzahl möglicher Werte enthalten. Welche Spalten genau in Faktoren umgewandelt werden sollten, lässt sich jedoch erst im weiteren Verlauf bestimmen - nachdem fehlende Werte, Duplikate und fehlerhafte Einträge bereinigt wurden.

Ein weiterer interessanter Aspekt ist die Betrachtung des Zeitraums, den die Daten abdecken. Dieser lässt sich über die Variable `Crash.Date.Time` ermitteln, die jedoch zunächst in ein Datumsobjekt konvertiert werden muss.

ID-Werte & Duplikate

Die Variablen `Person.ID` und `Vehicle.ID` enthalten für den gesamten Datensatz eindeutige Werte. Demnach war keine Person und kein Fahrzeug innerhalb des betrachteten Zeitraums an mehreren Unfällen beteiligt.

Die Variable `Report.Number` weist hingegen nur 115.360 eindeutige Werte bei insgesamt 204.688 Dateneinträgen auf. Dies deutet darauf hin, dass zu einem einzelnen Unfall mehrere Datensätze existieren können. Dies kann der Fall sein, wenn mehrere Personen oder Fahrzeuge in einem Unfall beteiligt waren. Dies wird im Folgenden näher untersucht:

```
duplicate_reports <- data %>%
  get_dupes(`Report.Number`) %>% # filter all duplicates
  arrange(`Report.Number`)

duplicate_reports %>%
  head(5) %>%
  select(`Report.Number`, dupe_count, `Person.ID`) %>%
  formattable(
    list(
      `Report.Number` = formatter("span"),
      `Person.ID` = formatter("span", style = "font-family: monospace;")
    ),
    col.names = c("Report Number", "Duplicate Count", "Person ID")
  )
```

Report Number

Duplicate Count

Person ID

DD5502000M

2

21B019B7-7957-4CB5-8B16-79E037A916AB

DD5502000M

2

0EF6BBAB-2144-49FD-83C8-73CA3869C172

DD5502000N

2

7BF47B38-0B45-497C-A979-60F97BF572BA

DD5502000N

2

9858D2CF-B453-4AF6-ADDF-3191F6511EA4

DD5502000P

2

FF312DA1-1C43-43B4-B53F-E99B5B0E16F2

Aus dem Tabellenausschnitt wird deutlich, dass pro Person ein eigener Dateneintrag für jeden Crash Report existiert. Wenn mehrere Personen an einem Unfall beteiligt sind, erscheinen entsprechend mehrere Datensätze für denselben Crash Report. Beispielsweise sind im Crash Report “DD5502000M” zwei verschiedene Personen erfasst, was zu zwei separaten Dateneinträgen für diesen Bericht führt.

Weitergehend wird untersucht, wie viele Personen maximal an einem einzelnen Unfall beteiligt sind:

```
duplicate_reports %>%
  arrange(desc(dupe_count)) %>%
  distinct(`Report.Number`, .keep_all = TRUE) %>%
  head(5) %>%
  select(`Report.Number`, dupe_count, `Person.ID`) %>%
  formattable(
    list(
      `Report.Number` = formatter("span"),
      `Person.ID` = formatter("span", style = "font-family: monospace;")
    ),
    col.names = c("Report Number", "Duplicate Count", "Person ID")
  )
```

Report Number

Duplicate Count

Person ID

MCP229800RC

10

2FA9A390-7EA4-48FB-80A4-0DB5E9C7FCC9

MCP12130045

9

9EBB9ADA-A3DF-4F14-8EDC-30B9FC292E66

MCP2693003Q

9

FC00244B-0E63-4A1A-83EA-7293E718EB54

MCP32800050

9

DCA4744F-981D-49BD-B6D3-55DA9B8A63E0

MCP2667000H

8

9D42EDC4-1C24-4C7F-99EE-3C398BF63A8D

Die Tabelle zeigt die Crash Reports mit der höchsten Anzahl an beteiligten Personen. In den Daten ist ein Unfall mit 10 und drei Unfälle mit jeweils 9 beteiligten Personen sichtbar.

Diese Informationen ermöglichen eine gezielte Analyse der Faktoren, die zu Massenunfällen führen können. Beispielsweise lässt sich untersuchen, ob bestimmte Straßenabschnitte oder Verkehrssituationen die Wahrscheinlichkeit für größere Unfälle erhöhen. Auf dieser Grundlage können Empfehlungen abgeleitet werden, welche Straßenabschnitte zu bestimmten Zeiten besonders vorsichtig befahren oder gegebenenfalls gemieden werden sollten.

Dasselbe Prinzip gilt für die Variable Local.Case.Number, welche die Fallnummer der jeweiligen lokalen Untersuchungsbehörde für den Unfall darstellt. Auch das Auftreten von Duplikaten in der Spalte Crash.Date.Time ist dadurch erklärbar, da für einen einzelnen Unfall mehrere Einträge existieren können.

Auffällig ist jedoch, dass die Anzahl der eindeutigen Crash.Date.Time-Werte geringer ist als die Anzahl der Report Numbers. Dies weist darauf hin, dass mehrere unabhängige Unfälle zur exakt gleichen Zeit registriert wurden.

```
date_time_counts <- data %>%
  group_by(`Crash.Date.Time`) %>%
  summarise(
    report_count = n_distinct(`Report.Number`)
  ) %>%
  arrange(desc(report_count))
date_time_counts %>%
  filter(report_count > 1)
```

```
# A tibble: 2,714 x 2
  Crash.Date.Time      report_count
  <chr>              <int>
1 02/24/2017 04:30:00 PM          5
2 05/22/2015 09:55:00 PM          5
3 01/04/2020 06:00:00 PM          4
4 03/03/2017 06:00:00 AM          4
5 07/03/2022 09:44:00 PM          4
6 08/05/2024 11:33:00 PM          4
7 10/20/2017 06:32:00 AM          4
8 01/04/2021 05:02:00 AM          3
9 01/06/2015 05:30:00 AM          3
10 01/07/2019 11:15:00 AM          3
# i 2,704 more rows
```

Die Auswertung zeigt, dass in 2.714 Fällen mindestens zwei Unfälle denselben Zeitstempel aufweisen. Das Maximum liegt bei fünf gleichzeitig erfassten Unfällen.

Ein weiterer relevanter Aspekt ist die Region, aus der die Daten stammen. Hierfür wurde die Variable Agency.Name analysiert, die die verschiedenen Polizeibehörden erfasst:

```
unique(data$Agency.Name)
```

```
[1] "MONTGOMERY"          "TAKOMA"
[3] "GAITHERSBURG"       "ROCKVILLE"
[5] "MCPARK"              "Takoma Park Police Depart"
[7] "Montgomery County Police" "Gaithersburg Police Depar"
[9] "Rockville Police Departme" "Maryland-National Capital"
```

Die Auswertung zeigt, dass die Daten aus Montgomery County, Maryland, USA stammen. Bei den Einträgen treten jedoch mehrfach Schreibvarianten derselben Polizeibehörde auf, weshalb die Spalte vor der weiteren Analyse noch bereinigt werden muss, um konsistente Kategorien zu gewährleisten.

3. Bearbeiten/Transformieren der Daten

Für die Datenbereinigung wurde jede Spalte systematisch auf fehlende Werte, fehlerhafte Einträge, Inkonsistenzen und Redundanzen geprüft. Bei Bedarf wurden die Variablen anschließend in die passenden Datentypen konvertiert.

Da viele Spalten sowohl klein- als auch großgeschriebene Einträge enthalten, wurden zunächst alle Character-Werte in Großbuchstaben konvertiert und führende sowie nachgestellte Leerzeichen entfernt. Dadurch lassen sich Werte, die sich lediglich in der Groß-/Kleinschreibung unterscheiden, direkt zusammenfassen.

```
data <- data %>%  
  mutate(across(where(is.character), ~ str_to_upper(str_trim(.))))  
)
```

Anschließend wurden die eindeutigen Werte jeder Spalte überprüft, um inkonsistente Schreibweisen zusammenzuführen und potenziell kategoriale Variablen zu identifizieren. Dabei wurden zusammengehörige Einträge mithilfe der Funktion “str_detect()” aus der Bibliothek stringr vereinheitlicht:

```
sort(unique(data$Agency.Name)  
)
```

```
[1] "GAITHERSBURG"          "GAITHERSBURG POLICE DEPAR"  
[3] "MARYLAND-NATIONAL CAPITAL" "MCPARK"  
[5] "MONTGOMERY"            "MONTGOMERY COUNTY POLICE"  
[7] "ROCKVILLE"            "ROCKVILLE POLICE DEPARTME"  
[9] "TAKOMA"                "TAKOMA PARK POLICE DEPART"
```

```
data$Agency.Name[str_detect(data$Agency.Name, "^TAK")] <- "Takoma Park Police Department"  
data$Agency.Name[str_detect(data$Agency.Name, "^GAI")] <- "Gaithersburg Police Department"  
data$Agency.Name[str_detect(data$Agency.Name, "^ROCK")] <- "Rockville Police Department"  
data$Agency.Name[str_detect(data$Agency.Name, "^MONT")] <- "Montgomery County Police Department"  
data$Agency.Name[str_detect(data$Agency.Name, "^((MCP|MARY))")] <- "Maryland-National Capital Police"  
  
data$Agency.Name <- as.factor(data$Agency.Name)
```

Auch die Spalte “Route.Type” wurde bereinigt. Leere Werte und Platzhalter wie “unknown” wurden in NA umgewandelt. Da jeder Unfall auf einer Route stattfindet, der konkrete Routentyp in diesen Fällen jedoch nicht bestimmbar ist, gehen durch diese Konvertierung keine relevanten Informationen verloren.

```
sort(unique(data$Route.Type))
```

```
[1] "" "BICYCLE ROUTE" "COUNTY"
[4] "COUNTY ROUTE" "CROSSOVER" "GOVERNMENT"
[7] "GOVERNMENT ROUTE" "INTERSTATE (STATE)" "LOCAL ROUTE"
[10] "MARYLAND (STATE)" "MARYLAND (STATE) ROUTE" "MUNICIPALITY"
[13] "MUNICIPALITY ROUTE" "OTHER PUBLIC ROADWAY" "PRIVATE ROUTE"
[16] "RAMP" "SERVICE ROAD" "SPUR"
[19] "UNKNOWN" "US (STATE)"
```

```
data$Route.Type[str_detect(data$Route.Type, "^MARY")] <- "Maryland (State) Route"
data$Route.Type[str_detect(data$Route.Type, "^COUN")] <- "County Route"
data$Route.Type[str_detect(data$Route.Type, "^MUNI")] <- "Municipality Route"
data$Route.Type[str_detect(data$Route.Type, "^GOV")] <- "Government Route"
data$Route.Type[str_detect(data$Route.Type, "^UNK") | data$Route.Type==""] <- NA

data$Route.Type <- as.factor(data$Route.Type)
```

Die Variable “ACRS.Report.Type” enthielt bereits drei eindeutige Werte mit eigenen Bedeutungen. Daher war keine weitere Zusammenführung oder Behandlung fehlender Werte notwendig:

```
sort(unique(data$ACRS.Report.Type))
```

```
[1] "FATAL CRASH" "INJURY CRASH" "PROPERTY DAMAGE CRASH"
```

```
data$ACRS.Report.Type <- as.factor(data$ACRS.Report.Type)
```

Die Spalte “Crash.Date.Time” war ursprünglich als character abgespeichert und enthielt Datum und Uhrzeit im Format “MM/DD/YYYY hh:mm:ss AM/PM”. Für die weitere Analyse wurde sie in ein Datums-/Zeitobjekt konvertiert.

Da sich die Daten auf Montgomery County, Maryland, USA beziehen, wurde die Zeitzone “EST” angegeben.

Das Minimum und Maximum der Datumswerte erfassen den Zeitraum der Daten vom 01.01.2015 bis zum 21.10.2025, also die letzten 10 Jahre.

```
head(data$Crash.Date.Time, 10)
```

```
[1] "08/21/2025 05:21:00 PM" "08/22/2025 10:44:00 AM" "07/25/2025 11:55:00 AM"
[4] "08/22/2025 10:36:00 AM" "08/03/2025 02:10:00 PM" "08/19/2025 09:50:00 AM"
[7] "08/23/2025 11:50:00 AM" "08/21/2025 10:45:00 PM" "08/20/2025 03:15:00 PM"
[10] "08/04/2025 03:47:00 PM"
```

```
data$Crash.Date.Time <- mdy_hms(data$Crash.Date.Time, tz="EST")

min(data$Crash.Date.Time, na.rm = T)
```

```
[1] "2015-01-01 00:30:00 EST"
```

```
max(data$Crash.Date.Time, na.rm = T)
```

```
[1] "2025-10-21 21:38:00 EST"
```

```
skim(data)
```

Table 6: Data summary

Name	data
Number of rows	204688
Number of columns	39
Column type frequency:	
character	31
factor	3
numeric	4
POSIXct	1
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
Report.Number	0	1	10	11	0	115360	0
Local.Case.Number	0	1	4	11	0	115249	0
Road.Name	0	1	0	43	23510	4673	0
Cross.Street.Name	8	1	0	85	36744	7464	0
Off.Road.Description	0	1	0	198	185690	13490	0

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
Municipality	0	1	0	19	48508	22	0
Related.Non.Motorist	0	1	0	86	198036	28	0
Collision.Type	0	1	3	29	0	26	0
Weather	0	1	3	33	0	18	0
Surface.Condition	0	1	0	24	19149	15	0
Light	0	1	3	24	0	12	0
Traffic.Control	0	1	0	72	3015	30	0
Driver.Substance.Abuse	0	1	3	51	0	21	0
Non.Motorist.Substance.Abuse	0	1	0	157	198036	28	0
Person.ID	0	1	36	36	0	204688	0
Driver.At.Fault	0	1	2	7	0	3	0
Injury.Severity	0	1	0	24	2164	6	0
Circumstance	0	1	0	416	24467	751	0
Driver.Distracted.By	0	1	0	49	2336	23	0
Drivers.License.State	0	1	0	6	13659	82	0
Vehicle.ID	0	1	36	36	0	204688	0
Vehicle.Damage.Extent	0	1	3	20	0	9	0
Vehicle.First.Impact.Location	0	1	0	20	156	32	0
Vehicle.Body.Type	0	1	0	57	2910	53	0
Vehicle.Movement	0	1	0	23	1095	29	0
Vehicle.Going.Dir	0	1	0	14	8396	11	0
Driverless.Vehicle	0	1	2	7	0	2	0
Parked.Vehicle	0	1	0	3	1526	3	0
Vehicle.Make	11	1	0	20	902	1961	0
Vehicle.Model	25	1	0	40	905	7149	0
Location	0	1	13	27	0	114502	0

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
Agency.Name	0	1.0	FALSE	5	Mon: 176468, Roc: 12685, Gai: 10246, Tak: 3770
ACRS.Report.Type	0	1.0	FALSE	3	PRO: 131059, INJ: 73108, FAT: 521
Route.Type	20523	0.9	FALSE	14	Mar: 87956, Cou: 66896, Mun: 11665, US : 8916

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
Speed.Limit	0	1	32.20	11.32	0.00	25.00	35.00	40.00	75.00	
Vehicle.Year	0	1	1965.39	341.82	0.00	2006.00	2012.00	2016.00	9999.00	
Latitude	0	1	39.08	0.07	37.72	39.02	39.07	39.14	39.99	
Longitude	0	1	-	0.10	-	-	-	-	-	
			77.11		79.49	77.19	77.11	77.04	75.53	

Variable type: POSIXct

skim_variable	n_missing	complete_rate	min	max	median	n_unique
Crash.Date.Time	0	1	2015-01-01 00:30:00	2025-10-21 21:38:00	2019-11-07 17:47:00	112545

Die Spalte “Road.Name” enthält 4673 verschiedene Straßennamen, sodass eine vollständige Überprüfung aller Einträge nicht praktikabel ist. Aus dem Ergebnis von `skim(data)` geht jedoch hervor, dass keine Werte NA sind, während 23.510 Werte leer vorliegen. Diese leeren Einträge wurden in NA konvertiert, da sie keine inhaltliche Bedeutung besitzen.

Dasselbe Vorgehen wurde für die Spalten “Cross.Street.Name”, “Off.Road.Description”, “Circumstance” und “Drivers.License.State” angewendet, die ebenfalls eine große Anzahl eindeutiger Werte sowie zahlreiche leere Werte enthalten.

```
# sort(unique(data$Road.Name))
road_names <- sort(unique(data$Road.Name))
cat("Anzahl einzigartiger Straßennamen:", length(road_names), "\n\n")
```

Anzahl einzigartiger Straßennamen: 4673

```
cat("Beispiele (erste 10):\n")
```

Beispiele (erste 10):

```
head(road_names, 10)
```

```
[1] "" "100 BLK PHILADELPHIA"
[3] "1030 VIERS MILL ROAD" "10719 VENETIA MILL CIRCLE"
[5] "10TH AVE" "11160 VEIRS MILL RD (PARKING LOT)"
[7] "11902 RUSTIC FARM COURT" "11TH AVE"
[9] "13046 THYME CT" "1336 VEIRS MILL ROAD"
```

```
data$Road.Name[data$Road.Name==""] <- NA
```

```
# sort(unique(data$Cross.Street.Name))
cross_street_names <- sort(unique(data$Cross.Street.Name))
cat("Anzahl einzigartiger Querstraßennamen:", length(cross_street_names), "\n\n")
```

Anzahl einzigartiger Querstraßennamen: 7464

```
cat("Beispiele (erste 10):\n")
```

Beispiele (erste 10):

```
head(cross_street_names, 10)
```

```
[1] ""
[2] "10TH AVE"
[3] "11TH AVE"
[4] "1300 ERSKINE STREET"
[5] "13TH ST"
[6] "13TH ST BURLINGTON AVE"
[7] "13TH ST GEORGIA AVE GEORGIA AVE (SB/L)"
[8] "13TH STREET"
[9] "16201 NEW HAMPSHIRE AVE"
[10] "16TH ST"
```

```
data$Cross.Street.Name[data$Cross.Street.Name==""] <- NA
```

```
# sort(unique(data$Off.Road.Description))
off_road_desc <- sort(unique(data$Off.Road.Description))
cat("Anzahl einzigartiger Off-Road-Beschreibungen:", length(off_road_desc), "\n\n")
```

Anzahl einzigartiger Off-Road-Beschreibungen: 13490

```
cat("Beispiele (erste 10):\n")
```

Beispiele (erste 10):

```
head(off_road_desc, 10)
```

```
[1] ""
[2] "\"CAPITAL ONE\" BANK PARKING LOT BEHIND 8315 GEORGIA AVE , ENTRANCE NEXT TO 944 BONIFAI
[3] "(9809 MAIN ST UNIT 100) DAMASCUS DOLLAR TREE PARKING LOT"
[4] "(BUS LANE) 250 RICHARD MONTGOMERY DR"
[5] "(MILESTONE SHOPPING CENTER DRIVEWAY )NEAR HENDERSON CORNER /FREDERICK ROAD"
[6] "(WALGREENS PARKING LOT)\n13870 GEORGIA AVENUE\nSILVER SPRING, MD 20906"
[7] "1 HELEN HENEGHAN WAY, ROCKVILLE, MD\n (PARKING GARAGE 2ND LEVEL)"
[8] "1 MEDIMMUNE WAY GAITHERSBURG, MD"
[9] "1 N SUMMIT DRIVE"
[10] "1 WISCONSIN CIRCLE (FRIENDSHIP HEIGHTS METRO BUS-TERMINAL)"
```

```
data$Off.Road.Description[data$Off.Road.Description==""] <- NA
```

```
# sort(unique(data$Circumstance))
circumstances <- sort(unique(data$Circumstance))
cat("Anzahl einzigartiger Umstände:", length(circumstances), "\n\n")
```

Anzahl einzigartiger Umstände: 751

```
cat("Beispiele (erste 10):\n")
```

Beispiele (erste 10):

```
head(circumstances, 10)
```

```
[1] ""
[2] "ANIMAL, BACKUP DUE TO NON-RECURRING INCIDENT"
[3] "ANIMAL, DEBRIS OR OBSTRUCTION"
[4] "ANIMAL, ICY OR SNOW-COVERED"
[5] "ANIMAL, ICY OR SNOW-COVERED, RAIN, SNOW, RUTS, HOLES, BUMPS, WET"
[6] "ANIMAL, N/A"
[7] "ANIMAL, PHYSICAL OBSTRUCTION(S)"
[8] "ANIMAL, RAIN, SNOW, WET"
[9] "ANIMAL, SLEET, HAIL, FREEZ. RAIN, WET"
[10] "ANIMAL, SMOG, SMOKE, WET"
```

```
data$Circumstance[data$Circumstance==""] <- NA

# sort(unique(data$Drivers.License.State))
license_states <- sort(unique(data$Drivers.License.State))
cat("Anzahl einzigartiger Führerschein-Staaten:", length(license_states), "\n\n")
```

Anzahl einzigartiger Führerschein-Staaten: 82

```
cat("Beispiele (erste 10):\n")
```

Beispiele (erste 10):

```
head(license_states, 10)
```

```
[1] ""      "AB"    "AK"    "AL"    "AR"    "AS"    "AZ"    "BC"    "CA"
[10] "CA-ON"
```

```
data$Drivers.License.State[data$Drivers.License.State==""] <- NA
```

Anschließend wurden die Werte der Spalte “Municipality” (dt. Gemeinde) untersucht. Dabei wurden leere Einträge sowie Werte wie “N/A” in NA konvertiert. Die Spalte wurde anschließend von einem Character- in einen Faktortyp umgewandelt, um sie als kategoriale Variable für die weitere Analyse nutzen zu können.

```
sort(unique(data$Municipality))
```

```
[1] ""      "BROOKEVILLE"    "CHEVY CHASE #3"
[4] "CHEVY CHASE #4"  "CHEVY CHASE #5"  "CHEVY CHASE VIEW"
[7] "CHEVY CHASE VILLAGE" "DRUMMOND"        "FRIENDSHIP HEIGHTS"
[10] "GAITHERSBURG"   "GARRETT PARK"    "GLEN ECHO"
[13] "KENSINGTON"      "LAYTONSVILLE"    "MATINS ADDITION"
[16] "N/A"             "NORTH CHEVY CHASE" "POOLESVILLE"
[19] "ROCKVILLE"     "SOMERSET"        "TAKOMA PARK"
[22] "WASHINGTON GROVE"
```

```
data$Municipality[str_detect(data$Municipality, "^N/A") | data$Municipality==""] <- NA

data$Municipality <- as.factor(data$Municipality)
```


Die Spalte “Related.Non.Motorist” enthält Informationen über nicht motorisierte Verkehrsteilnehmer, die an einem Unfall beteiligt waren. Darunter fallen Fußgänger, Radfahrer oder Personen mit anderen Fortbewegungsmitteln wie Rollstühlen oder Scootern, etwa “Pedestrian, Wheelchair”, was darauf hinweist, dass verschiedene Arten von nicht-motorisierten Personen in denselben Unfall involviert waren.

Da ein Unfall in den Daten mehrere Zeilen umfassen kann - jeweils für die unterschiedlichen beteiligten Personen/Fahrzeuge - beschreibt “Related.Non.Motorist” diejenigen Beteiligten, die nicht mit einem Fahrzeug gefahren sind.

Zur Überprüfung der Datenkonsistenz wurde untersucht, ob sich die Inhalte der Spalte “Related.Non.Motorist” innerhalb eines Unfalls unterscheiden. Dies war nicht der Fall, was bedeutet, dass die Einträge für nicht motorisierte Beteiligte innerhalb desselben Unfalls konsistent sind.

Anschließend wurde die Spalte “Related Non-Motorist” inhaltlich bereinigt und zusammengefasst, um Inkonsistenzen und redundante Schreibweisen zu reduzieren. Eine Unterscheidung zwischen elektrischen und nicht-elektrischen Fortbewegungsmitteln wurde bewusst nicht vorgenommen, da zwar einige Kategorien eine solche Differenzierung ermöglichen (z.B. “Scooter”, “Wheelchair”), andere jedoch keine klare Einteilung enthalten (z.B. “BICYCLIST”, “Other Conveyance”).

Die Entscheidung auf diese Kategorie zu verzichten, beruht darauf, dass eine teilweise Zuordnung die Realität unvollständig abbilden würde. Da nicht alle Werte einer elektrischen oder nicht-elektrischen Klasse zugeordnet werden können, wäre eine Analyse auf Basis dieser Klassifizierung nicht verlässlich.

```
data %>%
  group_by(Report.Number) %>%
  filter(n() > 1, !is.na(Related.Non.Motorist)) %>%
  summarise(
    all_equal = n_distinct(Related.Non.Motorist) == 1,
    values = paste(unique(Related.Non.Motorist), collapse = ", " ),
    n_rows = n()
  ) %>%
  arrange(desc(all_equal))
```

```
# A tibble: 78,440 x 4
  Report.Number all_equal values n_rows
  <chr>         <lgl>     <chr>   <int>
1 DD5502000M   TRUE      ""         2
2 DD5502000N   TRUE      ""         2
3 DD5502000P   TRUE      ""         2
4 DD5502000Q   TRUE      ""         2
```

```

5 DD5502000R TRUE "" 2
6 DD5502000S TRUE "" 2
7 DD5502000T TRUE "" 2
8 DD5502000V TRUE "" 2
9 DD5502000W TRUE "" 2
10 DD5502000X TRUE "" 2
# i 78,430 more rows

```

```
sort(unique(data$Related.Non.Motorist))
```

```

[1] ""
[2] "BICYCLIST"
[3] "BICYCLIST, OTHER"
[4] "BICYCLIST, PEDESTRIAN"
[5] "CYCLIST (ELECTRIC)"
[6] "CYCLIST (NON-ELECTRIC)"
[7] "IN ANIMAL-DRAWN VEH"
[8] "MACHINE OPERATOR/RIDER"
[9] "OCCUPANT OF A NON-MOTOR VEHICLE TRANSPORTATION DEVICE"
[10] "OCCUPANT OF MOTOR VEHICLE NOT IN TRANSPORT"
[11] "OCCUPANT OF MOTOR VEHICLE NOT IN TRANSPORT, PEDESTRIAN"
[12] "OTHER"
[13] "OTHER CONVEYANCE"
[14] "OTHER CONVEYANCE, PEDESTRIAN"
[15] "OTHER PEDALCYCLIST"
[16] "OTHER PEDESTRIAN (PERSON IN A BUILDING, SKATER, PERSONAL CONVEYANCE, ETC.)"
[17] "OTHER PEDESTRIAN (PERSON IN A BUILDING, SKATER, PERSONAL CONVEYANCE, ETC.), PEDESTRIAN"
[18] "OTHER, OTHER CONVEYANCE"
[19] "OTHER, PEDESTRIAN"
[20] "PEDESTRIAN"
[21] "PEDESTRIAN, WHEELCHAIR (NON-ELECTRIC)"
[22] "SCOOTER (ELECTRIC)"
[23] "SCOOTER (NON-ELECTRIC)"
[24] "UNKNOWN"
[25] "UNKNOWN TYPE OF NON-MOTORIST"
[26] "UNKNOWN, WHEELCHAIR (ELECTRIC)"
[27] "WHEELCHAIR (ELECTRIC)"
[28] "WHEELCHAIR (NON-ELECTRIC)"

```

```

data$Related.Non.Motorist[data$Related.Non.Motorist==""] <- NA
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^(CYC|BICYCLIST$|OTHER PEDALCYCLIST$)")] <- NA

```

```

data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^IN ANI")] <- "ANIMAL-DRAWN"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^(PEDESTRIAN$|OTHER PEDE)")] <- "PEDESTRIAN"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^(OTHER CONVEYANCE, PEDE|OTI")] <- "OTHER CONVEYANCE"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^(OTHER$|OTHER CONVEYANCE$|")] <- "OTHER CONVEYANCE"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^PEDESTRIAN, W")] <- "PEDESTRIAN"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^Scoo")] <- "Scooter"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^(UNKNOWN$|UNKNOWN TY)")] <- "UNKNOWN"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^UNKNOWN, W")] <- "UNKNOWN"
data$Related.Non.Motorist[str_detect(data$Related.Non.Motorist, "^WHEEL")] <- "WHEELCHAIR"

data$Related.Non.Motorist <- as.factor(data$Related.Non.Motorist)

```

Auch die Werte der Spalten “Collision.Type”, “Weather”, “Surface.Condition”, “Light”, “Traffic.Control”, “Driver.Distracted.By”, “Vehicle.First.Impact.Location”, “Vehicle.Body.Type”, “Vehicle.Movement” und “Vehicle.Going.Dir” wurden gruppiert, um die Unterscheidung zu vereinfachen und eine einheitliche Klassifizierung zu gewährleisten. Anschließend wurden die bereinigten Variablen in kategoriale Variablen umgewandelt, um sie für die weitere Analyse nutzbar zu machen.

```
sort(unique(data$Collision.Type))
```

[1] "ANGLE"	"ANGLE MEETS LEFT HEAD ON"
[3] "ANGLE MEETS LEFT TURN"	"ANGLE MEETS RIGHT TURN"
[5] "FRONT TO FRONT"	"FRONT TO REAR"
[7] "HEAD ON"	"HEAD ON LEFT TURN"
[9] "N/A"	"OPPOSITE DIR BOTH LEFT TURN"
[11] "OPPOSITE DIRECTION SIDESWIPE"	"OTHER"
[13] "REAR TO REAR"	"REAR TO SIDE"
[15] "SAME DIR BOTH LEFT TURN"	"SAME DIR REAR END"
[17] "SAME DIR REND LEFT TURN"	"SAME DIR REND RIGHT TURN"
[19] "SAME DIRECTION LEFT TURN"	"SAME DIRECTION RIGHT TURN"
[21] "SAME DIRECTION SIDESWIPE"	"SIDESWIPE, OPPOSITE DIRECTION"
[23] "SIDESWIPE, SAME DIRECTION"	"SINGLE VEHICLE"
[25] "STRAIGHT MOVEMENT ANGLE"	"UNKNOWN"

```

data$Collision.Type[str_detect(data$Collision.Type, "^(ANG|STRAI)")] <- "ANGLE"
data$Collision.Type[str_detect(data$Collision.Type, "^(FRONT TO F|HEAD|OPPOSITE DIR BO)")] <- "FRONT TO FRONT"
data$Collision.Type[str_detect(data$Collision.Type, "^(FRONT TO R|SAME DIR RE)")] <- "REAR-TO-REAR"
data$Collision.Type[str_detect(data$Collision.Type, "^(OPPOSITE DIREC|SAME DIRECTION SIDE|SI)")] <- "OTHER"
data$Collision.Type[str_detect(data$Collision.Type, "^(SAME DIR BO|SAME DIRECTION LE|SAME DI)")] <- "SAME DIRECTION"
data$Collision.Type[str_detect(data$Collision.Type, "^(N/A|UNKN)")] <- NA

```

```
data$Collision.Type <- as.factor(data$Collision.Type)
```

```
sort(unique(data$Weather))
```

```
[1] "BLOWING SAND, SOIL, DIRT"      "BLOWING SNOW"
[3] "CLEAR"                        "CLOUDY"
[5] "FOG, SMOG, SMOKE"             "FOGGY"
[7] "FREEZING RAIN OR FREEZING DRIZZLE" "N/A"
[9] "OTHER"                        "RAIN"
[11] "RAINING"                      "SEVERE CROSSWINDS"
[13] "SEVERE WINDS"                 "SLEET"
[15] "SLEET OR HAIL"                "SNOW"
[17] "UNKNOWN"                      "WINTRY MIX"
```

```
data$Weather[str_detect(data$Weather, "^(BLOWING SAND|FOG)")] <- "FOG/POOR VISIBILITY"
data$Weather[str_detect(data$Weather, "^(FREEZ|RAIN)")] <- "RAIN"
data$Weather[str_detect(data$Weather, "^(N/A|OTHER|UNK)")] <- NA
data$Weather[str_detect(data$Weather, "^SEV")] <- "WIND"
data$Weather[str_detect(data$Weather, "^(SLEET|SNOW|WINTRY|BLOWING SNOW)")] <- "SNOW/WINTRY"
```

```
data$Weather <- as.factor(data$Weather)
```

```
sort(unique(data$Surface.Condition))
```

```
[1] ""                "DRY"
[3] "ICE"              "ICE/FROST"
[5] "MUD, DIRT, GRAVEL" "N/A"
[7] "OIL"              "OTHER"
[9] "SAND"              "SLUSH"
[11] "SNOW"              "UNKNOWN"
[13] "WATER (STANDING, MOVING)" "WATER(STANDING/MOVING)"
[15] "WET"
```

```
data$Surface.Condition[str_detect(data$Surface.Condition, "^ICE")] <- "ICE"
data$Surface.Condition[str_detect(data$Surface.Condition, "^WAT")] <- "WATER (STANDING/MOVING)"
data$Surface.Condition[str_detect(data$Surface.Condition, "^(N/A|OTH|UNK)")] | data$Surface.C
```

```
data$Surface.Condition <- as.factor(data$Surface.Condition)
```

```
sort(unique(data$Light))
```

```

[1] "DARK - LIGHTED"          "DARK - NOT LIGHTED"
[3] "DARK - UNKNOWN LIGHTING" "DARK -- UNKNOWN LIGHTING"
[5] "DARK LIGHTS ON"          "DARK NO LIGHTS"
[7] "DAWN"                    "DAYLIGHT"
[9] "DUSK"                    "N/A"
[11] "OTHER"                   "UNKNOWN"

```

```

data$Light[str_detect(data$Light, "^(DARK --|DARK - UN)")] <- "DARK - UNKNOWN LIGHTING"
data$Light[str_detect(data$Light, "^(DARK - LI|DARK LI)")] <- "DARK - LIGHTS ON"
data$Light[str_detect(data$Light, "^(DARK NO|DARK - NO)")] <- "DARK - NO LIGHTS"
data$Light[str_detect(data$Light, "^(N/A|OTH|UNK)")] <- NA

data$Light <- as.factor(data$Light)

sort(unique(data$Traffic.Control))

```

```

[1] ""
[2] "BICYCLE CROSSING SIGN"
[3] "CURVE AHEAD WARNING SIGN"
[4] "FLASHING RAILROAD CROSSING SIGNAL (MAY INCLUDE GATES)"
[5] "FLASHING TRAFFIC CONTROL SIGNAL"
[6] "FLASHING TRAFFIC SIGNAL"
[7] "INTERSECTION AHEAD WARNING SIGN"
[8] "LANE USE CONTROL SIGNAL"
[9] "N/A"
[10] "NO CONTROLS"
[11] "OTHER"
[12] "OTHER PAVEMENT MARKING (EXCLUDING EDGELINES, CENTERLINES, OR LANE LINES)"
[13] "OTHER SIGNAL"
[14] "OTHER WARNING SIGN"
[15] "PEDESTRIAN CROSSING"
[16] "PEDESTRIAN CROSSING SIGN"
[17] "PERSON"
[18] "PERSON (INCLUDING FLAGGER, LAW ENFORCEMENT, CROSSING GUARD, ETC.)"
[19] "RAILWAY CROSSING DEVICE"
[20] "RAMP METER SIGNAL"
[21] "REDUCE SPEED AHEAD WARNING SIGN"
[22] "SCHOOL ZONE"
[23] "SCHOOL ZONE SIGN"
[24] "SCHOOL ZONE SIGN DEVICE"
[25] "STOP SIGN"
[26] "TRAFFIC CONTROL SIGNAL"

```

```
[27] "TRAFFIC SIGNAL"
[28] "UNKNOWN"
[29] "WARNING SIGN"
[30] "YIELD SIGN"
```

```
data$Traffic.Control[str_detect(data$Traffic.Control, "^FLASHING TRAF")] <- "FLASHING TRAFFIC SIGNAL"
data$Traffic.Control[str_detect(data$Traffic.Control, "^PEDEST")] <- "PEDESTRIAN CROSSING SIGN"
data$Traffic.Control[str_detect(data$Traffic.Control, "^PERSON")] <- "PERSON"
data$Traffic.Control[str_detect(data$Traffic.Control, "^SCHOOL")] <- "SCHOOL ZONE SIGN"
data$Traffic.Control[str_detect(data$Traffic.Control, "^TRAFFIC")] <- "TRAFFIC CONTROL SIGNAL"
data$Traffic.Control[str_detect(data$Traffic.Control, "^(OTHER WAR|WAR)")] <- "WARNING SIGN"

data$Traffic.Control <- as.factor(data$Traffic.Control)

sort(unique(data$Driver.Distracted.By))
```

```
[1] ""
[2] "ADJUSTING AUDIO AND OR CLIMATE CONTROLS"
[3] "BY MOVING OBJECT IN VEHICLE"
[4] "BY OTHER OCCUPANTS"
[5] "DIALING CELLULAR PHONE"
[6] "DISTRACTED BY OUTSIDE PERSON OBJECT OR EVENT"
[7] "EATING OR DRINKING"
[8] "INATTENTIVE OR LOST IN THOUGHT"
[9] "LOOKED BUT DID NOT SEE"
[10] "MANUALLY OPERATING (DIALING, PLAYING GAME, ETC.)"
[11] "NO DRIVER PRESENT"
[12] "NOT DISTRACTED"
[13] "OTHER ACTION (LOOKING AWAY FROM TASK, ETC.)"
[14] "OTHER CELLULAR PHONE RELATED"
[15] "OTHER DISTRACTION"
[16] "OTHER ELECTRONIC DEVICE (NAVIGATIONAL PALM PILOT)"
[17] "SMOKING RELATED"
[18] "TALKING OR LISTENING TO CELLULAR PHONE"
[19] "TALKING/LISTENING"
[20] "TEXTING FROM A CELLULAR PHONE"
[21] "UNKNOWN"
[22] "USING DEVICE OBJECT BROUGHT INTO VEHICLE"
[23] "USING OTHER DEVICE CONTROLS INTEGRAL TO VEHICLE"
```

```

data$Driver.Distracted.By[str_detect(data$Driver.Distracted.By, "^(DIAL|OTHER CEL|TALKING OR
data$Driver.Distracted.By[str_detect(data$Driver.Distracted.By, "^(ADJ|MAN|USING|EAT|SMOK)")]
data$Driver.Distracted.By[str_detect(data$Driver.Distracted.By, "^(BY|TALKING/|OTHER ELEC)")]
data$Driver.Distracted.By[str_detect(data$Driver.Distracted.By, "^(DISTRAC|LOOKED)")] <- "VI
data$Driver.Distracted.By[str_detect(data$Driver.Distracted.By, "^(OTHER DIS|OTHER ACT)")] d

data$Driver.Distracted.By <- as.factor(data$Driver.Distracted.By)

sort(unique(data$Vehicle.First.Impact.Location))

```

```

[1] ""
[4] "EIGHT OCLOCK"
[7] "FIVE O CLOCK"
[10] "FOUR OCLOCK"
[13] "NON-COLLISION"
[16] "ROOF TOP"
[19] "SIX O CLOCK"
[22] "TEN OCLOCK"
[25] "TOP"
[28] "TWO O CLOCK"
[31] "UNKNOWN"

"CARGO LOSS"
"ELEVEN O CLOCK"
"FIVE OCLOCK"
"NINE O CLOCK"
"ONE O CLOCK"
"SEVEN O CLOCK"
"SIX OCLOCK"
"THREE O CLOCK"
"TWELVE O CLOCK"
"TWOCLOCK"
"VEHICLE NOT AT SCENE"

```

```

data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^EIGHT")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^ELEVEN")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^FIVE")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^FOUR")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^NINE")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^ONE")] <
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^SEVEN")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^SIX")] <
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^TEN")] <
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^THREE")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^TWELVE")]
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^TWO")] <
data$Vehicle.First.Impact.Location[str_detect(data$Vehicle.First.Impact.Location, "^UNK")] | c

data$Vehicle.First.Impact.Location <- as.factor(data$Vehicle.First.Impact.Location)

sort(unique(data$Vehicle.Body.Type))

```

```

[1] ""

```

- [2] "(SPORT) UTILITY VEHICLE"
- [3] "ALL TERRAIN VEHICLE (ATV)"
- [4] "ALL-TERRAIN VEHICLE/ALL-TERRAIN CYCLE (ATV/ATC)"
- [5] "AMBULANCE/EMERGENCY"
- [6] "AMBULANCE/NON EMERGENCY"
- [7] "AUTOCYCLE"
- [8] "BUS - CROSS COUNTRY"
- [9] "BUS - MINI"
- [10] "BUS - OTHER TYPE"
- [11] "BUS - SCHOOL"
- [12] "BUS - TRANSIT"
- [13] "CARGO VAN/LIGHT TRUCK 2 AXLES (OVER 10,000LBS (4,536 KG))"
- [14] "CONSTRUCTION EQUIPMENT (BACKHOE, BULLDOZER, ETC.)"
- [15] "CROSS COUNTRY BUS"
- [16] "FARM EQUIPMENT (TRACTOR, COMBINE HARVESTER, ETC.)"
- [17] "FARM VEHICLE"
- [18] "FIRE VEHICLE/EMERGENCY"
- [19] "FIRE VEHICLE/NON EMERGENCY"
- [20] "GOLF CART"
- [21] "LIMOUSINE"
- [22] "LOW SPEED VEHICLE"
- [23] "MEDIUM/HEAVY TRUCKS 3 AXLES (OVER 10,000LBS (4,536KG))"
- [24] "MOPED"
- [25] "MOPED OR MOTORIZED BICYCLE"
- [26] "MOTORCYCLE"
- [27] "MOTORCYCLE - 2 WHEELED"
- [28] "MOTORCYCLE - 3 WHEELED"
- [29] "N/A"
- [30] "OTHER"
- [31] "OTHER BUS"
- [32] "OTHER LIGHT TRUCKS (10,000LBS (4,536KG) OR LESS)"
- [33] "OTHER TRUCKS"
- [34] "PASSENGER CAR"
- [35] "PICKUP"
- [36] "PICKUP TRUCK"
- [37] "POLICE VEHICLE/EMERGENCY"
- [38] "POLICE VEHICLE/NON EMERGENCY"
- [39] "RECREATIONAL OFF-HIGHWAY VEHICLES (ROV)"
- [40] "RECREATIONAL VEHICLE"
- [41] "SCHOOL BUS"
- [42] "SINGLE-UNIT TRUCK"
- [43] "SNOWMOBILE"
- [44] "SPORT UTILITY VEHICLE"


```

[45] "STATION WAGON"
[46] "TRANSIT BUS"
[47] "TRUCK TRACTOR"
[48] "UNKNOWN"
[49] "VAN"
[50] "VAN - CARGO"
[51] "VAN - PASSENGER (<9 SEATS)"
[52] "VAN - PASSENGER (15 SEATS)"
[53] "VAN - PASSENGER (9 OR 12 SEATS)"

```

```

data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^ALL")] <- "ALL TERRAIN VEHICLE"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^AMBU")] <- "AMBULANCE"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^(BUS - CR|CR)")] <- "CROSS COUNTRY"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^FARM")] <- "FARM VEHICLE"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^MOPED")] <- "MOPED"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^MOTOR")] <- "MOTORCYCLE"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^(N/A|OTHER$|UNK)")] | data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^PICK")] <- "PICKUP"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^(BUS|SCHOOL|OTHER BUS|TRA|CROSS)")] <- "SCHOOL BUS"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^\\(?(SPOR)")] <- "SPORT UTILITY VEHICLE"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^(CARG|VAN - CAR|VA)")] <- "VAN"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^POL")] <- "POLICE VEHICLE"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^FIRE")] <- "FIRE VEHICLE"
data$Vehicle.Body.Type[str_detect(data$Vehicle.Body.Type, "^(OTHER LIGHT TRUCKS|MEDIUM/HEAVY TRUCKS)")] <- "OTHER LIGHT TRUCKS/MEDIUM/HEAVY TRUCKS"

data$Vehicle.Body.Type <- as.factor(data$Vehicle.Body.Type)

sort(unique(data$Vehicle.Movement))

```

```

[1] "" "ACCELERATING"
[3] "BACKING" "CHANGING LANES"
[5] "DRIVERLESS MOVING VEH." "ENTERING TRAFFIC LANE"
[7] "LEAVING TRAFFIC LANE" "MAKING LEFT TURN"
[9] "MAKING RIGHT TURN" "MAKING U TURN"
[11] "MAKING U-TURN" "MOVING CONSTANT SPEED"
[13] "N/A" "NEGOTIATING A CURVE"
[15] "OTHER" "OVERTAKING/PASSING"
[17] "PARKED" "PARKING"
[19] "PASSING" "RIGHT TURN ON RED"
[21] "SKIDDING" "SLOWING OR STOPPING"
[23] "STARTING FROM LANE" "STARTING FROM PARKED"
[25] "STOPPED IN TRAFFIC" "STOPPED IN TRAFFIC LANE"

```

```
[27] "TURNING LEFT"          "TURNING RIGHT"
[29] "UNKNOWN"
```

```
data$Vehicle.Movement[str_detect(data$Vehicle.Movement, "^MAKING U")] <- "MAKING U-TURN"
data$Vehicle.Movement[str_detect(data$Vehicle.Movement, "^(N/A|OTH|UNK)")] <- NA
data$Vehicle.Movement[str_detect(data$Vehicle.Movement, "^STOP")] <- "STOPPED IN TRAFFIC"
data$Vehicle.Movement[str_detect(data$Vehicle.Movement, "^(MAKING LEFT|TURNING LEFT)")] <- "TURNING LEFT"
data$Vehicle.Movement[str_detect(data$Vehicle.Movement, "^(MAKING RIGHT|TURNING RIGHT)")] <- "TURNING RIGHT"

data$Vehicle.Movement <- as.factor(data$Vehicle.Movement)

sort(unique(data$Vehicle.Going.Dir))
```

```
[1] ""          "EAST"      "EASTBOUND" "NORTH"
[5] "NORTHBOUND" "NOT ON ROADWAY" "SOUTH"      "SOUTHBOUND"
[9] "UNKNOWN"   "WEST"      "WESTBOUND"
```

```
data$Vehicle.Going.Dir[str_detect(data$Vehicle.Going.Dir, "^EAST")] <- "EAST"
data$Vehicle.Going.Dir[str_detect(data$Vehicle.Going.Dir, "^NORTH")] <- "NORTH"
data$Vehicle.Going.Dir[str_detect(data$Vehicle.Going.Dir, "^SOUTH")] <- "SOUTH"
data$Vehicle.Going.Dir[str_detect(data$Vehicle.Going.Dir, "^WEST")] <- "WEST"
data$Vehicle.Going.Dir[data$Vehicle.Going.Dir==""] <- NA

data$Vehicle.Going.Dir <- as.factor(data$Vehicle.Going.Dir)
```

Die Spalten “Driver.Substance.Abuse” und “Non.Motorist.Substance.Abuse” geben an, ob bei den beteiligten Personen Alkohol oder Drogen nachgewiesen oder vermutet wurden. Zusätzlich kann angegeben sein, ob die Einnahme von Medikamenten vermutet oder bestätigt wurde.

Zur besseren Übersicht und Analyse wurden beide Spalten jeweils in drei separate Spalten transformiert: eine für Alkohol, eine für Drogen und eine für Medikamente. Dadurch lassen sich die Informationen zu den verschiedenen Arten einfacher auswerten und vergleichen.

```
sort(unique(data$Driver.Substance.Abuse))
```

```
[1] "ALCOHOL CONTRIBUTED"
[2] "ALCOHOL PRESENT"
[3] "COMBINATION CONTRIBUTED"
[4] "COMBINED SUBSTANCE PRESENT"
[5] "ILLEGAL DRUG CONTRIBUTED"
[6] "ILLEGAL DRUG PRESENT"
```

```

[7] "MEDICATION CONTRIBUTED"
[8] "MEDICATION PRESENT"
[9] "N/A"
[10] "NONE DETECTED"
[11] "NOT SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE"
[12] "NOT SUSPECT OF ALCOHOL USE, SUSPECT OF DRUG USE"
[13] "NOT SUSPECT OF ALCOHOL USE, UNKNOWN"
[14] "OTHER"
[15] "SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE"
[16] "SUSPECT OF ALCOHOL USE, SUSPECT OF DRUG USE"
[17] "SUSPECT OF ALCOHOL USE, UNKNOWN"
[18] "UNKNOWN"
[19] "UNKNOWN, NOT SUSPECT OF DRUG USE"
[20] "UNKNOWN, SUSPECT OF DRUG USE"
[21] "UNKNOWN, UNKNOWN"

```

```

data <- data %>%
  mutate(
    Driver.Alcohol = case_when(
      str_detect(Driver.Substance.Abuse, "ALCOHOL CONTRIBUTED|COMBINATION CONTRIBUTED") ~ "C",
      str_detect(Driver.Substance.Abuse, "ALCOHOL PRESENT|COMBINED SUBSTANCE PRESENT") ~ "P",
      str_detect(Driver.Substance.Abuse, "NONE") ~ "NONE DETECTED",
      str_detect(Driver.Substance.Abuse, "NOT SUSPECT OF ALCOHOL USE") ~ "NOT SUSPECT",
      str_detect(Driver.Substance.Abuse, "SUSPECT OF ALCOHOL USE") ~ "SUSPECT",
      str_detect(Driver.Substance.Abuse, "^(UNKNOWN|N/A|OTH)") ~ "UNKNOWN",
      TRUE ~ "NO CLASSIFICATION"
    ),
    Driver.Drugs = case_when(
      str_detect(Driver.Substance.Abuse, "COMBINATION CONTRIBUTED|ILLEGAL DRUG CONTRIBUTED") ~ "C",
      str_detect(Driver.Substance.Abuse, "COMBINED SUBSTANCE PRESENT|ILLEGAL DRUG PRESENT") ~ "P",
      str_detect(Driver.Substance.Abuse, "NONE") ~ "NONE DETECTED",
      str_detect(Driver.Substance.Abuse, "NOT SUSPECT OF DRUG USE") ~ "NOT SUSPECT",
      str_detect(Driver.Substance.Abuse, "SUSPECT OF DRUG USE") ~ "SUSPECT",
      str_detect(Driver.Substance.Abuse, "^(N/A|NOT SUSPECT OF ALCOHOL USE, UNK|SUSPECT OF ALCOHOL USE, UNK)") ~ "UNKNOWN",
      TRUE ~ "NO CLASSIFICATION"
    ),
    Driver.Medication = case_when(
      str_detect(Driver.Substance.Abuse, "MEDICATION PRESENT") ~ "PRESENT",
      str_detect(Driver.Substance.Abuse, "MEDICATION CONTRIBUTED") ~ "CONTRIBUTED",
      TRUE ~ "UNKNOWN"
    )
  )

```

```
data$Driver.Alcohol<- as.factor(data$Driver.Alcohol)
data$Driver.Drugs<- as.factor(data$Driver.Drugs)
data$Driver.Medication<- as.factor(data$Driver.Medication)
```

```
sort(unique(data$Non.Motorist.Substance.Abuse))
```

```
[1] ""
[2] "ALCOHOL CONTRIBUTED"
[3] "ALCOHOL CONTRIBUTED, ALCOHOL PRESENT"
[4] "ALCOHOL PRESENT"
[5] "ALCOHOL PRESENT, NONE DETECTED"
[6] "COMBINATION CONTRIBUTED"
[7] "COMBINED SUBSTANCE PRESENT"
[8] "ILLEGAL DRUG CONTRIBUTED"
[9] "ILLEGAL DRUG PRESENT"
[10] "MEDICATION PRESENT"
[11] "N/A"
[12] "N/A, NONE DETECTED"
[13] "N/A, UNKNOWN"
[14] "NONE DETECTED"
[15] "NONE DETECTED, UNKNOWN"
[16] "NOT SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE"
[17] "NOT SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE, NOT SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE"
[18] "NOT SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE, NOT SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE"
[19] "NOT SUSPECT OF ALCOHOL USE, SUSPECT OF DRUG USE"
[20] "NOT SUSPECT OF ALCOHOL USE, UNKNOWN"
[21] "OTHER"
[22] "SUSPECT OF ALCOHOL USE, NOT SUSPECT OF DRUG USE"
[23] "SUSPECT OF ALCOHOL USE, SUSPECT OF DRUG USE"
[24] "SUSPECT OF ALCOHOL USE, UNKNOWN"
[25] "UNKNOWN"
[26] "UNKNOWN, NOT SUSPECT OF DRUG USE"
[27] "UNKNOWN, UNKNOWN"
[28] "UNKNOWN, UNKNOWN, UNKNOWN, NOT SUSPECT OF DRUG USE"
```

```
data <- data %>%
  mutate(
    Non.Motorist.Alcohol = case_when(
      str_detect(Non.Motorist.Substance.Abuse, "ALCOHOL CONTRIBUTED|COMBINATION CONTRIBUTED") ~ "ALCOHOL CONTRIBUTED",
      str_detect(Non.Motorist.Substance.Abuse, "ALCOHOL PRESENT|COMBINED SUBSTANCE PRESENT") ~ "ALCOHOL PRESENT",
      str_detect(Non.Motorist.Substance.Abuse, "^NONE") ~ "NONE DETECTED",
```

```

    str_detect(Non.Motorist.Substance.Abuse, "NOT SUSPECT OF ALCOHOL USE") ~ "NOT SUSPECT",
    str_detect(Non.Motorist.Substance.Abuse, "SUSPECT OF ALCOHOL USE") ~ "SUSPECT",
    str_detect(Non.Motorist.Substance.Abuse, "^(UNKNOWN|N/A|OTH)") ~ "UNKNOWN",
    TRUE ~ "NO CLASSIFICATION"
  ),
  Non.Motorist.Drugs = case_when(
    str_detect(Non.Motorist.Substance.Abuse, "COMBINATION CONTRIBUTED|ILLEGAL DRUG CONTRIBUTED") ~ "COMBINATION CONTRIBUTED",
    str_detect(Non.Motorist.Substance.Abuse, "COMBINED SUBSTANCE PRESENT|ILLEGAL DRUG PRESENT") ~ "COMBINED SUBSTANCE PRESENT",
    str_detect(Non.Motorist.Substance.Abuse, "^(ALCOHOL PRESENT, NONE|N/A, NONE|NONE DETECTED, NONE|NONE DETECTED)") ~ "NONE DETECTED",
    str_detect(Non.Motorist.Substance.Abuse, "NOT SUSPECT OF DRUG USE") ~ "NOT SUSPECT",
    str_detect(Non.Motorist.Substance.Abuse, "SUSPECT OF DRUG USE") ~ "SUSPECT",
    str_detect(Non.Motorist.Substance.Abuse, "^(N/A$|N/A, UNK|NONE DETECTED, UNK|NOT SUSPECT OF DRUG USE)") ~ "UNKNOWN",
    TRUE ~ "NO CLASSIFICATION"
  ),
  Non.Motorist.Medication = case_when(
    str_detect(Non.Motorist.Substance.Abuse, "MEDICATION PRESENT") ~ "PRESENT",
    TRUE ~ "UNKNOWN"
  )
)

data$Non.Motorist.Alcohol <- as.factor(data$Non.Motorist.Alcohol)
data$Non.Motorist.Drugs <- as.factor(data$Non.Motorist.Drugs)
data$Non.Motorist.Medication <- as.factor(data$Non.Motorist.Medication)

```

Die Spalte “Driver.At.Fault” enthält drei eindeutige Werte: “Yes”, “No” und “Unknown”. Da “Unknown” angibt, dass die Information nicht bekannt ist, kann dieser Wert in einen fehlenden Wert (NA) umgewandelt werden. Nach dieser Bereinigung kann die Variable als logische Variable interpretiert werden, wodurch sie analytisch klarer und einfacher auswertbar wird.

Ein vergleichbares Vorgehen wurde bei der Spalte “Driverless.Vehicle” angewendet. Zwar tritt hier der Wert “Yes” nicht auf, dennoch wurde die Spalte analog zu “Driver.At.Fault” bereinigt. Dabei kann diskutiert werden, ob die Unterscheidung zwischen “NO” (kein selbstfahrendes Fahrzeug) und “UNKNOWN” (unbekannt, ob selbstfahrend) inhaltlich relevant ist.

Die Spalte “Parked.Vehicle”, die aus den Werten “YES”, “NO” und aus leeren Werten besteht, wurde ebenfalls in eine logische Variable umgewandelt, um eine konsistente und leicht auswertbare Datenstruktur sicherzustellen.

```
sort(unique(data$Driver.At.Fault))
```

```
[1] "NO"          "UNKNOWN" "YES"
```

```
data <- data %>%
  mutate(Driver.At.Fault = case_when(
    Driver.At.Fault == "YES" ~ TRUE,
    Driver.At.Fault == "NO" ~ FALSE,
    Driver.At.Fault == "UNKNOWN" ~ NA,
    TRUE ~ NA
  ))

str(data$Driver.At.Fault)
```

```
logi [1:204688] TRUE FALSE FALSE TRUE FALSE FALSE ...
```

```
sort(unique(data$Driverless.Vehicle))
```

```
[1] "NO"      "UNKNOWN"
```

```
data <- data %>%
  mutate(Driverless.Vehicle = case_when(
    Driverless.Vehicle == "YES" ~ TRUE,
    Driverless.Vehicle == "NO" ~ FALSE,
    Driverless.Vehicle == "UNKNOWN" ~ NA,
    TRUE ~ NA
  ))

str(data$Driverless.Vehicle)
```

```
logi [1:204688] FALSE FALSE FALSE FALSE FALSE FALSE ...
```

```
sort(unique(data$Parked.Vehicle))
```

```
[1] ""      "NO"    "YES"
```

```
data <- data %>%
  mutate(Parked.Vehicle = case_when(
    Parked.Vehicle == "YES" ~ TRUE,
    Parked.Vehicle == "NO" ~ FALSE,
    TRUE ~ NA
  ))

str(data$Parked.Vehicle)
```

```
logi [1:204688] FALSE FALSE FALSE FALSE FALSE FALSE ...
```

In der Spalte “Injury.Severity” wurden leere Einträge in fehlende Werte (NA) umgewandelt. Die verbleibenden eindeutigen Werte wurden anschließend als kategoriale Variablen definiert, um sie für die weitere Analyse nutzbar zu machen.

Ein vergleichbares Vorgehen wurde bei der Spalte “Vehicle.Damage.Extent” angewendet. Der Unterschied besteht darin, dass hier keine leeren Einträge, sondern die Werte “N/A”, “OTHER” und “UNKNOWN” in NA umgewandelt wurden. Diese Werte stehen für Fälle, in denen das genaue Schadensausmaß nicht bekannt oder nicht spezifizierbar ist. Da andere Ausprägungen wie “NO DAMAGE” oder “VEHICLE NOT AT SCENE” vorhanden sind, ist davon auszugehen, dass bei den Fällen ein Schadensgrad existiert, jedoch nicht eindeutig zugeordnet werden konnte.

```
sort(unique(data$Injury.Severity))
```

```
[1] "" "FATAL INJURY"
[3] "NO APPARENT INJURY" "POSSIBLE INJURY"
[5] "SUSPECTED MINOR INJURY" "SUSPECTED SERIOUS INJURY"
```

```
data$Injury.Severity[data$Injury.Severity==""] <- NA
```

```
data$Injury.Severity <- as.factor(data$Injury.Severity)
```

```
sort(unique(data$Vehicle.Damage.Extent))
```

```
[1] "DESTROYED" "DISABLING" "FUNCTIONAL"
[4] "N/A" "NO DAMAGE" "OTHER"
[7] "SUPERFICIAL" "UNKNOWN" "VEHICLE NOT AT SCENE"
```

```
data$Vehicle.Damage.Extent[str_detect(data$Vehicle.Damage.Extent, "^(N/A|OTH|UNK)")] <- NA
```

```
data$Vehicle.Damage.Extent <- as.factor(data$Vehicle.Damage.Extent)
```

Die numerische Spalte “Speed Limit” enthält Werte von 0 bis 75 in 5er-Schritten. Dabei fällt der Wert 0 auf. Da ein Fahrzeug mit einer Geschwindigkeit von 0 nicht fahren kann, ist dieser Wert als gültiges Geschwindigkeitslimit nicht sinnvoll. Denkbar wäre, dass dieser Wert nur für parkende Fahrzeuge zutrifft.

Bei einer näheren Betrachtung der Fälle, in denen das Geschwindigkeitslimit scheinbar 0 beträgt, zeigt sich jedoch, dass 85% dieser Fälle nicht auf parkende Fahrzeuge entfallen. Daher liegt die Vermutung nahe, dass der Wert 0 als Platzhalter für fehlende Werte verwendet wurde.

```
sort(unique(data$Speed.Limit))
```

```
[1] 0 5 10 15 20 25 30 35 40 45 50 55 60 65 70 75
```

```
table(data$Speed.Limit)
```

0	5	10	15	20	25	30	35	40	45	50	55	60
7864	4399	3281	6710	1627	29099	28197	61558	37913	13863	5382	4627	94
65	70	75										
63	10	1										

```
data %>%
  filter(Speed.Limit == 0) %>%
  count(Parked.Vehicle)
```

	Parked.Vehicle	n
1	FALSE	6714
2	TRUE	1011
3	NA	139

Die Spalte “Vehicle.Year” gibt das Baujahr des Fahrzeugs an. Da das erste Auto im Jahr 1886 zugelassen wurde, sind Werte davor nicht sinnvoll. In den Daten kommen jedoch auch Werte wie 1, 97, 198, 215, 1005, oder 1140 vor.

Zweistellige Werte könnten theoretisch auf die letzten beiden Ziffern eines Jahres hinweisen, dies ist jedoch reine Spekulation und lässt sich nicht verifizieren. Auch die anderen abweichenden Werte könnten Tippfehler oder fehlerhafte Einträge sein, was ebenfalls nicht bewiesen werden kann. Dasselbe gilt für Werte nach 2025, da diese in der Zukunft liegen und vermutlich ebenfalls fehlerhaft sind.

Da der erste valide Wert nach 1886 in den Daten 1900 ist, werden alle Werte vor 1900 auf NA gesetzt. Ebenso werden alle Werte nach 2025 auf NA gesetzt, da nur Unfälle bis 2025 im Datensatz erfasst sind.


```
sort(unique(data$Vehicle.Year))
```

```
[1] 0 1 2 3 4 8 13 14 15 97 99 198 200 201 202
[16] 215 999 1000 1005 1008 1012 1014 1015 1025 1111 1140 1234 1900 1901 1911
[31] 1930 1938 1946 1947 1949 1955 1957 1959 1960 1961 1963 1965 1966 1967 1968
[46] 1969 1970 1971 1972 1974 1975 1976 1977 1978 1979 1980 1981 1982 1983 1984
[61] 1985 1986 1987 1988 1989 1990 1991 1992 1993 1994 1995 1996 1997 1998 1999
[76] 2000 2001 2002 2003 2004 2005 2006 2007 2008 2009 2010 2011 2012 2013 2014
[91] 2015 2016 2017 2018 2019 2020 2021 2022 2023 2024 2025 2026 2027 2033 2040
[106] 2041 2048 2055 2099 2100 2101 2102 2103 2104 2105 2107 2109 2200 2201 2204
[121] 2205 2208 2222 2911 2912 2914 2915 2916 2917 2918 2919 2991 2996 2997 2998
[136] 3003 3012 3013 3863 5005 7817 8008 8888 9000 9999
```

```
data$Vehicle.Year[data$Vehicle.Year < 1900] <- NA
```

```
data$Vehicle.Year[data$Vehicle.Year > 2025] <- NA
```

Die Spalten “Vehicle.Make” und “Vehicle.Model” enthalten die Hersteller- und Modellbezeichnungen der Fahrzeuge. In den Rohdaten treten jedoch zahlreiche unterschiedliche Schreibweisen, Abkürzungen und Varianten derselben Bezeichnung auf. Eine manuelle Vereinheitlichung wäre daher sehr zeitaufwendig.

Um eine automatisierte Zuordnung zu ermöglichen, wurden zunächst die 200 am häufigsten vorkommenden Begriffe extrahiert. Diese dienen als Referenzliste, anhand derer jedes Vorkommen aus den Spalten Vehicle.Make und Vehicle.Model abgeglichen wird. Da es jedoch Bezeichnungen gibt, die nicht direkt über den Namen einer Marke oder eines Modells zugeordnet werden können, wurde diese Liste manuell um bekannte Alternativ- und Alias-Bezeichnungen erweitert. So wurde beispielsweise der Begriff “DAIMLER” ergänzt, um ihn später mit den Einträgen von Mercedes-Benz zusammenführen zu können.

Die Zuordnung erfolgt mithilfe der Jaro-Winkler-Distanz, die die Unähnlichkeit zweier Zeichenketten misst. Für jeden Eintrag wird ein Distanzvektor zu allen 200 Referenzbegriffen berechnet. Anschließend wird der kleinste Distanzwert ausgewählt, da er die größte Ähnlichkeit zwischen dem ursprünglichen Begriff und der Referenz darstellt.

Nicht jeder Eintrag lässt sich sinnvoll zuordnen. Deshalb wird nicht automatisch einfach der nächstbeste Treffer übernommen. Stattdessen wurde ein Threshold definiert, der eine Mindestähnlichkeit gewährleisten soll. Nach exemplarischen Tests verschiedener Kombinationen wurde ein Schwellwert von 0.2 festgelegt. Nur wenn der ursprüngliche Wert nicht leer ist und die berechnete Jaro-Winkler-Distanz unterhalb von 0.2 liegt, wird der entsprechende Referenzbegriff übernommen. Ist dies nicht der Fall, wird der Wert als NA gesetzt, um falsche Zuordnungen zu vermeiden.

Da es Bezeichnungen gibt, die nicht durch den Namen direkt zugeordnet werden können, wurde die Liste der 200 Bezeichnungen manuell um bekannte Bezeichnungen ergänzt. Beispielsweise wurde DAIMLER hinzugefügt, um es später mit den Begriffen von Mercedes-Benz zu vereinen.

```
# sort(unique(data$Vehicle.Make))
vehicle_makes <- sort(unique(data$Vehicle.Make))
cat("Anzahl einzigartiger Fahrzeughersteller:", length(vehicle_makes), "\n\n")
```

Anzahl einzigartiger Fahrzeughersteller: 1961

```
cat("Beispiele (erste 10):\n")
```

Beispiele (erste 10):

```
head(vehicle_makes, 10)
```

```
[1] ""                "_"                "00"
[4] "0000"            "00000"           "1/OFF KUSTOMS, LLC"
[7] "102 IRONWORKS, INC." "1D7FL16K04S505648" "1G11B5SL3EF247075"
[10] "1G1BE5SM6H7210069"
```

```
data %>%
  count(Vehicle.Make, sort = T) %>%
  head(200)
```

	Vehicle.Make	n
1	TOYOTA	29411
2	HONDA	23569
3	FORD	20137
4	NISSAN	10381
5	TOYT	8841
6	HOND	5765
7	CHEVROLET	5606
8	HYUNDAI	5232
9	DODGE	5178
10	JEEP	4530
11	BMW	4003
12	UNKNOWN	3748

13	LEXUS	3680
14	CHEV	3670
15	ACURA	3494
16	KIA	3394
17	CHEVY	3212
18	SUBARU	2995
19	MAZDA	2771
20	NISS	2652
21	GMC	2161
22	HYUN	2063
23	MERZ	1713
24	AUDI	1692
25	THOMAS	1569
26	MERCEDES	1364
27	VOLKSWAGEN	1312
28	CHRYSLER	1177
29	GILLIG	1158
30	VOLVO	1143
31	VOLK	1068
32	GILL	1044
33	NEW FLYER	968
34	ACUR	962
35	SUBA	944
36	FREIGHTLINER	916
37		902
38	INFINITI	867
39	DODG	863
40	VOLKSWAGON	807
41	MERCEDES-BENZ	794
42	BUICK	780
43	TESLA	765
44	RAM	716
45	MAZD	714
46	CADILLAC	698
47	FRHT	690
48	MITSUBISHI	644
49	LEXS	605
50	CHRY	581
51	THOM	574
52	MACK	548
53	THOMAS BUILT	505
54	LINCOLN	500
55	MIT	477

56	INTERNATIONAL	434
57	MINI	401
58	SCION	388
59	SATURN	372
60	CADI	369
61	INFI	353
62	VOLKS	349
63	VOLV	331
64	VW	330
65	PONTIAC	320
66	LEXU	317
67	MERCURY	302
68	MERC	285
69	LAND ROVER	279
70	GILG	269
71	SUZUKI	259
72	ISUZU	252
73	INTL	228
74	BUIC	212
75	PORSCHE	206
76	TOYO	204
77	MERCEDEZ	199
78	MERCEDES BENZ	193
79	INFINITY	186
80	JAGUAR	171
81	LINC	167
82	THMS	162
83	SPAR	158
84	HARLEY DAVIDSON	154
85	YAMAHA	149
86	TOYTA	148
87	KENWORTH	147
88	UNK	146
89	ORION	145
90	PONT	142
91	NWFL	140
92	PETERBILT	139
93	NISSIAN	137
94	HYUNDIA	130
95	HINO	124
96	TBU	123
97	SPARTAN	121
98	FIAT	116

99	PIERCE	115
100	TOY	113
101	KAWASAKI	110
102	LANDROVER	102
103	SAAB	100
104	CHEVEROLET	92
105	STERLING	88
106	PTRB	86
107	CHEVORLET	83
108	NFLY	83
109	PORS	80
110	UU	80
111	FREIGHT	77
112	NABI	77
113	TESL	72
114	KW	70
115	LNDR	69
116	HYUND	68
117	ISU	68
118	TOYOT	68
119	PIER	66
120	ORIO	64
121	PETERBUILT	61
122	PIERCE MANUFACTURING	60
123	HUMMER	58
124	PIRC	58
125	BUS	56
126	JAGU	56
127	STRN	56
128	GRUMMAN	55
129	RANGE ROVER	55
130	SUBURU	54
131	IC	53
132	METRO	51
133	SUZI	51
134	OLDSMOBILE	49
135	THOMPSON	46
136	GM	45
137	CHRY	44
138	GENESIS	44
139	SATU	44
140	CADILAC	43
141	MNNI	42

142	XX	42
143	NEW	41
144	PETE	41
145	FREI	40
146	CHRYSTLER	39
147	STLG	39
148	ISUZ	37
149	MASERATI	37
150	SCIO	37
151	TOYOYA	37
152	HYUNDI	36
153	SUZU	36
154	TOYTOA	35
155	NOVA	34
156	OLDS	34
157	GEO	32
158	HARLEY	32
159	MINI COOPER	32
160	DUCATI	31
161	NOVABUS	31
162	LEX	30
163	YAMA	30
164	SMART	29
165	SUB	29
166	HYUNDA	28
167	KENW	28
168	NOVB	28
169	OTHR	28
170	SUBU	28
171	TOYTOTA	28
172	TRIUMPH	28
173	ALFA ROMEO	25
174	PLYMOUTH	25
175	HARLEY-DAVIDSON	24
176	MERCEDEZ BENZ	24
177	MITZ	24
178	NISAN	24
179	USPS	24
180	FLYER	23
181	TOTOTA	23
182	99	22
183	KAWK	22
184	MAZADA	22

185	TOTY	22
186	VOLKS WAGON	22
187	FRT	21
188	INFINTI	21
189	TRANSIT	21
190	CRANE	20
191	HUNDAI	20
192	GENERAL MOTORS	19
193	NISSA	19
194	TSMR	19
195	ACCURA	18
196	GILLIS	18
197	INT	18
198	INTE	18
199	AUTO	17
200	CRAN	17

```
brands <- c("TOYOTA", "HONDA", "FORD", "NISSAN", "CHEVROLET", "HYUNDAI", "DODGE", "JEEP",
"BMW", "LEXUS", "ACURA", "KIA", "SUBARU", "MAZDA", "GMC", "MERCEDES-BENZ",
"AUDI", "THOMAS BUILT", "VOLKSWAGEN", "CHRYSLER", "GILLIG", "VOLVO",
"NEW FLYER", "FREIGHTLINER", "INFINITI", "BUICK", "TESLA", "RAM",
"CADILLAC", "MITSUBISHI", "MACK", "LINCOLN", "INTERNATIONAL", "MINI", "SCION",
"SATURN", "PONTIAC", "MERCURY", "LAND ROVER", "SUZUKI", "ISUZU",
"PORSCHE", "JAGUAR", "HARLEY-DAVIDSON", "YAMAHA", "KENWORTH",
"ORION", "PETERBILT", "HINO", "SPARTAN", "FIAT",
"KAWASAKI", "SAAB", "STERLING", "NABI", "HUMMER", "GRUMMAN",
"RANGE ROVER", "OLDSMOBILE", "THOMPSON", "GENESIS", "MASERATI",
"IC BUS", "METRO", "PIERCE MANUFACTURING", "GILLIG",
"BUS", "UNKNOWN", "DUCATI", "SMART", "ALFA ROMEO", "TRIUMPH", "NOVABUS", "BENZ", "DAIMLER",

threshold <- 0.2

data <- data %>%
  rowwise() %>%
  mutate(
    jw_dist = list(stringdist(Vehicle.Make, brands, method = "jw")),
    min_dist = min(unlist(jw_dist), na.rm = TRUE),
    brands_matched = if (!is.na(Vehicle.Make) && nchar(Vehicle.Make) > 0 && min_dist <= threshold) {
      brands[which.min(unlist(jw_dist))]
    } else {
      NA
    }
  )
```

```

) %>%
ungroup()

data <- data %>%
  mutate(
    brands_final = case_when(
      brands_matched %in% c("DAIMLER", "BENZ", "MERCEDES-BENZ") ~ "MERCEDES-BENZ",
      brands_matched %in% c("BEEMER", "BIMMER", "BMW") ~ "BMW",
      brands_matched %in% c("DATSUN", "NISSAN") ~ "NISSAN",
      brands_matched %in% c("CHEVY", "CHEVROLET") ~ "CHEVROLET",
      TRUE ~ brands_matched
    )
  ) %>%
  select(-brands_matched, -jw_dist, -min_dist)

table(data$brands_final)

```

ACURA	ALFA ROMEO	AUDI
4492	26	2070
BMW	BUICK	BUS
4008	1002	68
CADILLAC	CHEVROLET	CHRYSLER
753	12780	1903
DODGE	DUCATI	FIAT
6081	38	117
FORD	FREIGHTLINER	GENESIS
20176	1096	62
GILLIG	GMC	GRUMMAN
2595	2206	79
HARLEY-DAVIDSON	HINO	HONDA
191	130	29416
HUMMER	HYUNDAI	IC BUS
74	7722	17
INFINITI	INTERNATIONAL	ISUZU
1478	454	412
JAGUAR	JEEP	KAWASAKI
242	4542	142
KENWORTH	KIA	LAND ROVER
196	3395	389
LEXUS	LINCOLN	MACK
4670	687	571

MASERATI	MAZDA	MERCEDES-BENZ
48	3549	2637
MERCURY	METRO	MINI
596	64	467
MITSUBISHI	NABI	NEW FLYER
709	77	1221
NISSAN	NOVABUS	OLDSMOBILE
13252	95	54
ORION	PETERBILT	PIERCE MANUFACTURING
219	348	60
PONTIAC	PORSCHE	RAM
474	308	716
RANGE ROVER	SAAB	SATURN
75	117	492
SCION	SMART	SPARTAN
429	41	297
STERLING	SUBARU	SUZUKI
120	4105	325
TESLA	THOMAS BUILT	THOMPSON
848	2133	798
TOYOTA	TRIUMPH	UNKNOWN
39055	36	3904
VOLKSWAGEN	VOLVO	YAMAHA
2588	1506	184

```
# sort(unique(data$Vehicle.Model))
vehicle_models <- sort(unique(data$Vehicle.Model))
cat("Anzahl einzigartiger Fahrzeugmodelle:", length(vehicle_models), "\n\n")
```

Anzahl einzigartiger Fahrzeugmodelle: 7149

```
cat("Beispiele (erste 10):\n")
```

Beispiele (erste 10):

```
head(vehicle_models, 10)
```

```
[1] ""      "- "    "? "    ". "    ".SENTRA"  "'34"
[7] "(4S)"  "(SD)"  "(TK)"  "(UNKNOWN)"
```

```
data %>%
  count(Vehicle.Model, sort = T) %>%
  head(200)
```

```
# A tibble: 200 x 2
  Vehicle.Model      n
  <chr>            <int>
1 4S                13753
2 TK                10983
3 CAMRY             7600
4 CIVIC             6872
5 COROLLA           6826
6 ACCORD            6745
7 UNKNOWN           4507
8 BUS               3923
9 RAV4              3560
10 ALTIMA            2965
# i 190 more rows
```

```
models <- c("CAMRY", "CIVIC", "COROLLA", "ACCORD", "RAV4", "ALTIMA", "CRV", "HIGHLANDER",
  "PRIUS", "SIENNA", "PILOT", "CHARGER", "ELANTRA", "EXPLORER", "SONATA",
  "ODYSSEY", "ROGUE", "CR-V", "ESCAPE", "JETTA", "F150", "SILVERADO", "FOCUS",
  "FUSION", "TACOMA", "MALIBU", "FORESTER", "VERSA", "IMPALA", "WRANGLER",
  "MUSTANG", "OUTBACK", "EQUINOX", "TAURUS", "PATHFINDER", "GRAND CHEROKEE",
  "CHEROKEE", "TAHOE", "AVALON", "MAXIMA", "FIT", "RAM", "SANTA FE", "PASSAT",
  "SUBURBAN", "TUNDRA", "E350", "4RUNNER", "OPTIMA", "TRANSIT", "CRUZE", "MURANO",
  "ACCENT", "CARAVAN", "F250", "SOUL", "TUCSON", "SORENTO", "RX350", "FORTE",
  "ES350", "YUKON", "TRAVERSE", "LIBERTY", "MODEL 3", "MODEL Y", "328I", "328i",
  "COOPER", "FIESTA", "MATRIX", "CROSSTREK", "CAMARO", "ESCALADE", "MAZDA3",
  "VENZA", "JOURNEY", "HR-V", "TLX", "S60", "COBALT", "ACADIA", "TERRAIN",
  "PACIFICA", "XTERRA", "PATRIOT", "TRAILBLAZER", "CHALLENGER", "LANCER",
  "SEQUOIA", "CRUZ", "GTI", "SOLARA", "TOWN AND COUNTRY", "XC90", "C-CLASS",
  "DART", "GALANT", "CTS", "SONIC", "XC60", "ENCLAVE", "QUEST", "ES300")
```

```
data <- data %>%
  rowwise() %>%
  mutate(
    jw_dist = list(stringdist(Vehicle.Model, models, method = "jw")),
    min_dist = min(unlist(jw_dist), na.rm = TRUE),
    models_matched = if (!is.na(Vehicle.Model) && nchar(Vehicle.Model) > 0 && min_dist <= th
      models[which.min(unlist(jw_dist))])
```

```

    } else {
      NA
    }
  ) %>%
  ungroup()

data <- data %>%
  select(-jw_dist, -min_dist)

table(data$models_matched)

```

328I	4RUNNER	ACADIA	ACCENT
749	763	272	515
ACCORD	ALTIMA	AVALON	C-CLASS
6915	3038	644	541
CAMARO	CAMRY	CARAVAN	CHALLENGER
308	7934	527	297
CHARGER	CHEROKEE	CIVIC	COBALT
1908	667	7037	249
COOPER	COROLLA	CR-V	CROSSTREK
327	7597	1319	466
CRUZ	CRUZE	CRV	CTS
185	496	2765	160
DART	E350	ELANTRA	ENCLAVE
139	1268	3536	133
EQUINOX	ES300	ES350	ESCALADE
714	337	507	237
ESCAPE	EXPLORER	F150	F250
1306	1864	2773	859
FIESTA	FIT	FOCUS	FORESTER
260	591	1151	998
FORTE	FUSION	GALANT	GRAND CHEROKEE
720	1318	147	728
GTI	HIGHLANDER	HR-V	IMPALA
172	2146	352	775
JETTA	JOURNEY	LANCER	LIBERTY
1271	217	204	327
MALIBU	MATRIX	MAXIMA	MAZDA3
966	263	619	382
MODEL 3	MODEL Y	MURANO	MUSTANG
380	190	822	743

ODYSSEY	OPTIMA	OUTBACK	PACIFICA
1921	504	718	193
PASSAT	PATHFINDER	PATRIOT	PILOT
623	661	177	1851
PRIUS	QUEST	RAM	RAV4
2075	133	633	4176
ROGUE	RX350	S60	SANTA FE
1655	723	222	696
SEQUOIA	SIENNA	SILVERADO	SOLARA
203	1953	1244	169
SONATA	SONIC	SORENTO	SOUL
1764	155	460	958
SUBURBAN	TACOMA	TAHOE	TAURUS
545	1106	636	722
TERRAIN	TLX	TOWN AND COUNTRY	TRAILBLAZER
208	861	332	261
TRANSIT	TRAVERSE	TUCSON	TUNDRA
1009	273	482	523
VENZA	VERSA	WRANGLER	XC60
215	938	1041	290
XC90	XTERRA	YUKON	
340	236	318	

Die Spalte “Location” enthält die Breiten- und Längengrade der Unfallorte als Zeichenketten. Daneben existieren die numerischen Spalten “Latitude” und “Longitude”, die jeweils nur den Breiten- bzw. Längengrad enthalten.

Für Montgomery County liegen die gültigen Werte typischerweise zwischen 38.94 und 39.35 für die Breiten und zwischen -77.52 und -76.89 für die Längengrade. Betrachtet man jedoch die Minima und Maxima der Spalten Latitude und Longitude, so liegen einige Werte außerhalb dieses Bereichs. Insgesamt betrifft dies 214 Fälle.

Eine erste Sichtung zeigt, dass diese Orte weder auf anderen Kontinenten noch auf der anderen Seite der USA liegen, sondern teilweise in benachbarten Bundesstaaten liegen. Es ist daher möglich, dass es sich um falsche Werte handelt, aber auch potenzielle Ausnahmen sein könnten. Eine genaue Klärung würde den Kontakt zu den zuständigen Polizeibehörden erfordern.

Da die wertvolle Zeit der Polizeibehörden in Montgomery County nicht für eine rein lehrreiche Analyse der Daten beansprucht werden soll, wurde entschieden, die vorhandenen Werte im Datensatz unverändert zu belassen.

```
min(data$Latitude)
```

```
[1] 37.72
```

```
max(data$Latitude)
```

```
[1] 39.99041
```

```
min(data$Longitude)
```

```
[1] -79.486
```

```
max(data$Longitude)
```

```
[1] -75.52771
```

```
data %>%  
  filter(Latitude < 38.94 | Latitude > 39.35 | Longitude < -77.52 | Longitude > -76.89) %>%  
  select(Latitude, Longitude, Municipality, Agency.Name, Drivers.License.State)
```

```
# A tibble: 214 x 5
```

	Latitude <dbl>	Longitude <dbl>	Municipality <fct>	Agency.Name <fct>	Drivers.License.State <chr>
1	38.7	-77.5	<NA>	Montgomery County Poli~	MD
2	39.4	-77.3	<NA>	Montgomery County Poli~	MD
3	39.4	-77.3	<NA>	Montgomery County Poli~	<NA>
4	38.9	-77.0	<NA>	Montgomery County Poli~	MD
5	39.2	-76.7	<NA>	Montgomery County Poli~	MD
6	40.0	-77.1	<NA>	Montgomery County Poli~	MD
7	39.4	-77.3	<NA>	Montgomery County Poli~	MD
8	39.4	-77.4	<NA>	Montgomery County Poli~	MD
9	39.5	-77.9	<NA>	Montgomery County Poli~	<NA>
10	39.4	-77.3	<NA>	Montgomery County Poli~	MD

```
# i 204 more rows
```

Übersicht der bereinigten Daten

Nach Abschluss aller Transformationen wird der bereinigte Datensatz erneut inspiziert, um die Qualität der Datenaufbereitung zu überprüfen:

```
glimpse(data)
```

Rows: 204,688

Columns: 47

\$ Report.Number	<chr> "MCP3126006X", "MCP2349001B", "MCP296500~
\$ Local.Case.Number	<chr> "250037402", "250037516", "250033157", "~
\$ Agency.Name	<fct> Montgomery County Police Department, Mon~
\$ ACRS.Report.Type	<fct> INJURY CRASH, PROPERTY DAMAGE CRASH, PRO~
\$ Crash.Date.Time	<dtm> 2025-08-21 17:21:00, 2025-08-22 10:44:0~
\$ Route.Type	<fct> Maryland (State) Route, INTERSTATE (STAT~
\$ Road.Name	<chr> NA, "EISENHOWER MEMORIAL HWY", NA, NA, N~
\$ Cross.Street.Name	<chr> NA, NA, "NEW HAMPSHIRE AVE (SB/L) NORBEC~
\$ Off.Road.Description	<chr> NA, NA, NA, NA, "PARKING LOT WAY ~
\$ Municipality	<fct> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ~
\$ Related.Non.Motorist	<fct> NA, NA, NA, NA, NA, "PEDESTRIAN", "PEDES~
\$ Collision.Type	<fct> REAR-END, SINGLE VEHICLE, SIDESWIPE, REA~
\$ Weather	<fct> CLEAR, CLEAR, CLEAR, CLEAR, CLEAR, RAIN,~
\$ Surface.Condition	<fct> "DRY", "DRY", "DRY", "DRY", NA, "WET", "~
\$ Light	<fct> DAYLIGHT, DAYLIGHT, DAYLIGHT, DAYLIGHT, ~
\$ Traffic.Control	<fct> "NO CONTROLS", "NO CONTROLS", "TRAFFIC C~
\$ Driver.Substance.Abuse	<chr> "NOT SUSPECT OF ALCOHOL USE, NOT SUSPECT~
\$ Non.Motorist.Substance.Abuse	<chr> "", "", "", "", "", "NOT SUSPECT OF ALCO~
\$ Person.ID	<chr> "BB3CB0F3-5A89-45FB-9516-48DDDB92B0A9", ~
\$ Driver.At.Fault	<lgl> TRUE, FALSE, FALSE, TRUE, FALSE, FALSE, ~
\$ Injury.Severity	<fct> NO APPARENT INJURY, NA, NO APPARENT INJU~
\$ Circumstance	<chr> "FOLLOWED TOO CLOSELY", NA, NA, "FOLLOWE~
\$ Driver.Distracted.By	<fct> OTHER, OTHER, NOT DISTRACTED, MANUAL OPE~
\$ Drivers.License.State	<chr> "MD", NA, "CO", "MD", NA, "MD", "MD", "M~
\$ Vehicle.ID	<chr> "768C98FA-C137-47BC-BE44-EE3BA4B95F66", ~
\$ Vehicle.Damage.Extent	<fct> SUPERFICIAL, VEHICLE NOT AT SCENE, SUPER~
\$ Vehicle.First.Impact.Location	<fct> Clock Position (12), VEHICLE NOT AT SCEN~
\$ Vehicle.Body.Type	<fct> "PASSENGER CAR", "UNKNOWN", "PASSENGER C~
\$ Vehicle.Movement	<fct> MOVING CONSTANT SPEED, MOVING CONSTANT S~
\$ Vehicle.Going.Dir	<fct> NORTH, NORTH, WEST, SOUTH, NOT ON ROADWA~
\$ Speed.Limit	<int> 40, 55, 40, 30, 0, 25, 0, 25, 10, 35, 30~
\$ Driverless.Vehicle	<lgl> FALSE, FALSE, FALSE, FALSE, FALSE, FALSE~
\$ Parked.Vehicle	<lgl> FALSE, FALSE, FALSE, FALSE, FALSE, FALSE~
\$ Vehicle.Year	<int> 2013, NA, 2023, 2003, 2023, 2016, 2025, ~
\$ Vehicle.Make	<chr> "KIA", "", "LEXUS", "TOYOTA", "SUBARU", ~
\$ Vehicle.Model	<chr> "SOUL", "", "RX", "SIENNA", "IMPREZA", "~
\$ Latitude	<dbl> 39.21980, 39.18018, 39.12122, 39.20793, ~
\$ Longitude	<dbl> -77.25742, -77.25066, -76.98891, -77.141~
\$ Location	<chr> "(39.219796, -77.25741635)", "(39.180180~
\$ Driver.Alcohol	<fct> NOT SUSPECT, UNKNOWN, NOT SUSPECT, NOT S~
\$ Driver.Drugs	<fct> NOT SUSPECT, UNKNOWN, NOT SUSPECT, NOT S~

```

$ Driver.Medication      <fct> UNKNOWN, UNKNOWN, UNKNOWN, UNKNOWN, UNKN~
$ Non.Motorist.Alcohol   <fct> NO CLASSIFICATION, NO CLASSIFICATION, NO~
$ Non.Motorist.Drugs     <fct> NO CLASSIFICATION, NO CLASSIFICATION, NO~
$ Non.Motorist.Medication <fct> UNKNOWN, UNKNOWN, UNKNOWN, UNKNOWN, UNKN~
$ brands_final           <chr> "KIA", NA, "LEXUS", "TOYOTA", "SUBARU", ~
$ models_matched         <chr> "SOUL", NA, NA, "SIENNA", NA, NA, "XC90"~

```

```
skim(data)
```

Table 11: Data summary

Name	data
Number of rows	204688
Number of columns	47
Column type frequency:	
character	16
factor	23
logical	3
numeric	4
POSIXct	1
Group variables	None

Variable type: character

skim_variable	n_missing	complete	ratemin	max	empty	n_unique	whitespace
Report.Number	0	1.00	10	11	0	115360	0
Local.Case.Number	0	1.00	4	11	0	115249	0
Road.Name	23510	0.89	4	43	0	4672	0
Cross.Street.Name	36752	0.82	3	85	0	7463	0
Off.Road.Description	185690	0.09	3	198	0	13489	0
Driver.Substance.Abuse	0	1.00	3	51	0	21	0
Non.Motorist.Substance.Abuse	0	1.00	0	157	198036	28	0
Person.ID	0	1.00	36	36	0	204688	0
Circumstance	24467	0.88	3	416	0	750	0
Drivers.License.State	13659	0.93	2	6	0	81	0
Vehicle.ID	0	1.00	36	36	0	204688	0
Vehicle.Make	11	1.00	0	20	902	1961	0
Vehicle.Model	25	1.00	0	40	905	7149	0

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
Location	0	1.00	13	27	0	114502	0
brands_final	8461	0.96	3	20	0	72	0
models_matched	95391	0.53	3	16	0	103	0

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
Agency.Name	0	1.00	FALSE	5	Mon: 176468, Roc: 12685, Gai: 10246, Tak: 3770
ACRS.Report.Type	0	1.00	FALSE	3	PRO: 131059, INJ: 73108, FAT: 521
Route.Type	20523	0.90	FALSE	14	Mar: 87956, Cou: 66896, Mun: 11665, US : 8916
Municipality	185562	0.09	FALSE	20	ROC: 9320, GAI: 6437, TAK: 1685, KEN: 413
Related.Non.Motorist	198036	0.03	FALSE	17	PED: 4702, CYC: 1452, OTH: 331, SCO: 64
Collision.Type	1544	0.99	FALSE	9	REA: 67009, ANG: 40941, SID: 25350, OTH: 21051
Weather	14632	0.93	FALSE	6	CLE: 142319, RAI: 24107, CLO: 20184, SNO: 2513
Surface.Condition	24050	0.88	FALSE	9	DRY: 144840, WET: 33026, ICE: 1216, SNO: 1136
Light	2699	0.99	FALSE	6	DAY: 139367, DAR: 46645, DAR: 6062, DUS: 4354
Traffic.Control	0	1.00	FALSE	23	NO : 83881, TRA: 69518, N/A: 25473, STO: 14380
Injury.Severity	2164	0.99	FALSE	5	NO : 166287, POS: 19688, SUS: 14684, SUS: 1679
Driver.Distracted.By	0	1.00	FALSE	9	NOT: 128247, UNK: 40472, VIS: 22516, OTH: 6507
Vehicle.Damage.Extent	7038	0.97	FALSE	6	DIS: 76089, SUP: 52610, FUN: 52435, DES: 7610
Vehicle.First.Impact.Location	3238	0.98	FALSE	18	Clo: 77600, Clo: 38860, Clo: 19675, Clo: 17170
Vehicle.Body.Type	0	1.00	FALSE	23	PAS: 140074, SPO: 21196, BUS: 8668, PIC: 8464
Vehicle.Movement	4103	0.98	FALSE	22	MOV: 79920, SLO: 28327, STO: 21114, TUR: 20305

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
Vehicle.Going.Dir	8396	0.96	FALSE	6	NOR: 55049, SOU: 53418, EAS: 40451, WES: 39561
Driver.Alcohol	0	1.00	FALSE	7	NON: 122544, UNK: 46978, NOT: 28033, PRE: 4179
Driver.Drugs	0	1.00	FALSE	7	NON: 122544, UNK: 47034, NOT: 28796, NO : 5703
Driver.Medication	0	1.00	FALSE	3	UNK: 204507, PRE: 117, CON: 64
Non.Motorist.Alcohol	0	1.00	FALSE	7	NO : 198047, NON: 3869, UNK: 1455, NOT: 1078
Non.Motorist.Drugs	0	1.00	FALSE	7	NO : 198225, NON: 3892, UNK: 1446, NOT: 1108
Non.Motorist.Medication	0	1.00	FALSE	2	UNK: 204684, PRE: 4

Variable type: logical

skim_variable	n_missing	complete_rate	mean	count
Driver.At.Fault	4682	0.98	0.52	TRU: 103261, FAL: 96745
Driverless.Vehicle	752	1.00	0.00	FAL: 203936
Parked.Vehicle	1526	0.99	0.02	FAL: 199804, TRU: 3358

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
Speed.Limit	0	1.00	32.20	11.32	0.00	25.00	35.00	40.00	75.00	
Vehicle.Year	5108	0.98	2011.28	6.94	1900.00	2007.00	2012.00	2016.00	2025.00	
Latitude	0	1.00	39.08	0.07	37.72	39.02	39.07	39.14	39.99	
Longitude	0	1.00	-	0.10	-	-	-	-	-	
			77.11		79.49	77.19	77.11	77.04	75.53	

Variable type: POSIXct

skim_variable	n_missing	complete_rate	min	max	median	n_unique
Crash.Date.Time	0	1	2015-01-01 00:30:00	2025-10-21 21:38:00	2019-11-07 17:47:00	112545

Der bereinigte Datensatz enthält nun:

- **Faktorvariablen** für alle kategorialen Merkmale (Agency.Name, Route.Type, Weather, etc.)
- **Logische Variablen** für binäre Merkmale (Driver.At.Fault, Driverless.Vehicle, Parked.Vehicle)
- **Datum/Zeit-Objekte** für zeitliche Analysen (Crash.Date.Time)
- **Numerische Variablen** mit bereinigten Wertebereichen (Vehicle.Year, Speed.Limit, Latitude, Longitude)
- **Neue abgeleitete Variablen** für Substanzeinfluss (Driver.Alcohol, Driver.Drugs, Driver.Medication sowie die entsprechenden Non.Motorist-Variablen)
- **Näherungsweise zugeordnete Fahrzeugdaten** (brands_final, models_matched)

Entsprechen die Daten unseren Erwartungen?

Die transformierten Daten entsprechen weitgehend unseren Erwartungen:

- Die Konvertierung der kategorialen Variablen in Faktoren war erfolgreich und reduziert die Anzahl der eindeutigen Werte durch sinnvolle Gruppierungen.
- Die Trennung der Substanzmissbrauchs-Spalten in separate Alkohol-, Drogen- und Medikamenten-Variablen ermöglicht gezieltere Analysen.
- Die Datumskonvertierung funktioniert korrekt und ermöglicht zeitliche Analysen über den gesamten Zeitraum 2015–2025.
- Die hohe Anzahl an NA-Werten in einigen Spalten (z.B. Related.Non.Motorist, Off.Road.Description) war zu erwarten, da diese Informationen nur in spezifischen Unfallsituationen relevant sind.

Besonderheiten:

- Die geografischen Ausreißer (214 Fälle außerhalb von Montgomery County) wurden bewusst beibehalten, da sie möglicherweise legitime Grenzfälle darstellen.
- Das Fuzzy-Matching der Fahrzeugmarken und -modelle konnte nicht alle Einträge zuordnen, was bei der hohen Variabilität der Originaleinträge jedoch zu erwarten war.

4. Geeignete Visualisierung und Aggregation der Daten

Für die Visualisierungen wird zusätzlich das Paket `ggplot2` geladen:

```
library(ggplot2)
library(tidyr)
```

Im Folgenden werden die fünf formulierten Fragestellungen systematisch untersucht. Für jede Fragestellung werden zunächst deskriptive Statistiken und Visualisierungen erstellt, gefolgt von statistischen Tests zur Überprüfung der Hypothesen.

Fragestellung A: Zeitliche Muster von Verkehrsunfällen

Zu welchen Tageszeiten und Wochentagen ereignen sich die meisten Verkehrsunfälle, und unterscheidet sich die Unfallschwere je nach Zeitpunkt?

Extraktion der Zeitkomponenten


Zunächst werden aus dem `Crash.Date.Time` die relevanten Zeitkomponenten extrahiert:

```
data <- data %>%
  mutate(
    crash_hour = hour(Crash.Date.Time),
    crash_wday = wday(Crash.Date.Time, label = TRUE, abbr = TRUE, week_start = 1),
    crash_month = month(Crash.Date.Time, label = TRUE, abbr = TRUE),
    crash_year = year(Crash.Date.Time)
  )
```

Verteilung nach Tageszeit

```
# Verteilung der Unfälle nach Tageszeit

data %>%
  filter(!is.na(crash_hour)) %>%
  count(crash_hour) %>%
  ggplot(aes(x = crash_hour, y = n)) +
  geom_col(fill = "steelblue") +
  geom_vline(xintercept = c(7, 9, 16, 18), linetype = "dashed", color = "darkred", alpha = 0.5) +
  annotate("text", x = 8, y = max(table(data$crash_hour)) * 0.9, label = "Rush Hour", color = "darkred") +
  annotate("text", x = 17, y = max(table(data$crash_hour)) * 0.9, label = "Rush Hour", color = "darkred") +
  scale_x_continuous(breaks = seq(0, 23, 2)) +
  labs(
    x = "Stunde des Tages",
    y = "Anzahl Unfälle",
    title = "Unfallhäufigkeit nach Tageszeit"
  ) +
  theme_minimal()
```



Zur Analyse der zeitlichen Verteilung der Unfälle wurden zunächst Datensätze mit fehlenden Angaben in der Spalte `crash_hour` bereinigt. Die verbleibenden Daten wurden nach Stunden aggregiert, um die absolute Unfallhäufigkeit im Tagesverlauf zu visualisieren.

Das resultierende Histogramm zeigt zwei deutliche Maxima, die mit den Hauptverkehrszeiten zusammenfallen. Während das Unfallaufkommen in den Nachtstunden (0 bis 4 Uhr) sein Minimum erreicht, ist ab 6 Uhr ein steiler Anstieg zu verzeichnen. Dieser mündet in ein erstes lokales Maximum zwischen 7 und 9 Uhr, welches im Diagramm als morgendliche „Rush Hour“ gekennzeichnet ist.

Nach einem leichten Rückgang am Vormittag steigen die Fallzahlen ab der Mittagszeit erneut kontinuierlich an und erreichen zwischen 16 und 18 Uhr („Evening Rush Hour“) ihren absoluten Tageshöchstwert. Auffällig ist, dass der abendliche Peak signifikant höher ausfällt als der morgendliche, bevor die Kurve in den Abendstunden wieder stetig abfällt.

Heatmap: Stunde × Wochentag


```
# Heatmap: Unfallhäufigkeit nach Stunde und Wochentag

data %>%
  filter(!is.na(crash_hour), !is.na(crash_wday)) %>%
  count(crash_wday, crash_hour) %>%
  ggplot(aes(x = crash_hour, y = crash_wday, fill = n)) +
  geom_tile() +
```

```

scale_fill_gradient(low = "lightyellow", high = "darkred") +
scale_x_continuous(breaks = seq(0, 23, 2)) +
labs(
  x = "Stunde des Tages",
  y = "Wochentag",
  fill = "Anzahl",
  title = "Unfallhäufigkeit nach Stunde und Wochentag"
) +
theme_minimal()

```



Für die Erstellung der Heatmap wurden zunächst Datensätze entfernt, die fehlende Werte in den Variablen `crash_hour` oder `crash_wday` aufwiesen. Die verbleibenden Daten wurden aggregiert, um die Unfallhäufigkeit in Abhängigkeit von Uhrzeit und Wochentag zu visualisieren. Die Farbintensität dient dabei als Indikator für die Fallzahl, wobei dunklere Rottöne eine höhere Unfallkonzentration signalisieren.


Die Grafik verdeutlicht signifikante strukturelle Unterschiede zwischen Werktagen und Wochenenden. An den Tagen Montag bis Freitag ist das klassische Pendler-Muster („Rush Hour“) klar erkennbar: Es zeigen sich zwei ausgeprägte Spitzen am Morgen (ca. 7–9 Uhr) und, noch intensiver, am späten Nachmittag (ca. 15–18 Uhr). Im Gegensatz dazu entfällt am Samstag und Sonntag der morgendliche Peak vollständig. Stattdessen ist am Wochenende ein sanfterer, gleichmäßigerer Anstieg der Unfallzahlen zur Tagesmitte hin zu beobachten, wobei die absoluten Höchstwerte der Woche (dunkelste Rotfärbung) eindeutig in den Feierabendstunden der

Werktage liegen.

Verletzungsschwere nach Tageszeit

```
# Verletzungsschwere nach Tageszeit

data %>%
  filter(!is.na(crash_hour), !is.na(Injury.Severity)) %>%
  mutate(
    time_of_day = case_when(
      crash_hour >= 6 & crash_hour < 10 ~ "Morgen (6-10)",
      crash_hour >= 10 & crash_hour < 16 ~ "Mittag (10-16)",
      crash_hour >= 16 & crash_hour < 20 ~ "Abend (16-20)",
      TRUE ~ "Nacht (20-6)"
    ),
    time_of_day = factor(time_of_day, levels = c("Morgen (6-10)", "Mittag (10-16)", "Abend (16-20)", "Nacht (20-6)"))
  ) %>%
  count(time_of_day, Injury.Severity) %>%
  group_by(time_of_day) %>%
  mutate(anteil = n / sum(n) * 100) %>%
  ggplot(aes(x = Injury.Severity, y = anteil, fill = time_of_day)) +
  geom_col(position = "dodge") +
  labs(
    x = "Verletzungsschwere",
    y = "Anteil (%)",
    fill = "Tageszeit",
    title = "Verletzungsschwere nach Tageszeit"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Zur Analyse der Verletzungsschwere in Abhängigkeit von der Tageszeit wurden die Daten zunächst gruppiert und die absoluten Fallzahlen in relative Anteile (Prozent) umgerechnet. Dieser Schritt war notwendig, um die Verteilungen vergleichbar zu machen, da die absoluten Unfallzahlen je nach Tageszeit stark variieren (siehe vorherige Grafiken).

Die Visualisierung verdeutlicht, dass die Struktur der Unfallfolgen über alle Tageszeiten hinweg weitgehend stabil bleibt. Die Kategorie „NO APPARENT INJURY“ dominiert das Geschehen eindeutig und macht in allen Zeitfenstern (Morgen, Mittag, Abend, Nacht) den weitaus größten Anteil aus (ca. 80 %). Signifikante Abweichungen sind kaum festzustellen, wenngleich bei den schwereren Verletzungsgraden („SUSPECTED SERIOUS INJURY“ und „FATAL INJURY“) in den Nachtstunden (20–6 Uhr) ein minimal erhöhter Anteil im Vergleich zu den Tageszeiten zu erkennen ist.

```
# Anteil schwerer Verletzungen nach Tageszeit
severe_by_time <- data %>%
  filter(!is.na(crash_hour), !is.na(Injury.Severity)) %>%
  mutate(
    time_of_day = case_when(
      crash_hour >= 6 & crash_hour < 10 ~ "Morgen (6-10)",
      crash_hour >= 10 & crash_hour < 16 ~ "Mittag (10-16)",
      crash_hour >= 16 & crash_hour < 20 ~ "Abend (16-20)",
      TRUE ~ "Nacht (20-6)"
    ),
    is_severe = Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")
  )
```

```

) %>%
group_by(time_of_day) %>%
summarise(
  n = n(),
  n_severe = sum(is_severe),
  anteil_severe = mean(is_severe) * 100
)

severe_by_time

```

```

# A tibble: 4 x 4
  time_of_day      n n_severe anteil_severe
  <chr>         <int>   <int>         <dbl>
1 Abend (16-20)  56090     379         0.676
2 Mittag (10-16) 70853     553         0.780
3 Morgen (6-10)  38308     317         0.828
4 Nacht (20-6)   37273     430         1.15

```

Der Anteil der Verletzungsschwere variiert im Tagesverlauf nur gering. Auffällig ist jedoch, dass schwere Verletzungen eher bei Unfällen in der Nacht auftreten.


Monatliche Trends

```

# Monatliche Unfallzahlen über die Jahre

data %>%
  filter(!is.na(crash_month), !is.na(crash_year)) %>%
  count(crash_year, crash_month) %>%
  ggplot(aes(x = crash_month, y = n, group = crash_year, color = as.factor(crash_year))) +
  geom_line(alpha = 0.7) +
  geom_point(size = 1) +
  labs(
    x = "Monat",
    y = "Anzahl Unfälle",
    color = "Jahr",
    title = "Monatliche Unfallzahlen nach Jahr"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

```

Für die Untersuchung der langfristigen Trends und saisonalen Effekte wurden zunächst Datensätze mit fehlenden Zeitangaben (Monat oder Jahr) ausgefiltert. Die verbleibenden Daten wurden aggregiert, um die absoluten Unfallzahlen pro Monat im Jahresvergleich darzustellen.

Die Visualisierung offenbart ein relativ stabiles saisonales Grundmuster für die meisten Jahre, das durch Spitzen im Frühjahr (Mai) und Herbst (Oktober) sowie ein Minimum im Februar gekennzeichnet ist. Eine signifikante Anomalie stellt das Jahr 2020 (türkise Linie) dar: Hier ist ab April ein drastischer Einbruch der Fallzahlen zu verzeichnen, der das übliche Muster durchbricht. Dieser Verlauf korreliert eindeutig mit den Mobilitätseinschränkungen zu Beginn der Corona-Pandemie. Auch das Folgejahr 2021 beginnt auf diesem niedrigen Niveau, bevor eine langsame Annäherung an den langjährigen Durchschnitt (ca. 1.500 bis 2.000 Unfälle/Monat) stattfindet. Der starke Abfall der Kurve für 2025 gegen Jahresende ist hingegen auf eine noch unvollständige Datenerfassung für die letzten Monate zurückzuführen.

Statistische Prüfung: Chi-Quadrat-Test

```
# Chi-Quadrat-Test: Sind Unfälle gleichmäßig über die Wochentage verteilt?
weekday_counts <- table(data$crash_wday)
chisq_weekday <- chisq.test(weekday_counts)
chisq_weekday
```

Chi-squared test for given probabilities

```
data: weekday_counts
X-squared = 3633.2, df = 6, p-value < 2.2e-16
```

```
# Chi-Quadrat-Test: Tageszeit × Verletzungsschwere
time_severity_chi <- data %>%
  filter(!is.na(crash_hour), !is.na(Injury.Severity)) %>%
  mutate(
    time_of_day = case_when(
      crash_hour >= 6 & crash_hour < 10 ~ "Morgen",
      crash_hour >= 10 & crash_hour < 16 ~ "Mittag",
      crash_hour >= 16 & crash_hour < 20 ~ "Abend",
      TRUE ~ "Nacht"
    )
  ) %>%
  select(time_of_day, Injury.Severity)

chisq_time_severity <- chisq.test(table(time_severity_chi$time_of_day, time_severity_chi$Injury.Severity))
chisq_time_severity
```

Pearson's Chi-squared test

```
data: table(time_severity_chi$time_of_day, time_severity_chi$Injury.Severity)
X-squared = 319.39, df = 12, p-value < 2.2e-16
```

Zur statistischen Absicherung der beobachteten Muster wurden Chi-Quadrat-Tests durchgeführt. Zunächst bestätigte der Test für die Wochentage (`weekday_counts`) mit einem p-Wert von $< 2,2 \cdot 10^{-16}$, dass die Unfallhäufigkeit signifikant ungleich über die Woche verteilt ist, was die visuellen Ergebnisse der Heatmap statistisch untermauert.

Für die vertiefende Analyse des Zusammenhangs zwischen Tageszeit und Verletzungsschwere wurde ein weiteres Verfahren angewendet. Im ersten Schritt wurden Datensätze mit fehlenden Werten in den Spalten „`crash_hour`“ und „`Injury.Severity`“ entfernt. Die stundenbasierten Zeitangaben wurden anschließend in die vier diskreten Kategorien „Morgen“ (6–10 Uhr), „Mittag“ (10–16 Uhr), „Abend“ (16–20 Uhr) und „Nacht“ (übrige Zeiten) aggregiert, um die Fallzahlen für den Test zu bündeln.

Der darauf folgende Pearson's Chi-Squared Test lieferte ebenfalls einen extrem niedrigen p-Wert ($< 2,2 \cdot 10^{-16}$). Dieses Ergebnis belegt einen hochsignifikanten stochastischen Zusammenhang zwischen der Tageszeit und der Schwere der Verletzungen. Dies bedeutet, dass die

Verteilung der Verletzungsgrade nicht zufällig ist, sondern signifikant von der Tageszeit abhängt. Damit können die zuvor nur visuell leicht erkennbaren Unterschiede (z. B. nachts) statistisch validiert werden.

Zwischenfazit Fragestellung A

Die zeitliche Analyse bestätigt die aufgestellten Hypothesen weitgehend:

Rush-Hour-Peaks: Die Daten zeigen eindeutig das erwartete zweigipflige Muster mit Spitzen am Morgen (7–9 Uhr) und einem noch ausgeprägteren Maximum am Nachmittag (16–18 Uhr). Der abendliche Peak ist signifikant höher als der morgendliche, was mit dem höheren Verkehrsaufkommen während der Feierabendzeit korreliert.

Wochentag-Unterschiede: Die Heatmap offenbart klare Unterschiede zwischen Werktagen (klassisches Pendler-Muster) und Wochenenden (kein morgendlicher Peak, gleichmäßigerer Anstieg zur Tagesmitte). Der Chi-Quadrat-Test ($p < 2,2 \cdot 10^{-1}$) bestätigt statistisch, dass Unfälle nicht gleichmäßig über die Wochentage verteilt sind.

Nächtliche Unfallschwere: Die Hypothese, dass nächtliche Unfälle trotz geringerer Häufigkeit schwerere Verletzungen verursachen, wird durch die Daten gestützt. Der Anteil schwerer Verletzungen (FATAL + SUSPECTED SERIOUS INJURY) liegt nachts (20–6 Uhr) bei 1,15 % gegenüber 0,83 % am Morgen, 0,78 % am Mittag und 0,68 % am Abend. Der Chi-Quadrat-Test ($p < 2,2 \cdot 10^{-1}$) bestätigt diesen Zusammenhang statistisch.

Fragestellung B: Wetter und Straßenbedingungen


Führen ungünstige Wetterbedingungen und Straßenverhältnisse zu schwereren Unfällen?

Verteilung der Wetterbedingungen

```
# Verteilung der Unfälle nach Wetterbedingungen

data %>%
  filter(!is.na(Weather)) %>%
  count(Weather, sort = TRUE) %>%
  ggplot(aes(x = reorder(Weather, n), y = n, fill = Weather)) +
  geom_col() +
  geom_text(aes(label = scales::comma(n)), hjust = -0.1, size = 3) +
  coord_flip() +
```

```
labs(
  x = "Wetterbedingungen",
  y = "Anzahl Unfälle",
  title = "Unfälle nach Wetterbedingungen"
) +
theme_minimal() +
theme(legend.position = "none") +
scale_y_continuous(expand = expansion(mult = c(0, 0.15)))
```




Für die Analyse des Einflusses der Witterung auf das Unfallgeschehen wurden zunächst Datensätze mit fehlenden Angaben in der Variable „Weather“ entfernt. Die verbleibenden Daten wurden nach der Häufigkeit der Wetterbedingungen aggregiert und absteigend sortiert visualisiert, um die dominierenden Umgebungsfaktoren zu identifizieren.

Die Grafik zeigt eindeutig, dass die überwiegende Mehrheit der Unfälle (142.319 Fälle) bei klaren Wetterverhältnissen („CLEAR“) registriert wurde. Regen („RAIN“) und bewölkter Himmel („CLOUDY“) folgen mit deutlichem Abstand, weisen aber mit ca. 24.000 bzw. 20.000 Fällen noch relevante Anteile auf. Schwierige Sicht- oder Fahrbahnverhältnisse durch Schnee („SNOW/WINTRY“), Nebel („FOG/POOR VISIBILITY“) oder Wind spielen quantitativ eine untergeordnete Rolle. Dies legt nahe, dass die absolute Mehrheit der Verkehrsunfälle nicht durch extreme Wetterlagen verursacht wird, sondern bei normalen Standardbedingungen stattfindet. Dies kann auch darauf zurückzuführen sein, dass im Verhältnis mehr Tage klares Wetter aufwiesen als zum Beispiel Regen oder Schnee.

Verletzungsschwere nach Wetterbedingungen

```
# Verletzungsschwere nach Wetterbedingungen

data %>%
  filter(!is.na(Weather), !is.na(Injury.Severity)) %>%
  count(Weather, Injury.Severity) %>%
  group_by(Weather) %>%
  mutate(anteil = n / sum(n) * 100) %>%
  ggplot(aes(x = Injury.Severity, y = anteil, fill = Weather)) +
  geom_col(position = "dodge") +
  labs(
    x = "Verletzungsschwere",
    y = "Anteil (%)",
    fill = "Wetter",
    title = "Verletzungsschwere nach Wetterbedingungen"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Zur Untersuchung des Zusammenhangs zwischen Witterungsverhältnissen und der Verletzungsschwere wurden zunächst Datensätze mit fehlenden Werten in den entsprechenden Variablen (Weather, Injury.Severity) bereinigt. Da die absoluten Fallzahlen je nach Wetterlage extrem unterschiedlich ausfallen (z. B. sehr viele Fälle bei „CLEAR“, sehr wenige bei „WIND“),

wurden die Daten gruppiert und in relative Anteile umgerechnet. Dies ermöglicht einen direkten Vergleich der Verteilungsstrukturen unabhängig von der Häufigkeit der Wetterereignisse.

Die grafische Auswertung zeigt, dass die Verteilung der Verletzungsschwere weitgehend unabhängig von den Wetterbedingungen ist. Über alle Kategorien hinweg – von klarem Himmel („CLEAR“) bis hin zu schwierigen Verhältnissen wie Schnee („SNOW/WINTRY“) oder Nebel – dominiert die Kategorie „NO APPARENT INJURY“ mit einem Anteil von jeweils etwa 80 %. Es lässt sich visuell kein Trend erkennen, dass schlechte Witterungsbedingungen proportional zu signifikant schwereren Unfallfolgen führen würden; die relative Struktur der Schweregrade bleibt über alle Wetterlagen hinweg nahezu identisch.

```
# Anteil schwerer Verletzungen nach Wetter
severe_by_weather <- data %>%
  filter(!is.na(Weather), !is.na(Injury.Severity)) %>%
  mutate(is_severe = Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")) %>%
  group_by(Weather) %>%
  summarise(
    n = n(),
    n_severe = sum(is_severe),
    anteil_severe = mean(is_severe) * 100
  ) %>%
  arrange(desc(anteil_severe))

severe_by_weather
```

```
# A tibble: 6 x 4
  Weather          n n_severe anteil_severe
  <fct>          <int>   <int>         <dbl>
1 FOG/POOR VISIBILITY  754         8         1.06
2 CLOUDY            20044        190         0.948
3 CLEAR            140569       1209         0.860
4 RAIN              23936        160         0.668
5 SNOW/WINTRY        2496         15         0.601
6 WIND              176          1         0.568
```

Um über die bloße Verteilung der Unfallhäufigkeit hinauszugehen, wurde eine spezifische Analyse der Unfallschwere durchgeführt. Hierfür wurde eine binäre Zielvariable (`is_severe`) definiert, welche die Kategorien „FATAL“ (tödlich) und „SUSPECTED SERIOUS INJURY“ (vermutlich schwer verletzt) zusammenfasst. Anschließend wurde für jede Wetterbedingung der prozentuale Anteil dieser schweren Unfallfolgen berechnet und absteigend sortiert.


Die tabellarische Auswertung offenbart, dass schlechte Sichtverhältnisse („FOG/POOR VISIBILITY“) mit einer Quote von 1,06 % das höchste relative Risiko für schwere Personenschäden

bergen. Bemerkenswert ist, dass klassische widrige Straßenverhältnisse wie Regen („RAIN“, 0,67 %) oder Schnee („SNOW/WINTRY“, 0,60 %) niedrigere Schweregrade aufweisen als Unfälle bei bewölktem (0,95 %) oder klarem Himmel (0,86 %). Dieser Befund könnte darauf hindeuten, dass Verkehrsteilnehmer bei offensichtlicher Glätte oder Nässe tendenziell vorsichtiger oder mit geringerer Geschwindigkeit fahren, während die Gefahren bei Nebel oder vermeintlich guten Bedingungen potenziell unterschätzt werden.

Straßenbedingungen und Fahrzeugschaden

```
# Fahrzeugschaden nach Straßenbedingungen

data %>%
  filter(!is.na(Surface.Condition), !is.na(Vehicle.Damage.Extent)) %>%
  count(Surface.Condition, Vehicle.Damage.Extent) %>%
  group_by(Surface.Condition) %>%
  mutate(anteil = n / sum(n) * 100) %>%
  ggplot(aes(x = Vehicle.Damage.Extent, y = anteil, fill = Surface.Condition)) +
  geom_col(position = "dodge") +
  labs(
    x = "Schadensausmaß",
    y = "Anteil (%)",
    fill = "Straßenbedingung",
    title = "Fahrzeugschaden nach Straßenbedingungen"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Zur Analyse der Wechselwirkung zwischen Straßenbeschaffenheit und Fahrzeugschäden wurden Datensätze mit fehlenden Angaben in den Variablen `Surface.Condition` und `Vehicle.Damage.Extent` bereinigt. Um die stark variierenden absoluten Fallzahlen der verschiedenen Straßenzustände vergleichbar zu machen, wurden die Daten gruppiert und die absoluten Häufigkeiten in relative Anteile innerhalb der jeweiligen Kategorie umgerechnet.

Die Visualisierung verdeutlicht, dass über fast alle Straßenbedingungen hinweg die Schadenstypen „DISABLING“ (fahruntüchtig) und „SUPERFICIAL“ (oberflächlich) dominieren. Dennoch zeigen sich bei genauerer Betrachtung spezifische Risikoprofile: Während auf verschmutzten Untergründen wie „SAND“ oberflächliche Schäden mit über 40 % überproportional häufig auftreten (türkiser Balken), führen glatte Verhältnisse (z. B. „OIL“) besonders oft zu Schäden, die das Fahrzeug fahruntüchtig machen. Auffällig ist die Kategorie „WATER (STANDING/MOVING)“. Hier liegt der Anteil an Totalschäden („DESTROYED“) deutlich über allen anderen Bedingungen (lila Balken), was auf die fatalen Auswirkungen von Wasser auf Motor und Elektronik hindeutet.

Vergleich: Gutes vs. schlechtes Wetter

```
# Verletzungsschwere bei gutem vs. schlechtem Wetter

weather_comparison <- data %>%
  filter(!is.na(Weather), !is.na(Injury.Severity)) %>%
  mutate(
```




```

weather_group = case_when(
  Weather == "CLEAR" ~ "Gutes Wetter",
  TRUE ~ "Schlechtes Wetter"
)
) %>%
count(weather_group, Injury.Severity) %>%
group_by(weather_group) %>%
mutate(anteil = n / sum(n) * 100)

weather_comparison %>%
ggplot(aes(x = Injury.Severity, y = anteil, fill = weather_group)) +
geom_col(position = "dodge") +
labs(
  x = "Verletzungsschwere",
  y = "Anteil (%)",
  fill = "",
  title = "Verletzungsschwere: Gutes vs. schlechtes Wetter"
) +
theme_minimal() +
theme(axis.text.x = element_text(angle = 45, hjust = 1))

```



Um die Analyse zu vereinfachen und zentrale Muster herauszuarbeiten, wurde die komplexe Variable „Weather“ in eine binäre Variable transformiert. Dabei wurde die Ausprägung

„CLEAR“ der Kategorie „Gutes Wetter“ zugeordnet, während alle übrigen Wetterbedingungen (z. B. Regen, Schnee, Nebel) unter „Schlechtes Wetter“ subsumiert wurden. Nach Bereinigung fehlender Werte wurden die relativen Anteile der Verletzungsschwere innerhalb dieser beiden Gruppen verglichen.

Die Visualisierung bestätigt eindrucksvoll, dass die äußeren Witterungsbedingungen kaum Einfluss auf die strukturelle Verteilung der Verletzungsschwere haben. Die Balken für „Gutes Wetter“ und „Schlechtes Wetter“ verlaufen über alle Schweregrade hinweg nahezu synchron. Zwar ist bei gutem Wetter der Anteil gänzlich unverletzter Personen („NO APPARENT INJURY“) minimal höher, während bei schlechtem Wetter die Kategorie „POSSIBLE INJURY“ leicht zunimmt, doch sind diese Abweichungen statistisch kaum relevant. Das Gesamtrisikoprofil bleibt somit unabhängig davon, ob die Sonne scheint oder widrige Bedingungen herrschen, weitgehend konstant.

```
# Vergleich der Anteile schwerer Verletzungen
weather_severe_comparison <- data %>%
  filter(!is.na(Weather), !is.na(Injury.Severity)) %>%
  mutate(
    weather_group = case_when(
      Weather == "CLEAR" ~ "Gutes Wetter",
      TRUE ~ "Schlechtes Wetter"
    ),
    is_severe = Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")
  ) %>%
  group_by(weather_group) %>%
  summarise(
    n = n(),
    n_severe = sum(is_severe),
    anteil_severe = mean(is_severe) * 100
  )

weather_severe_comparison
```

```
# A tibble: 2 x 4
  weather_group      n n_severe anteil_severe
  <chr>          <int>   <int>         <dbl>
1 Gutes Wetter   140569    1209         0.860
2 Schlechtes Wetter 47406     374         0.789
```

Um die Hypothese zu überprüfen, ob widrige Witterung zu schwerwiegenderen Unfallfolgen führt, wurde eine binäre Vergleichsanalyse durchgeführt. Hierfür wurden die Wetterdaten in zwei Gruppen („Gutes Wetter“ vs. „Schlechtes Wetter“) klassifiziert und der Anteil schwerer Verletzungen (definiert als „FATAL“ oder „SUSPECTED SERIOUS INJURY“) berechnet.

Die statistische Auswertung liefert ein auf den ersten Blick unerwartetes Ergebnis: Der Anteil schwerer Verletzungen fällt bei „Gutem Wetter“ mit 0,860 % höher aus als bei „Schlechtem Wetter“ (0,789 %). Obwohl die absoluten Fallzahlen bei gutem Wetter deutlich höher liegen, ist das relative Risiko für schwerste Unfallfolgen bei widrigen Bedingungen geringer. Dies stützt die Annahme, dass Verkehrsteilnehmer bei Regen, Schnee oder Nebel durch angepasste Geschwindigkeit und erhöhte Vorsicht die Schwere der Aufprallenergie reduzieren, während bei optimalen Sicht- und Straßenverhältnissen tendenziell höhere Geschwindigkeiten gefahren werden, die im Unfall zu gravierenderen Verletzungen führen.

Statistische Prüfung: Chi-Quadrat-Test

```
# Chi-Quadrat-Test: Wetter × Verletzungsschwere
weather_injury_chi <- data %>%
  filter(!is.na(Weather), !is.na(Injury.Severity)) %>%
  select(Weather, Injury.Severity)

chisq_weather_injury <- chisq.test(table(weather_injury_chi$Weather, weather_injury_chi$Injury.Severity))
chisq_weather_injury
```

Pearson's Chi-squared test

```
data: table(weather_injury_chi$Weather, weather_injury_chi$Injury.Severity)
X-squared = 97.888, df = 20, p-value = 3.002e-12
```

Zur statistischen Absicherung der visuellen Befunde wurde ein Pearson's Chi-Quadrat-Test durchgeführt. Zuvor wurden die Daten gefiltert, um Einträge mit fehlenden Werten in den Variablen `Weather` und `Injury.Severity` explizit auszuschließen und so eine saubere Datenbasis für die Kreuztabellierung zu schaffen.

Das Testergebnis liefert einen p-Wert von $3,002 \cdot 10^{-12}$, der weit unter dem üblichen Signifikanzniveau von 0,05 liegt. Dies belegt einen hochsignifikanten stochastischen Zusammenhang zwischen der Wetterlage und der Verletzungsschwere. Das Ergebnis bedeutet, dass die beobachteten Unterschiede, etwa das leicht erhöhte Risiko schwerer Verletzungen bei gutem Wetter (siehe vorherige Tabelle), statistisch nicht zufällig sind, sondern systematisch mit den Witterungsbedingungen korrelieren. Aufgrund der großen Stichprobe werden hier selbst kleine strukturelle Abweichungen als statistisch signifikant identifiziert.

```
# Chi-Quadrat-Test: Straßenbedingung × Fahrzeugschaden
surface_damage_chi <- data %>%
  filter(!is.na(Surface.Condition), !is.na(Vehicle.Damage.Extent)) %>%
```

```
select(Surface.Condition, Vehicle.Damage.Extent)

chisq_surface_damage <- chisq.test(table(surface_damage_chi$Surface.Condition, surface_damage_chi$Vehicle.Damage.Extent))
chisq_surface_damage
```

Pearson's Chi-squared test

```
data: table(surface_damage_chi$Surface.Condition, surface_damage_chi$Vehicle.Damage.Extent)
X-squared = 454.16, df = 40, p-value < 2.2e-16
```

Zur statistischen Überprüfung des Zusammenhangs zwischen der Straßenbeschaffenheit und dem Ausmaß des Fahrzeugschadens wurde ein weiterer Chi-Quadrat-Test durchgeführt. Im Vorfeld wurden die Daten erneut bereinigt, indem alle Datensätze mit fehlenden Einträgen in den Variablen `Surface.Condition` und `Vehicle.Damage.Extent` entfernt wurden, um eine valide Kreuztabelle zu erstellen.

Das Testergebnis bestätigt mit einem p-Wert von $< 2,2 \cdot 10^{-16}$ die statistische Signifikanz auf höchstem Niveau. Damit lässt sich die Nullhypothese, dass Straßenzustand und Schadenshöhe voneinander unabhängig seien, eindeutig verwerfen. Dies untermauert die Erkenntnisse aus der vorangegangenen Visualisierung statistisch. Die beobachteten Auffälligkeiten, etwa die gehäuften Totalschäden bei Wasser oder spezifische Schadensbilder bei Glätte, sind nicht zufällig, sondern es besteht ein systematischer Zusammenhang zwischen dem Untergrund und der Schwere des Sachschadens.

Zwischenfazit Fragestellung B

Die Analyse der Wetterbedingungen bestätigt die kontraintuitive Hypothese vollständig:

Unfallhäufigkeit: Die absolute Mehrheit der Unfälle (142.319 Fälle, ca. 73 %) ereignet sich bei klarem Wetter. Widrige Witterungsbedingungen wie Schnee, Nebel oder starker Wind spielen quantitativ eine untergeordnete Rolle.

Verletzungsschwere: Der Vergleich zeigt, dass Unfälle bei gutem Wetter tatsächlich einen höheren Anteil schwerer Verletzungen aufweisen (0,86 %) als bei schlechtem Wetter (0,79 %). Interessanterweise liegt das Risiko schwerer Verletzungen bei Regen (0,67 %) und Schnee (0,6 %) sogar unter dem bei klarem Himmel. Die höchste Quote schwerer Verletzungen findet sich bei Nebel/schlechter Sicht (1,06 %), wo die Gefahr offenbar unterschätzt wird.

Fahrzeugschäden: Bei Straßenbedingungen mit Wasser (stehend/fließend) zeigt sich der höchste Anteil an Totalschäden, während bei Glätte (Eis, Schneematsch) Schäden dominieren, die das Fahrzeug fahruntüchtig machen.

Interpretation: Diese Ergebnisse stützen die Hypothese: Fahrer passen ihr Verhalten bei offensichtlich widrigen Bedingungen an (geringere Geschwindigkeit, erhöhte Aufmerksamkeit), während bei vermeintlich guten Verhältnissen tendenziell schneller und unvorsichtiger gefahren wird. Der Chi-Quadrat-Test ($p = 3,0 \cdot 10^{-12}$) bestätigt den Zusammenhang statistisch.

Fragestellung C: Substanzeinfluss und Schuldfrage

Sind Fahrer mit nachgewiesenem oder vermutetem Alkohol-/Drogeneinfluss häufiger schuld am Unfall?

Deskriptive Analyse: Alkoholeinfluss und Schuld

Zunächst wird die Verteilung der Schuldfrage in Abhängigkeit vom Alkoholstatus untersucht:

```
# Kreuztabelle: Alkohol × Schuld
alcohol_fault_table <- data %>%
  filter(!is.na(Driver.At.Fault), !is.na(Driver.Alcohol)) %>%
  count(Driver.Alcohol, Driver.At.Fault) %>%
  pivot_wider(names_from = Driver.At.Fault, values_from = n, values_fill = 0) %>%
  mutate(
    Total = `FALSE` + `TRUE`,
    Anteil_Schuld = round(`TRUE` / Total * 100, 1)
  )

alcohol_fault_table
```


```
# A tibble: 7 x 5
  Driver.Alcohol `FALSE` `TRUE` Total Anteil_Schuld
  <fct>          <int> <int> <int>         <dbl>
1 CONTRIBUTED      16  1464  1480          98.9
2 NO CLASSIFICATION  30   509   539          94.4
3 NONE DETECTED  59408 59946 119354          50.2
4 NOT SUSPECT    18576  9457  28033          33.7
5 PRESENT         99   4057  4156          97.6
6 SUSPECT        246   684   930          73.5
7 UNKNOWN      18370 27144  45514          59.6
```

```

# Anteil der schuldigen Fahrer nach Alkoholstatus

data %>%
  filter(!is.na(Driver.At.Fault), !is.na(Driver.Alcohol)) %>%
  group_by(Driver.Alcohol) %>%
  summarise(
    n = n(),
    n_schuld = sum(Driver.At.Fault),
    anteil_schuld = mean(Driver.At.Fault) * 100
  ) %>%
  ggplot(aes(x = reorder(Driver.Alcohol, -anteil_schuld), y = anteil_schuld, fill = Driver.A
  geom_col() +
  geom_text(aes(label = paste0(round(anteil_schuld, 1), "%")), vjust = -0.5, size = 3) +
  labs(
    x = "Alkoholstatus",
    y = "Anteil schuldiger Fahrer (%)",
    title = "Schuld am Unfall nach Alkoholstatus"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    legend.position = "none"
  ) +
  ylim(0, 100)

```



Für die Untersuchung des Einflusses von Alkohol auf die Unfallverantwortlichkeit wurde die Variable „Alkoholstatus“ als kategoriale Größe definiert und gegen den prozentualen Anteil der schuldigen Fahrer untersucht. Die Balken wurden absteigend sortiert, um die Korrelation zwischen Alkoholnachweis und Schuldfrage visuell hervorzuheben.

Ein besonders deutlicher Zusammenhang zeigt sich bei den Ausprägungen „CONTRIBUTED“ und „PRESENT“. Diese Werte stehen für Fälle, in denen Alkohol als Unfallursache beitrug oder zumindest vorhanden war, und weisen mit 98,9 % bzw. 97,6 % die höchsten Schuldanteile auf. Bemerkenswert ist zudem die Kategorie „NO CLASSIFICATION“, die sich mit 94,4 % auf einem ähnlich hohen Niveau bewegt. Da dieser Wert deutlich über dem Durchschnitt liegt, ist davon auszugehen, dass auch bei fehlender formeller Klassifizierung oft belastende Umstände vorlagen. Im Gegensatz dazu stehen die Kategorien „NONE DETECTED“ und „NOT SUSPECT“, wobei letztere mit 33,7 % den geringsten Schuldanteil aufweist. Dies verdeutlicht, dass das explizite Ausschließen eines Alkoholverdachts („NOT SUSPECT“) die Wahrscheinlichkeit einer Schuldzuweisung signifikant stärker senkt als das bloße Nicht-Detektieren („NONE DETECTED“).

Deskriptive Analyse: Drogeneinfluss und Schuld


```
# Anteil der schuldigen Fahrer nach Drogenstatus

data %>%
  filter(!is.na(Driver.At.Fault), !is.na(Driver.Drugs)) %>%
```

```

group_by(Driver.Drugs) %>%
summarise(
  n = n(),
  n_schuld = sum(Driver.At.Fault),
  anteil_schuld = mean(Driver.At.Fault) * 100
) %>%
ggplot(aes(x = reorder(Driver.Drugs, -anteil_schuld), y = anteil_schuld, fill = Driver.Drugs)) +
  geom_col() +
  geom_text(aes(label = paste0(round(anteil_schuld, 1), "%")), vjust = -0.5, size = 3) +
  labs(
    x = "Drogenstatus",
    y = "Anteil schuldiger Fahrer (%)",
    title = "Schuld am Unfall nach Drogenstatus"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    legend.position = "none"
  ) +
  ylim(0, 100)

```



Analog zur Untersuchung des Alkoholeinflusses wurde in diesem Schritt der Zusammenhang zwischen dem Drogenstatus („Driver.Drugs“) und der Unfallschuld analysiert. Vor der Berech-

nung wurden die Daten gefiltert, indem Einträge mit fehlenden Werten (NA) sowohl in der Zielvariable „Driver.At.Fault“ als auch in der erklärenden Variable „Driver.Drugs“ ausgeschlossen wurden.

Die Ergebnisse weisen eine bemerkenswerte Ähnlichkeit zur Verteilung beim Alkoholstatus auf. Die Kategorien „CONTRIBUTED“ und „PRESENT“ zeigen mit 99,3 % bzw. 96,3 % erneut die höchsten Schuldanteile. Auch hier fällt die Gruppe „NO CLASSIFICATION“ mit 97,7 % auf, was darauf hindeutet, dass diese Klassifizierung in der Erfassungspraxis faktisch oft mit einer Beeinträchtigung gleichgesetzt wird. Am unteren Ende der Skala bestätigt sich, dass der Status „NOT SUSPECT“ (34,8 %) signifikant stärker entlastend wirkt als der bloße negative Befund „NONE DETECTED“ (50,2 %).

Zusammenhang Alkohol- und Drogeneinfluss

```
# Sind die Spalten identisch?
identical(data$Driver.Alcohol, data$Driver.Drugs)
```

```
[1] FALSE
```

```
# Wie ist die Überlappung?
table(data$Driver.Alcohol, data$Driver.Drugs, useNA = "ifany")
```

	CONTRIBUTED	NO CLASSIFICATION	NONE DETECTED	NOT SUSPECT
CONTRIBUTED	47	1435	0	0
NO CLASSIFICATION	102	181	0	0
NONE DETECTED	0	0	122544	0
NOT SUSPECT	0	0	0	27951
PRESENT	0	4087	0	0
SUSPECT	0	0	0	767
UNKNOWN	0	0	0	78

	PRESENT	SUSPECT	UNKNOWN
CONTRIBUTED	0	0	0
NO CLASSIFICATION	259	0	0
NONE DETECTED	0	0	0
NOT SUSPECT	0	41	41
PRESENT	92	0	0
SUSPECT	0	62	101
UNKNOWN	0	8	46892

Analog zur Untersuchung des Alkoholeinflusses wurde der Zusammenhang zwischen dem Drogenstatus („Driver.Drugs“) und der Unfallschuld analysiert. Die Verteilung der Schuldanteile ähnelt stark der des Alkoholstatus, was eine nähere Untersuchung der Datenstruktur veranlasste.

Eine Kreuztabellierung der beiden Variablen offenbart eine starke Überlappung der Kategorien. Insbesondere bei den unauffälligen Befunden („NONE DETECTED“, „NOT SUSPECT“) sowie den fehlenden Werten („UNKNOWN“) decken sich die Einträge fast vollständig. Auffällig ist die Kategorie „NO CLASSIFICATION“ beim Drogenstatus, die stark mit einem positiven Alkoholfund („PRESENT“ oder „CONTRIBUTED“) korreliert.

Dies lässt darauf schließen, dass bei festgestelltem Alkoholeinfluss häufig auf eine spezifische Klassifizierung des Drogenstatus verzichtet wurde bzw. dieser als „nicht klassifiziert“ eingetragen blieb. Der hohe Schuldanteil in der Kategorie „NO CLASSIFICATION“ (97,7 %) ist somit primär als Effekt des Alkoholeinflusses zu interpretieren und nicht isoliert auf den Drogenstatus zurückzuführen. Echte positive Drogenbefunde („CONTRIBUTED“, „PRESENT“) sind in den Daten deutlich seltener als Alkoholfunde, weisen aber bei Vorliegen eine ebenso eindeutige Schuldzuweisung (>96 %) auf.

Statistische Prüfung: Chi-Quadrat-Test

Um zu prüfen, ob ein statistisch signifikanter Zusammenhang zwischen Alkoholstatus und Schuld besteht, wird ein Chi-Quadrat-Test durchgeführt:

```
# Chi-Quadrat-Test: Alkohol × Schuld
alcohol_fault_chi <- data %>%
  filter(!is.na(Driver.At.Fault), !is.na(Driver.Alcohol)) %>%
  select(Driver.Alcohol, Driver.At.Fault)

chisq_alcohol <- chisq.test(table(alcohol_fault_chi$Driver.Alcohol, alcohol_fault_chi$Driver
chisq_alcohol
```

Pearson's Chi-squared test

```
data: table(alcohol_fault_chi$Driver.Alcohol, alcohol_fault_chi$Driver.At.Fault)
X-squared = 10277, df = 6, p-value < 2.2e-16
```

```
# Chi-Quadrat-Test: Drogen × Schuld
drugs_fault_chi <- data %>%
  filter(!is.na(Driver.At.Fault), !is.na(Driver.Drugs)) %>%
  select(Driver.Drugs, Driver.At.Fault)
```

```
chisq_drugs <- chisq.test(table(drugs_fault_chi$Driver.Drugs, drugs_fault_chi$Driver.At.Fault))
chisq_drugs
```

Pearson's Chi-squared test

```
data: table(drugs_fault_chi$Driver.Drugs, drugs_fault_chi$Driver.At.Fault)
X-squared = 9801.1, df = 6, p-value < 2.2e-16
```

Zur statistischen Absicherung der visuellen Befunde wurde für beide Einflussfaktoren (Alkohol und Drogen) jeweils ein Pearson's Chi-Quadrat-Test durchgeführt. Im ersten Schritt wurde die Datenbasis bereinigt, indem Einträge mit fehlenden Werten (NA) in der Zielvariable `Driver.At.Fault` sowie den jeweiligen Prädiktoren `Driver.Alcohol` und `Driver.Drugs` entfernt wurden.


Die Ergebnisse bestätigen die vermuteten Zusammenhänge eindrucksvoll. Sowohl für den Alkoholstatus (`X-squared = 10277`) als auch für den Drogenstatus (`X-squared = 9801`) liegen die p-Werte weit unter der rechnerischen Nachweisgrenze ($< 2,2 \cdot 10^{-16}$). Dies belegt statistisch hochsignifikant, dass die Unfallschuld nicht unabhängig vom Konsumstatus ist. Die extrem hohen Teststatistiken verdeutlichen zudem die Stärke des Zusammenhangs, was die vorangegangene Analyse zur Überlappung der beiden Variablen und deren massiven Einfluss auf die Unfallverantwortlichkeit quantitativ bestätigt.

Verletzungsschwere bei Substanzeinfluss

```
# Verletzungsschwere bei Unfällen mit und ohne Alkoholeinfluss

data %>%
  filter(!is.na(Injury.Severity), !is.na(Driver.Alcohol)) %>%
  mutate(
    Alkohol_vereinfacht = case_when(
      Driver.Alcohol %in% c("CONTRIBUTED", "PRESENT") ~ "Alkohol nachgewiesen",
      Driver.Alcohol == "NONE DETECTED" ~ "Kein Alkohol",
      TRUE ~ "Unbekannt/Verdacht"
    )
  ) %>%
  filter(Alkohol_vereinfacht != "Unbekannt/Verdacht") %>%
  count(Alkohol_vereinfacht, Injury.Severity) %>%
  group_by(Alkohol_vereinfacht) %>%
  mutate(anteil = n / sum(n) * 100) %>%
  ggplot(aes(x = Injury.Severity, y = anteil, fill = Alkohol_vereinfacht)) +
```

```
geom_col(position = "dodge") +
labs(
  x = "Verletzungsschwere",
  y = "Anteil (%)",
  fill = "Alkoholstatus",
  title = "Verletzungsschwere nach Alkoholstatus"
) +
theme_minimal() +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Für die Untersuchung des Einflusses von Substanzen auf die Unfallfolgen wurde die Variable „Driver.Alcohol“ in eine binäre Variable transformiert. Die Ausprägungen „CONTRIBUTED“ und „PRESENT“ wurden zur Kategorie „Alkohol nachgewiesen“ zusammengefasst, während „NONE DETECTED“ als „Kein Alkohol“ definiert wurde. Unklare Fälle sowie Datensätze mit fehlenden Werten in der Verletzungsschwere wurden aus der Analyse ausgeschlossen, um einen direkten Vergleich der beiden Gruppen zu ermöglichen.

Die Visualisierung offenbart ein differenziertes Risikoprofil. Zwar bildet die Kategorie „NO APPARENT INJURY“ (keine offensichtliche Verletzung) in beiden Gruppen den größten Anteil, doch zeigt sich unter Alkoholeinfluss eine Verschiebung hin zu den extremen Unfallfolgen. Während nüchterne Fahrer häufiger „mögliche Verletzungen“ („POSSIBLE INJURY“) aufweisen, ist bei alkoholisierten Fahrern (roter Balken) der Anteil an schweren Verletzungen

(„SUSPECTED SERIOUS INJURY“) und tödlichen Folgen („FATAL INJURY“) sichtbar erhöht. Dies verdeutlicht, dass Unfälle unter Alkoholeinfluss, wenn es zu physischen Schäden kommt, tendenziell gravierender verlaufen als Unfälle ohne Substanzeinfluss.

Zwischenfazit Fragestellung C

Die Analyse bestätigt beide Teile der aufgestellten Hypothese eindeutig:

Substanzeinfluss und Schuld: Die Daten zeigen einen dramatischen Unterschied in der Schuldzuweisung. Bei nachgewiesenem Alkoholeinfluss („CONTRIBUTED“) liegt der Anteil schuldiger Fahrer bei 98,9 %, bei „PRESENT“ bei 97,6 %. Im Vergleich dazu sind nur 33,7 % der Fahrer mit Status „NOT SUSPECT“ als schuldig eingestuft. Ähnliche Muster zeigen sich beim Drogeneinfluss (99,3 % bei „CONTRIBUTED“, 96,3 % bei „PRESENT“). Die Chi-Quadrat-Tests bestätigen diese Zusammenhänge mit extrem hohen Teststatistiken ($X^2 = 10.277$ für Alkohol, $X^2 = 9.801$ für Drogen, jeweils $p < 2,2 \cdot 10^{-1}$).

Überlappung Alkohol/Drogen: Die Kreuztabellierung zeigt, dass die Kategorien stark überlappen. Bei positivem Alkoholfund wird der Drogenstatus häufig als „NO CLASSIFICATION“ erfasst, was den hohen Schuldanteil dieser Kategorie (97,7 %) erklärt.

Verletzungsschwere: Die Visualisierung bestätigt, dass Unfälle unter Alkoholeinfluss zu einer Verschiebung hin zu schwereren Verletzungsfolgen führen. Der Anteil an „SUSPECTED SERIOUS INJURY“ und „FATAL INJURY“ ist bei alkoholisierten Fahrern sichtbar erhöht, während die Kategorie „POSSIBLE INJURY“ bei nüchternen Fahrern dominiert.

Fazit: Die Hypothese ist vollständig bestätigt. Substanzeinfluss ist sowohl mit signifikant höherer Unfallschuld als auch mit schwereren Verletzungen assoziiert.

Fragestellung D: Ablenkung am Steuer


Welche Ablenkungsarten sind am häufigsten und wie hängen sie mit dem Kollisionstyp zusammen?

Häufigkeit der Ablenkungsarten

```
# Häufigkeit der verschiedenen Ablenkungsarten

distraction_counts <- data %>%
  filter(!is.na(Driver.Distracted.By)) %>%
  count(Driver.Distracted.By, sort = TRUE)
```

```
distraktion_counts %>%
  ggplot(aes(x = reorder(Driver.Distracted.By, n), y = n, fill = Driver.Distracted.By)) +
  geom_col() +
  geom_text(aes(label = scales::comma(n)), hjust = -0.1, size = 3) +
  coord_flip() +
  labs(
    x = "Ablenkungsart",
    y = "Anzahl Unfälle",
    title = "Verteilung der Ablenkungsarten bei Unfällen"
  ) +
  theme_minimal() +
  theme(legend.position = "none") +
  scale_y_continuous(expand = expansion(mult = c(0, 0.15)))
```



```
# Tabelle mit Anteilen
distraktion_counts %>%
  mutate(Anteil = round(n / sum(n) * 100, 1))
```

```
# A tibble: 9 x 3
  Driver.Distracted.By      n Anteil
  <fct>             <int> <dbl>
1 NOT DISTRACTED      128247  62.7
```

2 UNKNOWN	40472	19.8
3 VISUAL DISTRACTION	22516	11
4 OTHER	6507	3.2
5 INATTENTIVE OR LOST IN THOUGHT	4320	2.1
6 INTERNAL DISTRACTION	1027	0.5
7 PHONE USE	769	0.4
8 MANUAL OPERATION	551	0.3
9 NO DRIVER PRESENT	279	0.1


Zur Analyse der Ablenkungsursachen wurden zunächst Datensätze mit fehlenden Angaben in der Variable `Driver.Distracted.By` bereinigt. Die verbleibenden Daten wurden aggregiert, um die absolute Häufigkeit der registrierten Ablenkungsarten zu visualisieren.

Die Ergebnisse zeigen, dass in der Mehrzahl der Fälle (62,7 %) keine Ablenkung des Fahrers dokumentiert wurde. In rund 20 % der Unfälle konnte keine eindeutige Aussage zur Ablenkung getroffen werden ("UNKNOWN"). Die häufigste identifizierte Ablenkungsform ist die visuelle Ablenkung mit einem Anteil von etwa 11 %. Andere Ablenkungsarten, darunter Handynutzung oder sonstige externe Einflüsse, treten vergleichsweise selten auf.

Zusammenhang: Ablenkung und Kollisionstyp

```
# Ablenkungsart und Kollisionstyp

data %>%
  filter(!is.na(Driver.Distracted.By), !is.na(Collision.Type)) %>%
  count(Driver.Distracted.By, Collision.Type) %>%
  group_by(Driver.Distracted.By) %>%
  mutate(anteil = n / sum(n) * 100) %>%
  ggplot(aes(x = Collision.Type, y = Driver.Distracted.By, fill = anteil)) +
  geom_tile() +
  geom_text(aes(label = round(anteil, 0)), size = 3, color = "white") +
  scale_fill_gradient(low = "steelblue", high = "darkred") +
  labs(
    x = "Kollisionstyp",
    y = "Ablenkungsart",
    fill = "Anteil (%)",
    title = "Kollisionstypen nach Ablenkungsart"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Zur Analyse des Zusammenhangs zwischen Fahrerablenkung und der Art des Zusammenstoßes wurden zunächst Datensätze mit fehlenden Angaben in den Variablen `Driver.Distracted.By` und `Collision.Type` bereinigt. Die verbleibenden Daten wurden gruppiert und die absoluten Häufigkeiten in relative Anteile innerhalb der Ablenkungskategorie umgerechnet, um die Verteilung der Unfalltypen quantitativ zu bewerten.

Über nahezu alle Ablenkungsarten hinweg stellen Auffahrunfälle (REAR-END) den häufigsten Kollisionstyp dar. Dieses Muster entspricht der Erwartung, da Ablenkung insbesondere die Reaktionszeit und die Aufmerksamkeit auf den vorausfahrenden Verkehr beeinträchtigt. Eine auffällige Abweichung zeigt sich bei der visuellen Ablenkung, bei der Angle-Kollisionen den höchsten Anteil aufweisen. Bei No driver present lässt sich hingegen der am häufigsten vorkommende Kollisionstyp nicht feststellen, da dieser nicht definiert ist.

Fokus: Handynutzung und Auffahrunfälle

Gemäß unserer Hypothese untersuchen wir, ob Handynutzung überproportional zu Auffahrunfällen (REAR-END) führt:

```
# Vergleich: Anteil REAR-END bei Handynutzung vs. andere Ablenkungen
rearend_comparison <- data %>%
  filter(!is.na(Driver.Distracted.By), !is.na(Collision.Type)) %>%
  mutate(
    is_phone = Driver.Distracted.By == "PHONE USE",
    is_rearend = Collision.Type == "REAR-END"
```



```

) %>%
group_by(is_phone) %>%
summarise(
  n = n(),
  n_rearend = sum(is_rearend),
  anteil_rearend = mean(is_rearend) * 100
) %>%
mutate(Gruppe = if_else(is_phone, "Handynutzung", "Andere Ablenkung"))

rearend_comparison

```

```

# A tibble: 2 x 5
  is_phone      n n_rearend anteil_rearend Gruppe
<lg1>      <int>    <int>         <dbl> <chr>
1 FALSE    202377    66681          32.9 Andere Ablenkung
2 TRUE      767      328          42.8 Handynutzung


```

```

# Anteil Auffahrunfälle: Handynutzung vs. andere Ablenkungen

rearend_comparison %>%
  ggplot(aes(x = Gruppe, y = anteil_rearend, fill = Gruppe)) +
  geom_col() +
  geom_text(aes(label = paste0(round(anteil_rearend, 1), "%")), vjust = -0.5) +
  labs(
    x = "",
    y = "Anteil Auffahrunfälle innerhalb der Gruppe (%)",
    title = "Anteil der Auffahrunfälle (REAR-END) innerhalb jeder Ablenkungsart"
  ) +
  theme_minimal() +
  theme(legend.position = "none") +
  ylim(0, max(rearend_comparison$anteil_rearend) * 1.2)

```



Die Ergebnisse bestätigen diese Annahme deutlich: Bei Unfällen mit Handynutzung handelt es sich in 42,8 % der Fälle um Auffahrunfälle, während dieser Anteil bei allen anderen Ablenkungsarten lediglich 32,9 % beträgt. Damit sind Auffahrunfälle bei Handynutzung überproportional häufig vertreten, was den besonderen Einfluss dieser Ablenkungsform auf das Unfallgeschehen unterstreicht.

Statistische Prüfung: Chi-Quadrat-Test

```
# Chi-Quadrat-Test: Ablenkungsart × Kollisionstyp
distraction_collision_chi <- data %>%
  filter(!is.na(Driver.Distracted.By), !is.na(Collision.Type)) %>%
  select(Driver.Distracted.By, Collision.Type)

chisq_distraction <- chisq.test(table(distraction_collision_chi$Driver.Distracted.By,
                                     distraction_collision_chi$Collision.Type))
chisq_distraction
```

Pearson's Chi-squared test

```
data: table(distraction_collision_chi$Driver.Distracted.By, distraction_collision_chi$Collision.Type)
X-squared = 9285.5, df = 64, p-value < 2.2e-16
```


Zur statistischen Absicherung der deskriptiven Befunde wurde ein Pearson's Chi-Quadrat-Test zwischen der Ablenkungsart und dem Kollisionstyp durchgeführt. Auch hier wurden zuvor Datensätze mit fehlenden Angaben ausgeschlossen.

Der Test ergibt einen extrem kleinen p-Wert ($p < 2,2 \cdot 10^{-1}$), womit die Nullhypothese der Unabhängigkeit klar verworfen werden kann. Es besteht somit ein hochsignifikanter statistischer Zusammenhang zwischen der Art der Ablenkung und dem Kollisionstyp, was die zuvor beobachteten Muster bestätigt.

Ablenkung und Schuld

```
# Schuldanteil nach Ablenkungsart

data %>%
  filter(!is.na(Driver.Distracted.By), !is.na(Driver.At.Fault)) %>%
  group_by(Driver.Distracted.By) %>%
  summarise(
    n = n(),
    anteil_schuld = mean(Driver.At.Fault) * 100
  ) %>%
  ggplot(aes(x = reorder(Driver.Distracted.By, anteil_schuld), y = anteil_schuld, fill = Driver.Distracted.By)) +
  geom_col() +
  geom_text(aes(label = paste0(round(anteil_schuld, 1), "%")), hjust = -0.1, size = 3) +
  coord_flip() +
  labs(
    x = "Ablenkungsart",
    y = "Anteil schuldiger Fahrer (%)",
    title = "Schuld am Unfall nach Ablenkungsart"
  ) +
  theme_minimal() +
  theme(legend.position = "none") +
  scale_y_continuous(limits = c(0, 100), expand = expansion(mult = c(0, 0.1)))
```



Abschließend wurde der Zusammenhang zwischen Ablenkungsart und der Unfallschuld analysiert. Hierzu wurde der Anteil schuldiger Fahrer innerhalb jeder Ablenkungskategorie berechnet und visualisiert.

Die Ergebnisse zeigen, dass bei nahezu allen Formen der Ablenkung der Anteil schuldiger Fahrer sehr hoch ist. Eine deutliche Ausnahme bildet die Kategorie “NOT DISTRACTED”, bei der lediglich 30,4 % der Fahrer als schuldig eingestuft wurden. Dies verdeutlicht, dass festgestellte Ablenkung nahezu immer mit einer Schuldzuweisung einhergeht.

Zwischenfazit Fragestellung D

Die Analyse der Ablenkung am Steuer bestätigt die aufgestellten Hypothesen:

Ablenkungsarten: Der Großteil der Unfälle wird zwar ohne dokumentierte Ablenkung erfasst, jedoch stellt visuelle Ablenkung die häufigste identifizierte Form dar.

Kollisionstypen: Auffahrunfälle dominieren bei nahezu allen Ablenkungsarten. Besonders bei Handynutzung treten Auffahrunfälle signifikant häufiger auf als bei anderen Ablenkungsformen.

Ablenkung und Schuld: Ablenkung ist stark mit der Schuldfrage verknüpft. Während nicht abgelenkte Fahrer vergleichsweise selten als schuldig gelten, wird bei nahezu allen Ablenkungsarten eine sehr hohe Schuldquote beobachtet.

Fazit: Ablenkung am Steuer stellt einen zentralen Risikofaktor im Unfallgeschehen dar. Insbesondere Handynutzung ist häufig mit Auffahrunfällen verbunden und geht oft mit einer

Schuldzuweisung einher. Die Ergebnisse unterstreichen die Bedeutung von Maßnahmen zur Reduktion fahrerseitiger Ablenkung.


Fragestellung E: Fußgänger- und Radfahrerunfälle

Unter welchen Bedingungen ereignen sich Unfälle mit nicht-motorisierten Verkehrsteilnehmern, und wie schwer sind diese?

Verteilung der nicht-motorisierten Verkehrsteilnehmer

```
# Verteilung der nicht-motorisierten Verkehrsteilnehmer bei Unfällen

data %>%
  filter(!is.na(Related.Non.Motorist)) %>%
  count(Related.Non.Motorist, sort = TRUE) %>%
  ggplot(aes(x = reorder(Related.Non.Motorist, n), y = n, fill = Related.Non.Motorist)) +
  geom_col() +
  geom_text(aes(label = n), hjust = -0.1, size = 3) +
  coord_flip() +
  labs(
    x = "Nicht-motorisierter Verkehrsteilnehmer",
    y = "Anzahl Unfälle",
    title = "Unfälle mit nicht-motorisierten Verkehrsteilnehmern"
  ) +
  theme_minimal() +
  theme(legend.position = "none") +
  scale_y_continuous(expand = expansion(mult = c(0, 0.15)))
```



Zur Einordnung der betrachteten Unfallgruppe wurde zunächst die Verteilung der nicht-motorisierten Verkehrsteilnehmer analysiert. Grundlage bildet die Variable “Related.Non.Motorist”, wobei ausschließlich Datensätze mit gültigen Einträgen berücksichtigt wurden. Die Auswertung zeigt, dass Fußgänger den mit Abstand größten Anteil der nicht-motorisierten Unfallbeteiligten darstellen. Fahrradfahrer bilden die zweitgrößte Gruppe, ihr Anteil fällt jedoch deutlich geringer aus. Andere Formen nicht-motorisierter Verkehrsteilnehmer spielen im vorliegenden Datensatz nur eine untergeordnete Rolle. Damit fokussiert sich die weitere Analyse inhaltlich primär auf das Unfallrisiko von Fußgängern und Radfahrern.


Lichtverhältnisse bei Fußgänger-/Radfahrerunfällen

```
# Lichtverhältnisse bei Unfällen mit und ohne nicht-motorisierte Beteiligte

light_comparison <- data %>%
  filter(!is.na(Light)) %>%
  mutate(has_nonmotorist = !is.na(Related.Non.Motorist)) %>%
  count(has_nonmotorist, Light) %>%
  group_by(has_nonmotorist) %>%
  mutate(anteil = n / sum(n) * 100) %>%
  mutate(Gruppe = if_else(has_nonmotorist, "Mit Fußgänger/Radfahrer", "Nur Fahrzeuge"))

light_comparison %>%
```

```
ggplot(aes(x = Light, y = anteil, fill = Gruppe)) +
  geom_col(position = "dodge") +
  labs(
    x = "Lichtverhältnisse",
    y = "Anteil (%)",
    fill = "",
    title = "Lichtverhältnisse: Unfälle mit vs. ohne nicht-motorisierte Beteiligte"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Zur Untersuchung der Lichtverhältnisse wurde eine binäre Variable erstellt, die zwischen Unfällen mit und ohne Beteiligung von Fußgängern oder Radfahrern unterscheidet. Diese Einteilung basiert darauf, ob in der Variable “Related.Non.Motorist” ein Eintrag vorhanden ist oder nicht.

Die vergleichende Analyse zeigt, dass sich der relative Anteil der Lichtverhältnisse bei Unfällen mit nicht-motorisierten Beteiligten insgesamt nur geringfügig von reinen Fahrzeugunfällen unterscheidet. Tageslicht dominiert in beiden Gruppen deutlich.

```
# Anteil Dunkelheit bei Unfällen mit Non-Motorist
dark_rates <- data %>%
  filter(!is.na(Light)) %>%
```

```
mutate(
  has_nonmotorist = !is.na(Related.Non.Motorist),
  is_dark = str_detect(Light, "DARK")
) %>%
group_by(has_nonmotorist) %>%
summarise(
  n = n(),
  n_dark = sum(is_dark),
  anteil_dark = mean(is_dark) * 100
) %>%
mutate(Gruppe = if_else(has_nonmotorist, "Mit Fußgänger/Radfahrer", "Nur Fahrzeuge"))

dark_rates
```

```
# A tibble: 2 x 5
  has_nonmotorist      n n_dark anteil_dark Gruppe
  <lgl>          <int> <int>      <dbl> <chr>
1 FALSE       195424  52492      26.9 Nur Fahrzeuge
2 TRUE         6565   1983      30.2 Mit Fußgänger/Radfahrer
```

Für eine präzisere Betrachtung wurde der Anteil von Unfällen bei Dunkelheit separat berechnet. Hierzu wurden alle Lichtkategorien, die den Begriff “DARK” enthalten, zusammengefasst. Dabei zeigt sich, dass der Anteil der Dunkelheit bei Unfällen mit Fußgängern oder Radfahrern leicht erhöht ist (30,2 % gegenüber 26,9 % bei reinen Fahrzeugunfällen).

Dieser Unterschied deutet darauf hin, dass nicht-motorisierte Verkehrsteilnehmer bei Dunkelheit einem leicht erhöhten Risiko ausgesetzt sind, etwa aufgrund eingeschränkter Sichtbarkeit.


Verletzungsschwere: Vergleich mit Fahrzeugunfällen

```
# Verletzungsschwere: Unfälle mit vs. ohne nicht-motorisierte Beteiligte

data %>%
  filter(!is.na(Injury.Severity)) %>%
  mutate(has_nonmotorist = !is.na(Related.Non.Motorist)) %>%
  count(has_nonmotorist, Injury.Severity) %>%
  group_by(has_nonmotorist) %>%
  mutate(anteil = n / sum(n) * 100) %>%
  mutate(Gruppe = if_else(has_nonmotorist, "Mit Fußgänger/Radfahrer", "Nur Fahrzeuge")) %>%
  ggplot(aes(x = Injury.Severity, y = anteil, fill = Gruppe)) +
```



```
geom_col(position = "dodge") +
labs(
  x = "Verletzungsschwere",
  y = "Anteil (%)",
  fill = "",
  title = "Verletzungsschwere: Unfälle mit vs. ohne nicht-motorisierte Beteiligte"
) +
theme_minimal() +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Im nächsten Schritt wurde die Verletzungsschwere bei Unfällen mit und ohne nicht-motorisierte Beteiligung verglichen. Hierfür wurden die relativen Anteile der verschiedenen Kategorien der Variable “Injury.Severity” innerhalb der Gruppen berechnet.

In beiden Gruppen stellt die Kategorie “NO APPARENT INJURY” den größten Anteil dar. Auffällig ist jedoch, dass bei Unfällen mit ausschließlich motorisierten Fahrzeugen der Anteil unverletzter Beteiligter etwas geringer ausfällt, während mögliche oder leichte Verletzungen häufiger auftreten.

```
# Anteil schwerer Verletzungen (FATAL, SUSPECTED SERIOUS INJURY)
severe_rates <- data %>%
  filter(!is.na(Injury.Severity)) %>%
  mutate(
```

```

    has_nonmotorist = !is.na(Related.Non.Motorist),
    is_severe = Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")
  ) %>%
group_by(has_nonmotorist) %>%
summarise(
  n = n(),
  n_severe = sum(is_severe),
  anteil_severe = mean(is_severe) * 100
) %>%
mutate(Gruppe = if_else(has_nonmotorist, "Mit Fußgänger/Radfahrer", "Nur Fahrzeuge"))

severe_rates

```

```

# A tibble: 2 x 5
  has_nonmotorist      n n_severe anteil_severe Gruppe
  <lgl>             <int>   <int>         <dbl> <chr>
1 FALSE          196001    1658         0.846 Nur Fahrzeuge
2 TRUE           6523      21         0.322 Mit Fußgänger/Radfahrer

```

Um den Fokus gezielt auf besonders gravierende Unfallfolgen zu legen, wurden zusätzlich die Kategorien “FATAL” und “SUSPECTED SERIOUS INJURY” zu einer gemeinsamen Gruppe schwerer Verletzungen zusammengefasst. Diese Analyse zeigt bei beiden Gruppierungen geringe Anteile mit unter einem Prozent. Bei reinen Fahrzeugunfällen ist der Wert mit 0,85 % höher als bei Unfällen mit Fußgängern oder Radfahrern mit 0,32 %.

Tageszeit der Fußgänger-/Radfahrerunfälle

```

# Verteilung der Unfälle mit nicht-motorisierten Beteiligten nach Tageszeit


```

```

data %>%
  filter(!is.na(Related.Non.Motorist), !is.na(Crash.Date.Time)) %>%
  mutate(hour = hour(Crash.Date.Time)) %>%
  count(hour) %>%
  ggplot(aes(x = hour, y = n)) +
  geom_col(fill = "steelblue") +
  geom_smooth(aes(group = 1), method = "loess", se = FALSE, color = "darkred", linewidth = 1) +
  scale_x_continuous(breaks = seq(0, 23, 2)) +
  labs(
    x = "Stunde des Tages",
    y = "Anzahl Unfälle",
    title = "Tageszeit der Unfälle mit Fußgängern/Radfahrern"
  )

```

```
) +  
theme_minimal()
```



Zur Analyse der zeitlichen Struktur der Unfälle wurde aus dem Zeitstempel “Crash.Date.Time” die jeweilige Stunde des Tages extrahiert. Anschließend wurden die absoluten Unfallzahlen pro Stunde aggregiert und visualisiert. Die Darstellung zeigt einen kontinuierlichen Anstieg der Unfallhäufigkeit im Tagesverlauf, mit einem klaren Maximum in den späten Nachmittagsstunden zwischen 17 und 18 Uhr. In den Nachtstunden, insbesondere zwischen 0 und 5 Uhr, treten hingegen die wenigsten Unfälle auf. Dieses Muster passt zu den typischen Zeiten von Fußgängern und Radfahrern.

Statistische Prüfung: Chi-Quadrat-Test

```
# Chi-Quadrat-Test: Non-Motorist-Beteiligung × Lichtverhältnisse  
nonmotorist_light_chi <- data %>%  
  filter(!is.na(Light)) %>%  
  mutate(has_nonmotorist = !is.na(Related.Non.Motorist)) %>%  
  select(has_nonmotorist, Light)  
  
chisq_nonmotorist_light <- chisq.test(table(nonmotorist_light_chi$has_nonmotorist,  
                                           nonmotorist_light_chi$Light))  
chisq_nonmotorist_light
```

Pearson's Chi-squared test

```
data: table(nonmotorist_light_chi$has_nonmotorist, nonmotorist_light_chi$Light)
X-squared = 49.707, df = 5, p-value = 1.591e-09
```

```
# Chi-Quadrat-Test: Non-Motorist-Beteiligung × Verletzungsschwere
nonmotorist_injury_chi <- data %>%
  filter(!is.na(Injury.Severity)) %>%
  mutate(has_nonmotorist = !is.na(Related.Non.Motorist)) %>%
  select(has_nonmotorist, Injury.Severity)

chisq_nonmotorist_injury <- chisq.test(table(nonmotorist_injury_chi$has_nonmotorist,
                                             nonmotorist_injury_chi$Injury.Severity))
chisq_nonmotorist_injury
```

Pearson's Chi-squared test

```
data: table(nonmotorist_injury_chi$has_nonmotorist, nonmotorist_injury_chi$Injury.Severity)
X-squared = 854.64, df = 4, p-value < 2.2e-16
```

Zur statistischen Absicherung der beobachteten Unterschiede wurden zwei Pearson-Chi-Quadrat-Tests durchgeführt. Im ersten Test wurde der Zusammenhang zwischen der Beteiligung nicht-motorisierter Verkehrsteilnehmer und den Lichtverhältnissen untersucht. Im zweiten Test wurde geprüft, ob ein Zusammenhang zwischen der Beteiligung von Fußgängern/Radfahrern und der Verletzungsschwere besteht. Beide Tests ergeben extrem niedrige p-Werte ($p = 1,59 \cdot e^{-9}$ für Lichtverhältnisse bzw. $p < 2,2 \cdot e^{-16}$ für Verletzungsschwere). Damit kann die Nullhypothese der Unabhängigkeit in beiden Fällen klar verworfen werden. Es besteht somit ein statistisch signifikanter Zusammenhang zwischen der Beteiligung nicht-motorisierter Verkehrsteilnehmer und sowohl den Lichtverhältnissen als auch der Verletzungsschwere.

Zwischenfazit Fragestellung E

Die Analyse bestätigt die aufgestellte Hypothese bedingt:

Verletzungsschwere: Schwere Verletzungen treten in beiden Unfallgruppen selten auf und liegen jeweils unter einem Prozent. Der Anteil ist bei reinen Fahrzeugunfällen (0,85 %) sogar leicht höher als bei Unfällen mit Fußgängern oder Radfahrern (0,32 %).

Lichtverhältnisse: Entgegen der ursprünglichen Vermutung ereignen sich Unfälle mit nicht-motorisierten Beteiligten nicht überwiegend bei Dunkelheit. Zwar ist der Dunkelheitsanteil

leicht erhöht, der Großteil der Unfälle findet jedoch bei Tageslicht statt. Der Chi-Quadrat-Test ($p = 1,59 \cdot e^{-}$) zeigt dennoch einen signifikanten Zusammenhang.

Zeitliche Verteilung: Die Häufung der Unfälle in den Nachmittags- und frühen Abendstunden spricht für einen starken Zusammenhang mit alltäglichen Mustern wie Berufsverkehr, Schulwegen und Freizeitaktivitäten.

Fazit: Die Hypothese wird nur teilweise bestätigt. Unfälle mit Fußgängern und Radfahrern treten nicht deutlich häufiger bei schlechten Lichtverhältnissen auf und schwere Verletzungen sind insgesamt selten. Bestätigt wird jedoch die klare zeitliche Häufung dieser Unfälle in den Nachmittags- und frühen Abendstunden, was auf typische Alltagsmuster hinweist.

Ergänzende Analyse: Räumliche Unfallhotspots


Wo konzentrieren sich Verkehrsunfälle geografisch, und unterscheiden sich die Hotspots je nach Unfallschwere?

Übersicht der geografischen Verteilung

```
# Geografische Verteilung aller Unfälle in Montgomery County
str(data$Latitude)
```

```
num [1:204688] 39.2 39.2 39.1 39.2 39 ...
```

```
data %>%
  filter(!is.na(Latitude), !is.na(Longitude)) %>%
  filter(Latitude >= 38.9, Latitude <= 39.4, Longitude >= -77.6, Longitude <= -76.8) %>%
  ggplot(aes(x = Longitude, y = Latitude)) +
  geom_point(alpha = 0.05, size = 0.3, color = "steelblue") +
  coord_fixed(ratio = 1.3) +
  labs(
    x = "Längengrad",
    y = "Breitengrad",
    title = "Räumliche Verteilung der Unfälle in Montgomery County"
  ) +
  theme_minimal()
```




Die Visualisierung zeigt die räumliche Verteilung der Verkehrsunfälle in Montgomery County. Dabei werden lineare Strukturen sichtbar, die den Verlauf von Straßen widerspiegeln. Straßenabschnitte mit einer hohen Punktedichte weisen auf Bereiche mit gehäuftem Unfallgeschehen hin und sind vermutlich zugleich stärker frequentierte Verkehrswege.

Dichtekarte der Unfallhotspots

```
# Dichtekarte der Unfallhotspots

data %>%
  filter(!is.na(Latitude), !is.na(Longitude)) %>%
  filter(Latitude >= 38.9, Latitude <= 39.4, Longitude >= -77.6, Longitude <= -76.8) %>%
  ggplot(aes(x = Longitude, y = Latitude)) +
  geom_density_2d_filled(alpha = 0.8) +
  coord_fixed(ratio = 1.3) +
  labs(
    x = "Längengrad",
    y = "Breitengrad",
    fill = "Dichte",
    title = "Unfallhotspots in Montgomery County"
  ) +
  theme_minimal() +
  theme(legend.position = "right")
```




Die Dichtekarte macht räumliche Unfallhotspots besonders deutlich. Ein erhöhtes Unfallaufkommen ist vor allem im Bereich zwischen den Längengraden -77,3 und -76,9 sowie den Breitengraden 38,95 und 39,2 erkennbar. Dieser Bereich entspricht vermutlich den urbanen Teilen von Montgomery County, in denen eine höhere Verkehrs- und Bevölkerungsdichte vorliegt.

Hotspots schwerer Unfälle

```
# Hotspots schwerer Unfälle (FATAL und SUSPECTED SERIOUS INJURY)

data %>%
  filter(!is.na(Latitude), !is.na(Longitude), !is.na(Injury.Severity)) %>%
  filter(Latitude >= 38.9, Latitude <= 39.4, Longitude >= -77.6, Longitude <= -76.8) %>%
  filter(Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")) %>%
  ggplot(aes(x = Longitude, y = Latitude)) +
  geom_density_2d_filled(alpha = 0.8) +
  geom_point(alpha = 0.3, size = 0.5, color = "darkred") +
  coord_fixed(ratio = 1.3) +
  labs(
    x = "Längengrad",
    y = "Breitengrad",
    fill = "Dichte",
    title = "Hotspots schwerer Unfälle"
```

```
) +  
theme_minimal()
```



Die räumliche Verteilung schwerer Unfälle zeigt ein ähnliches Muster wie die allgemeine Unfallverteilung. Auch hier konzentrieren sich die Hotspots in denselben Bereichen. Im Vergleich zu den allgemeinen Unfallhotspots erscheinen die schweren Unfälle etwas weiter gestreut zu sein.

Vergleich: Schwere vs. leichte Unfälle


```
# Räumlicher Vergleich: Schwere vs. leichte Unfälle  
  
data %>%  
  filter(!is.na(Latitude), !is.na(Longitude), !is.na(Injury.Severity)) %>%  
  filter(Latitude >= 38.9, Latitude <= 39.4, Longitude >= -77.6, Longitude <= -76.8) %>%  
  mutate(  
    Schweregrad = case_when(  
      Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY") ~ "Schwer (Fatal/Serious)"  
      Injury.Severity == "NO APPARENT INJURY" ~ "Keine Verletzung",  
      TRUE ~ "Leicht/Möglich"  
    )  
  ) %>%
```



```

filter(Schweregrad != "Leicht/Möglich") %>%
ggplot(aes(x = Longitude, y = Latitude)) +
geom_density_2d(aes(color = Schweregrad), linewidth = 0.8) +
coord_fixed(ratio = 1.3) +
scale_color_manual(values = c("Keine Verletzung" = "steelblue", "Schwer (Fatal/Serious)" =
labs(
  x = "Längengrad",
  y = "Breitengrad",
  color = "Schweregrad",
  title = "Vergleich der Unfallverteilung nach Schweregrad"
) +
theme_minimal()

```



Die Grafik vergleicht die räumliche Verteilung von schweren Unfällen mit Unfällen ohne Verletzungen anhand von Dichtekonturen. Es wird deutlich, dass sich beide Unfallarten größtenteils in denselben geografischen Räumen bündeln. Gleichzeitig zeigt sich, dass die Dichtekonturen schwerer Unfälle räumlich etwas breiter gestreut sind als jene ohne Verletzungen. Schwere Unfälle treten somit nicht ausschließlich in den dichtesten Unfallhotspots auf, sondern auch in weniger stark frequentierten Bereichen.

Top-Unfallstandorte

```
# Aggregation nach gerundeten Koordinaten zur Identifikation von Hotspots
hotspot_locations <- data %>%
  filter(!is.na(Latitude), !is.na(Longitude)) %>%
  filter(Latitude >= 38.9, Latitude <= 39.4, Longitude >= -77.6, Longitude <= -76.8) %>%
  mutate(
    lat_rounded = round(Latitude, 1),
    lon_rounded = round(Longitude, 1)
  ) %>%
  group_by(lat_rounded, lon_rounded)%>%
  summarise(n = n(), .groups = "drop")%>%
  arrange(desc(n))%>%
  slice_head(n=10)

hotspot_locations
```

```
# A tibble: 10 x 3
  lat_rounded lon_rounded     n
    <dbl>         <dbl> <int>
1      39          -77  38829
2     39.1        -77.1 33649
3     39.1        -77.2 31630
4      39          -77.1 31288
5     39.2        -77.2 19977
6     39.1        -77   16355
7     39.2        -77.3 12210
8     39.1        -76.9  4906
9      39          -77.2  4381
10    39.2        -77.1  3651
```

Nach Aggregation der Daten auf gerundete Koordinaten lassen sich die Hotspots mit den meisten Unfällen identifizieren. Der Standort bei Breitengrad 39, Längengrad -77 weist mit 38.829 Unfällen die höchste Häufigkeit auf. Dicht darauf folgen die Standorte 39,1 / -77,1, 39,1 / -77,2 und 39 / -77,1, die jeweils ebenfalls über 30.000 Unfälle verzeichnen.

Zwischenfazit Räumliche Analyse

Die räumliche Analyse der Verkehrsunfälle in Montgomery County zeigt, dass sich Unfälle geografisch entlang der Straßen verteilen. Besonders hohe Unfallhäufigkeiten treten zwischen den Längengraden -77,3 und -76,9, sowie den Breitengraden 38,95 und 39,2 auf, was auf die urbaneren Bereiche des Countys hindeutet. Ein konkreter Hotspots nach Aggregation gerundeter Koordinaten ist mit 38.829 Unfällen Breitengrad 39 und Längengrad -77.

Die Verteilung schwerer Unfälle ähnelt weitgehend der allgemeinen Unfallverteilung, zeigt jedoch eine etwas größere Streuung, was darauf hindeutet, dass schwere Unfälle nicht allein in den Hotspots auftreten.


Ergänzende Analyse: Fahrzeugtypen und Fahrer-Herkunft

Unterscheiden sich Unfallschwere und Schuldquote je nach Fahrzeugtyp? Woher stammen die Fahrer?

Unfälle nach Fahrzeugtyp

```
# Verteilung der Unfälle nach Fahrzeugtyp

data %>%
  filter(!is.na(Vehicle.Body.Type)) %>%
  count(Vehicle.Body.Type, sort = TRUE) %>%
  head(15) %>%
  ggplot(aes(x = reorder(Vehicle.Body.Type, n), y = n, fill = Vehicle.Body.Type)) +
  geom_col() +
  geom_text(aes(label = scales::comma(n)), hjust = -0.1, size = 3) +
  coord_flip() +
  labs(
    x = "Fahrzeugtyp",
    y = "Anzahl Unfälle",
    title = "Top 15 Fahrzeugtypen bei Unfällen"
  ) +
  theme_minimal() +
  theme(legend.position = "none") +
  scale_y_continuous(expand = expansion(mult = c(0, 0.15)))
```



Der Großteil der bei den Unfällen beteiligten Fahrzeuge waren normale Pkw (140.074). Darauf folgen Sport Utility Vehicles mit 21.196 Unfällen. Busse, Pickups und Vans machen jeweils deutlich geringere Anteile aus, jeweils rund 8.000 Unfälle.

Verletzungsschwere nach Fahrzeugtyp

```
# Anteil schwerer Verletzungen nach Fahrzeugtyp


# Berechnung des Anteils schwerer Verletzungen pro Fahrzeugtyp
vehicle_severity <- data %>%
  filter(!is.na(Vehicle.Body.Type), !is.na(Injury.Severity)) %>%
  group_by(Vehicle.Body.Type) %>%
  summarise(
    n = n(),
    n_severe = sum(Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")),
    anteil_severe = mean(Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")) * 100
  ) %>%
  filter(n >= 100) %>%
  arrange(desc(anteil_severe))

vehicle_severity %>%
  head(15) %>%
  ggplot(aes(x = reorder(Vehicle.Body.Type, anteil_severe), y = anteil_severe, fill = anteil_severe))
```

```

geom_col() +
geom_text(aes(label = paste0(round(anteil_severe, 1), "%")), hjust = -0.1, size = 3) +
coord_flip() +
scale_fill_gradient(low = "steelblue", high = "darkred") +
labs(
  x = "Fahrzeugtyp",
  y = "Anteil schwerer Verletzungen (%)",
  title = "Anteil schwerer Verletzungen nach Fahrzeugtyp",
  subtitle = "(nur Typen mit mind. 100 Unfällen)"
) +
theme_minimal() +
theme(legend.position = "none") +
scale_y_continuous(expand = expansion(mult = c(0, 0.15)))

```



```

# Tabelle der Verletzungsschwere nach Fahrzeugtyp
vehicle_severity %>%
  head(10)

```

```

# A tibble: 10 x 4
  Vehicle.Body.Type      n n_severe anteil_severe
  <fct>          <int>   <int>         <dbl>
1 MOTORCYCLE      1071     227          21.2

```

2	MOPED	131	26	19.8
3	ALL TERRAIN VEHICLE	153	4	2.61
4	RECREATIONAL VEHICLE	197	4	2.03
5	STATION WAGON	884	10	1.13
6	SPORT UTILITY VEHICLE	20956	167	0.797
7	SNOWMOBILE	129	1	0.775
8	PASSENGER CAR	138925	1070	0.770
9	VAN	7701	55	0.714
10	PICKUP	8322	56	0.673

Die Hypothese, dass Motorradfahrer häufiger schwerere Verletzungen erleiden, wird durch die Daten bestätigt. Bei Motorrädern liegt der Anteil schwerer Verletzungen bei 21,1 %, bei Mopeds bei 19,8 %. Darauf folgt mit deutlich geringerem Anteil Geländefahrzeuge mit nur 2,6 %, was den Abstand zu Motorrädern und Mopeds noch einmal verdeutlicht.


Schuldquote nach Fahrzeugtyp

```
# Schuldquote nach Fahrzeugtyp

vehicle_fault <- data %>%
  filter(!is.na(Vehicle.Body.Type), !is.na(Driver.At.Fault)) %>%
  group_by(Vehicle.Body.Type) %>%
  summarise(
    n = n(),
    n_schuld = sum(Driver.At.Fault),
    anteil_schuld = mean(Driver.At.Fault) * 100
  ) %>%
  filter(n >= 100) %>%
  arrange(desc(anteil_schuld))

vehicle_fault %>%
  head(15) %>%
  ggplot(aes(x = reorder(Vehicle.Body.Type, anteil_schuld), y = anteil_schuld, fill = anteil_schuld)) +
  geom_col() +
  geom_text(aes(label = paste0(round(anteil_schuld, 1), "%")), hjust = -0.1, size = 3) +
  coord_flip() +
  scale_fill_gradient(low = "steelblue", high = "darkred") +
  labs(
    x = "Fahrzeugtyp",
    y = "Schuldquote (%)",
    title = "Schuldquote nach Fahrzeugtyp",
    subtitle = "(nur Typen mit mind. 100 Unfällen)"
  )
```

```
) +
theme_minimal() +
theme(legend.position = "none") +
scale_y_continuous(expand = expansion(mult = c(0, 0.15)))
```




Die höchste Schuldquote findet sich bei unbekannten Fahrzeugen, was jedoch wenig aussagekräftig ist. Unter den bekannten Fahrzeugtypen haben Feuerwehrfahrzeuge mit 69,9 % und Krankenwagen mit 64,5 % die höchsten Werte. Dies könnte darauf zurückzuführen sein, dass diese Einsatzfahrzeuge im Notfall schnell unterwegs sind und ihre Aufmerksamkeit auf das Retten von Leben richten müssen, wodurch sie im Straßenverkehr möglicherweise weniger vorsichtig agieren.

Top Fahrzeugmarken

Top 15 Fahrzeugmarken bei Unfällen

```
data %>%
  filter(!is.na(brands_final)) %>%
  count(brands_final, sort = TRUE) %>%
  head(15) %>%
  ggplot(aes(x = reorder(brands_final, n), y = n, fill = brands_final)) +
  geom_col() +
```

```
geom_text(aes(label = scales::comma(n)), hjust = -0.1, size = 3) +
coord_flip() +
labs(
  x = "Fahrzeugmarke",
  y = "Anzahl Unfälle",
  title = "Top 15 Fahrzeugmarken bei Unfällen"
) +
theme_minimal() +
theme(legend.position = "none") +
scale_y_continuous(expand = expansion(mult = c(0, 0.15)))
```



Die am häufigsten bei Unfällen in Montgomery County beteiligten Automarken sind Toyota, Honda und Ford. Da jedoch keine Informationen über die allgemeine Verteilung der Fahrzeugmarken im County vorliegen, lässt sich nicht automatisch darauf schließen, dass die Marke einen Einfluss auf die Unfallhäufigkeit hat.


Fahrzeugalter und Unfälle

```
# Verteilung der Unfälle nach Fahrzeugalter

data %>%
  filter(!is.na(Vehicle.Year), !is.na(crash_year)) %>%
```



```
mutate(vehicle_age = crash_year - Vehicle.Year) %>%
filter(vehicle_age >= 0, vehicle_age <= 30) %>%
ggplot(aes(x = vehicle_age)) +
geom_histogram(binwidth = 1, fill = "steelblue", color = "white") +
labs(
  x = "Fahrzeugalter (Jahre)",
  y = "Anzahl Unfälle",
  title = "Unfallverteilung nach Fahrzeugalter"
) +
theme_minimal()
```



Die meisten Unfälle treten bei Fahrzeugen auf, die ein bis fünf Jahre alt sind. Mit zunehmendem Alter der Fahrzeuge nimmt die Unfallhäufigkeit kontinuierlich ab. Dies erscheint zunächst überraschend, da man erwarten könnte, dass ältere Autos durch Ausfälle oder technische Mängel ein höheres Unfallrisiko hätten. Wahrscheinlich hängt die Statistik jedoch damit zusammen, dass nur wenige Fahrzeuge über einen sehr langen Zeitraum genutzt werden, da viele Menschen ihr Auto heute nur wenige Jahre besitzen oder leasen.

```
# Verletzungsschwere nach Fahrzeugalter (gruppiert)
data %>%
  filter(!is.na(Vehicle.Year), !is.na(crash_year), !is.na(Injury.Severity)) %>%
  mutate(
    vehicle_age = crash_year - Vehicle.Year,
```

```

age_group = case_when(
  vehicle_age < 0 ~ NA_character_,
  vehicle_age <= 3 ~ "0-3 Jahre (neu)",
  vehicle_age <= 7 ~ "4-7 Jahre",
  vehicle_age <= 12 ~ "8-12 Jahre",
  vehicle_age <= 20 ~ "13-20 Jahre",
  TRUE ~ "21+ Jahre (alt)"
) %>%
filter(!is.na(age_group)) %>%
group_by(age_group) %>%
summarise(
  n = n(),
  anteil_severe = mean(Injury.Severity %in% c("FATAL", "SUSPECTED SERIOUS INJURY")) * 100
) %>%
arrange(age_group)

```

```

# A tibble: 5 x 3
  age_group      n anteil_severe
  <chr>      <int>      <dbl>
1 0-3 Jahre (neu) 48449      0.799
2 13-20 Jahre    40404      0.960
3 21+ Jahre (alt) 6824      1.64
4 4-7 Jahre     51093      0.669
5 8-12 Jahre     50632      0.865

```

Ab einem Fahrzeugalter von acht Jahren steigt der Anteil schwerer Unfälle. Fahrzeuge, die 21 Jahre oder älter sind, weisen mit 1,64 % den höchsten Anteil auf. Dies erscheint plausibel, da ältere Fahrzeuge meist schlechter ausgestattet und sicherheitstechnisch weniger modern sind. Zudem nimmt die Funktionsfähigkeit des Fahrzeugs mit der Zeit ab, was das Risiko schwerer Unfälle erhöht.

Herkunft der Fahrer (Führerschein-Staat)

```

# Top 15 Führerschein-Staaten der unfallbeteiligten Fahrer


data %>%
  filter(!is.na(Drivers.License.State), Drivers.License.State != "") %>%
  count(Drivers.License.State, sort = TRUE) %>%
  head(15) %>%
  ggplot(aes(x = reorder(Drivers.License.State, n), y = n, fill = Drivers.License.State)) +

```

```

geom_col() +
geom_text(aes(label = scales::comma(n)), hjust = -0.1, size = 3) +
coord_flip() +
labs(
  x = "Führerschein-Staat",
  y = "Anzahl Unfälle",
  title = "Herkunft der Fahrer nach Führerschein-Staat"
) +
theme_minimal() +
theme(legend.position = "none") +
scale_y_continuous(expand = expansion(mult = c(0, 0.15)))

```



```

# Anteil lokaler vs. auswärtiger Fahrer
data %>%
  filter(!is.na(Drivers.License.State), Drivers.License.State != "") %>%
  mutate(
    herkunft = case_when(
      Drivers.License.State == "MD" ~ "Maryland (lokal)",
      Drivers.License.State %in% c("VA", "DC") ~ "Nachbarstaaten (VA/DC)",
      TRUE ~ "Andere Staaten"
    )
  ) %>%

```

```
count(herkunft) %>%
mutate(anteil = round(n / sum(n) * 100, 1))
```

```
# A tibble: 3 x 3
  herkunft      n anteil
  <chr>      <int> <dbl>
1 Andere Staaten    10349    5.4
2 Maryland (lokal) 168860   88.4
3 Nachbarstaaten (VA/DC) 11820    6.2
```


Der größte Anteil der Fahrer stammt aus Maryland (88,4 %), dem Bundesstaat, in dem Montgomery County liegt. Mit ungefähr 6,2 % folgen Washington D.C. und Virginia, beide direkte Nachbarn von Montgomery County und geografisch sehr nah gelegen. Nur 5,4 % der Fahrer kommen aus anderen Staaten.

Schuldquote nach Herkunft

```
# Schuldquote nach Fahrer-Herkunft

data %>%
  filter(!is.na(Drivers.License.State), !is.na(Driver.At.Fault), Drivers.License.State != "")
  mutate(
    herkunft = case_when(
      Drivers.License.State == "MD" ~ "Maryland (lokal)",
      Drivers.License.State %in% c("VA", "DC") ~ "Nachbarstaaten (VA/DC)",
      TRUE ~ "Andere Staaten"
    )
  ) %>%
  group_by(herkunft) %>%
  summarise(
    n = n(),
    anteil_schuld = mean(Driver.At.Fault) * 100
  ) %>%
  ggplot(aes(x = reorder(herkunft, -anteil_schuld), y = anteil_schuld, fill = herkunft)) +
  geom_col() +
  geom_text(aes(label = paste0(round(anteil_schuld, 1), "%")), vjust = -0.5, size = 4) +
  labs(
    x = "Herkunft",
    y = "Schuldquote (%)",
    title = "Schuldquote nach Fahrer-Herkunft"
  ) +
```

```
theme_minimal() +
theme(legend.position = "none") +
scale_y_continuous(limits = c(0, 70), expand = expansion(mult = c(0, 0.1)))
```



Mit 59 % ist der Anteil schuldiger Fahrer aus anderen Bundesstaaten wie erwartet am höchsten, gefolgt von Fahrern aus Nachbarstaaten mit 51,4 % und einheimischen Fahrern mit 49,4 %. Die Unterschiede sind insgesamt nicht übermäßig groß, was darauf hindeutet, dass Ortskenntnis zwar eine Rolle spielt, sie jedoch nicht allein entscheidend für die Schuld an einem Unfall ist.

Zwischenfazit Fahrzeugtypen und Herkunft

Die Analyse bestätigt, dass sich Unfallschwere und Schuldquote je nach Fahrzeugtyp unterscheiden. Während Pkw den Großteil der Unfälle ausmachen, weisen insbesondere Motorräder und Mopeds den höchsten Anteil schwerer Verletzungen auf, was die Hypothese des fehlenden Karosserieschutzes stützt. Auch das Fahrzeugalter spielt eine Rolle. Ältere Fahrzeuge sind seltener in Unfällen verwickelt, zeigen jedoch einen höheren Anteil schwerer Verletzungen.

Hinsichtlich der Herkunft der Fahrer stammen die meisten Unfallbeteiligten erwartungsgemäß aus Maryland. Auswärtige Fahrer sind zwar zahlenmäßig klar in der Minderheit, weisen jedoch eine etwas höhere Schuldquote auf als lokale Fahrer. Die Unterschiede sind insgesamt moderat, was darauf hindeutet, dass Ortskenntnis zwar einen Einfluss hat, jedoch nicht allein ausschlaggebend für die Schuld des Fahrers ist.

5. Zusammenfassung und Schlussfolgerung

Überblick der Fragestellungen

Diese Analyse untersuchte Verkehrsunfalldaten aus Montgomery County, Maryland (2015–2025) anhand von sieben Fragestellungen. Der Fokus lag auf menschlichen Verhaltensfaktoren und deren Zusammenhang mit Unfallschuld und Verletzungsschwere.

Zusammenfassung der Ergebnisse

Fragestellung A: Zeitliche Muster

Ergebnis: Die zeitliche Analyse zeigt klare, statistisch signifikante Muster. Die Rush-Hour-Peaks (7–9 Uhr und 16–18 Uhr) sind deutlich erkennbar, wobei der abendliche Peak ausgeprägter ist als der morgendliche. Werktage zeigen das klassische Pendler-Muster, während Wochenenden ein gleichmäßigeres Unfallaufkommen zur Tagesmitte aufweisen. Der Anteil schwerer Verletzungen ist nachts (20–6 Uhr) mit 1,15 % deutlich höher als zu anderen Tageszeiten (0,68–0,83 %).

Vergleich mit Hypothese: Wir hatten erwartet, dass (1) Unfälle sich auf die Rush Hours konzentrieren und (2) nächtliche Unfälle zwar seltener, aber schwerer ausfallen. Beides bestätigt sich: Die Peaks morgens und abends sind deutlich sichtbar, und die Nachtunfälle zeigen trotz geringerer Zahl schwerere Verletzungen.

Fragestellung B: Wetter und Straßenbedingungen

Ergebnis: Bei klarem Wetter liegt der Anteil schwerer Verletzungen (0,86 %) höher als bei schlechtem Wetter (0,79 %). Besonders niedrig ist das Risiko bei Regen (0,67 %) und Schnee (0,60 %). Die höchste Quote findet sich bei Nebel (1,06 %), wo die Gefahr unterschätzt zu werden scheint. Bei Straßenbedingungen mit Wasser treten die meisten Totalschäden auf.

Vergleich mit Hypothese: Die Vermutung lautete, dass schlechtes Wetter nicht zwangsläufig zu schwereren Unfällen führt, weil Fahrer ihr Verhalten anpassen. Die Daten bestätigen, dass bei Regen, Schnee oder Eis die Unfallschwere sinkt, was auf vorsichtigeres Fahren hindeutet.

Fragestellung C: Substanzeinfluss und Schuldfrage

Ergebnis: Bei nachgewiesenem Alkoholeinfluss liegt der Schuldanteil bei 97,6–98,9 %, bei Drogeneinfluss bei 96,3–99,3 %. Im Vergleich dazu sind nur 33,7 % der Fahrer mit Status „NOT SUSPECT“ als schuldig eingestuft. Unfälle unter Alkoholeinfluss zeigen zudem eine Verschiebung hin zu schwereren Verletzungsfolgen (erhöhter Anteil FATAL und SUSPECTED SERIOUS INJURY).

Vergleich mit Hypothese: Erwartet hatten wir, dass Fahrer unter Substanzeinfluss häufiger als schuldig eingestuft werden und dass solche Unfälle schwerer ausfallen. Aus den Daten geht klar hervor, dass sowohl die Schuldquote als auch die Verletzungsschwere bei Alkohol- oder Drogeneinfluss klar über dem Durchschnitt liegen.

Fragestellung D: Ablenkung am Steuer

Ergebnis: Visuelle Ablenkung stellt die häufigste identifizierte Ablenkungsart dar. Insgesamt zeigt sich ein klarer Zusammenhang zwischen Ablenkung und Schuldfrage: Nicht abgelenkte Fahrer werden deutlich seltener als schuldig eingestuft, während nahezu alle Ablenkungsarten eine hohe Schuldquote aufweisen.

Vergleich mit Hypothese: Wir erwarteten, dass Handynutzung die häufigste Ablenkungsform ist und besonders oft zu Auffahrunfällen führt. Das stimmt nur teilweise: Am häufigsten ist tatsächlich visuelle Ablenkung allgemein, nicht speziell Handynutzung. Der zweite Teil bestätigt sich aber: Wer am Handy ist, verursacht überproportional viele Auffahrunfälle.

Fragestellung E: Fußgänger- und Radfahrerunfälle

Ergebnis: Entgegen der ursprünglichen Erwartung treten schwere Verletzungen bei reinen Fahrzeugunfällen mit 0,85 % etwas häufiger auf als bei Unfällen mit Fußgängern oder Radfahrern (0,32 %). Zudem ereignet sich die Mehrheit dieser Unfälle bei Tageslicht. Der Anteil der Unfälle bei Dunkelheit liegt bei 21,3 % und ist damit nur geringfügig höher als bei reinen Fahrzeugunfällen (19,7 %).

Vergleich mit Hypothese: Unsere These war, dass Unfälle mit Fußgängern und Radfahrern häufiger bei Dunkelheit passieren und schwerer ausfallen als Fahrzeug-Fahrzeug-Unfälle. Das lässt sich so nicht bestätigen. Was sich allerdings zeigt, ist, dass sich diese Unfälle während der Stoßzeiten morgens und abends häufen.

Fragestellung F: Räumliche Unfallhotspots

Ergebnis: Besonders hohe Unfallhäufigkeiten treten im Bereich zwischen den Längengraden -77,3 und -76,9 sowie den Breitengraden 38,95 und 39,2 auf, was auf die urbaneren Bereiche des Countys hindeutet. Die räumliche Verteilung schwerer Unfälle ähnelt dabei weitgehend der allgemeinen Unfallverteilung, ist jedoch etwas breiter gestreut, was darauf schließen lässt, dass schwere Unfälle nicht ausschließlich in den größten Unfallhotspots auftreten.

Vergleich mit Hypothese: Wir hatten angenommen, dass Unfälle sich entlang von Hauptverkehrsachsen und an Knotenpunkten konzentrieren, während schwere Unfälle eher auf Schnellstraßen auftreten. Das ließ sich nicht vollständig prüfen, da der Datensatz keine Informationen zu Straßentypen enthält. Die räumliche Analyse zeigt allerdings klare Hotspots, die vermutlich stark befahrene Bereiche widerspiegeln.

Fragestellung G: Fahrzeugtypen und Fahrer-Herkunft

Ergebnis: Ältere Fahrzeuge sind insgesamt seltener an Unfällen beteiligt, weisen jedoch einen höheren Anteil schwerer Verletzungen auf. Zudem zeigen Motorräder und Mopeds im Vergleich zu anderen Fahrzeugtypen einen deutlich erhöhten Anteil schwerer Unfallfolgen. Fahrer aus anderen Staaten weisen eine leicht höhere Schuldquote auf, was darauf hindeutet, dass Ortskenntnis einen Einfluss auf das Unfallgeschehen haben kann.

Vergleich mit Hypothese: Die Annahme war, dass Motorradfahrer die höchste Rate schwerer Verletzungen haben und dass auswärtige Fahrer häufiger als schuldig eingestuft werden. Beides trifft zu. Motorrad- und Mopedfahrer sind am stärksten von schweren Verletzungen betroffen, was am fehlenden Karosserieschutz liegt. Fahrer von außerhalb Marylands weisen ebenfalls eine höhere Schuldquote auf, vermutlich wegen mangelnder Ortskenntnis.

Gesamtfazit

Die Analyse der 204.688 Verkehrsunfälle aus Montgomery County (2015–2025) liefert konkrete, statistisch abgesicherte Erkenntnisse:

1. **Menschliches Verhalten ist der stärkste Risikofaktor:** Bei nachgewiesenem Substanzeinfluss liegt die Schuldquote bei über 97%, verglichen mit nur 34 % bei unverdächtigen Fahrern. Dieser Zusammenhang ist statistisch hochsignifikant ($\text{Chi}^2 > 10.000$, $p < 2,2 \cdot 10^{-1}$) und zeigt die zentrale Rolle menschlichen Fehlverhaltens.
2. **Zeitliche Muster ermöglichen gezielte Prävention:** Das höhere Risiko schwerer Verletzungen in der Nacht (1,15 % vs. 0,68-0,83 %) sowie die Rush-Hour-Peaks bieten Ansatzpunkte für verstärkte Polizeipräsenz und Aufklärungskampagnen zu spezifischen Zeiten.
3. **Risikokompensation funktioniert meist:** Bei Regen und Schnee ist das Risiko schwerer Verletzungen niedriger als bei klarem Wetter, was auf angepasstes Fahrverhalten hindeutet. Bei Nebel versagt dieser Mechanismus jedoch (höchste Verletzungsquote mit 1,06 %).

Limitationen

Diese Analyse unterliegt einigen Einschränkungen:

- **Beobachtungsdaten:** Es handelt sich um Beobachtungsdaten, die keine kausalen Schlüsse erlauben. Die identifizierten Zusammenhänge können durch Drittvariablen beeinflusst sein.
- **Fehlende Werte:** Einige Variablen weisen hohe NA-Anteile auf (z.B. Related.Non.Motorist bei 96% der Fälle), was die Generalisierbarkeit einschränken kann.

- **Regionale Beschränkung:** Die Daten stammen ausschließlich aus Montgomery County, Maryland (Vorort von Washington D.C.). Die Ergebnisse sind möglicherweise nicht auf ländliche Gebiete oder andere Bundesstaaten übertragbar.
- **Dokumentationsqualität:** Die Qualität der Daten hängt von der Dokumentation durch die Polizeibehörden ab. Systematische Verzerrungen in der Erfassung (z.B. Untererfassung von Substanzverdacht) können nicht ausgeschlossen werden.

Ausblick

Weiterführende Analysen könnten folgende Aspekte vertiefen:

- Zeitreihenanalyse zur Identifikation langfristiger Trends

Quellenverzeichnis

Verwendete R-Pakete (nicht in der Vorlesung behandelt)

Die folgenden R-Pakete wurden zusätzlich zu den in der Vorlesung behandelten Paketen verwendet:

skimr — Datenübersichten und Zusammenfassungen

Waring E, Quinn M, McNamara A, Arino de la Rubia E, Zhu H, Ellis S (2022).
 skimr: Compact and Flexible Summaries of Data.
 R package version 2.1.5, <https://CRAN.R-project.org/package=skimr>

janitor — Duplikaterkennung und Datenbereinigung

Firke S (2023).
 janitor: Simple Tools for Examining and Cleaning Dirty Data.
 R package version 2.2.0, <https://CRAN.R-project.org/package=janitor>

stringdist — Fuzzy String Matching (Jaro-Winkler-Distanz)

van der Loo M (2014).
 "The stringdist package for approximate string matching."
 The R Journal, 6(1), 111-122.
<https://CRAN.R-project.org/package=stringdist>

formattable — Tabellenformatierung

Ren K, Russell K (2021).
formattable: Create 'Formattable' Data Structures.
R package version 0.2.1, <https://CRAN.R-project.org/package=formattable>

scales — Zahlenformatierung für Visualisierungen

Wickham H, Pedersen TL, Seidel D (2023).
scales: Scale Functions for Visualization.
R package version 1.3.0, <https://CRAN.R-project.org/package=scales>

kableExtra — Erweiterte Tabellenformatierung

Zhu H (2024).
kableExtra: Construct Complex Table with 'kable' and Pipe Syntax.
R package version 1.4.0, <https://CRAN.R-project.org/package=kableExtra>

Datenquelle

Montgomery County Crash Reporting - Drivers Data

Montgomery County, Maryland, USA
Open Data Portal: <https://data.montgomerycountymd.gov/>
Datensatz: Crash Reporting - Drivers Data
Zeitraum: 2015-2025
Anzahl Beobachtungen: 204.688